

Whitepaper

Swiss AI Hub

Contents

1	Executive Summary	12
1.1	Auf einen Blick	12
1.2	Strategische Datensouveränität und Schweizer Compliance	12
1.2.1	Geschäftlicher Nutzen	12
1.2.2	Konzeptioneller Ansatz	12
1.2.3	Technische Umsetzung im Swiss AI Hub	13
1.3	Beschleunigte Wertschöpfung durch das Stufenmodell	13
1.3.1	Geschäftlicher Nutzen	13
1.3.2	Konzeptioneller Ansatz	13
1.3.3	Technische Umsetzung im Swiss AI Hub	13
1.4	Vertrauen durch Transparenz und Closed Workflows	14
1.4.1	Geschäftlicher Nutzen	14
1.4.2	Konzeptioneller Ansatz	14
1.4.3	Technische Umsetzung im Swiss AI Hub	14
1.5	Investitionsschutz durch Open Source und Unabhängigkeit	14
1.5.1	Geschäftlicher Nutzen	14
1.5.2	Konzeptioneller Ansatz	14
1.5.3	Technische Umsetzung im Swiss AI Hub	15
2	Die Business-Herausforderung – AI im Unternehmen	15
2.1	Auf einen Blick	15
2.2	Die Infrastrukturlücke: Von der Demo zur Realität	15
2.2.1	Geschäftlicher Nutzen	15
2.2.2	Konzeptioneller Ansatz	16
2.2.3	Technische Umsetzung im Swiss AI Hub	16
2.3	Fragmentierung, Schatten-IT und Kostenkontrolle	16
2.3.1	Geschäftlicher Nutzen	16
2.3.2	Konzeptioneller Ansatz	16
2.3.3	Technische Umsetzung im Swiss AI Hub	17
2.4	Die Schweizer Compliance-Hürde und Datensouveränität	17
2.4.1	Geschäftlicher Nutzen	17
2.4.2	Konzeptioneller Ansatz	17

2.4.3	Technische Umsetzung im Swiss AI Hub	17
2.5	Vertrauen durch Prozess-Stabilität und Transparenz	18
2.5.1	Geschäftlicher Nutzen	18
2.5.2	Konzeptioneller Ansatz	18
2.5.3	Technische Umsetzung im Swiss AI Hub	18
3	Plattform-Überblick – Die Swiss AI-Hub-Lösung	18
3.1	Auf einen Blick	19
3.2	Enterprise-Infrastruktur <i>“Out-of-the-Box”</i>	19
3.2.1	Geschäftlicher Nutzen	19
3.2.2	Konzeptioneller Ansatz	19
3.2.3	Technische Umsetzung im Swiss AI Hub	19
3.3	Ein Stufenmodell für skalierbare KI-Adoption	20
3.3.1	Geschäftlicher Nutzen	20
3.3.2	Konzeptioneller Ansatz	20
3.3.3	Technische Umsetzung im Swiss AI Hub	20
3.4	Strategische Unabhängigkeit und der <i>“Day 2”</i> -Vorteil	20
3.4.1	Geschäftlicher Nutzen	20
3.4.2	Konzeptioneller Ansatz	21
3.4.3	Technische Umsetzung im Swiss AI Hub	21
4	Datensouveränität und vollständige Kundenkontrolle	21
4.1	Auf einen Blick	21
4.2	Physische Datenhoheit und flexible Infrastruktur	22
4.2.1	Geschäftlicher Nutzen	22
4.2.2	Konzeptioneller Ansatz	22
4.2.3	Technische Umsetzung im Swiss AI Hub	22
4.3	Granulare Zugriffskontrolle und dynamische Sichtbarkeit	23
4.3.1	Geschäftlicher Nutzen	23
4.3.2	Konzeptioneller Ansatz	23
4.3.3	Technische Umsetzung im Swiss AI Hub	23
4.4	Modell-Agnostik und proaktiver Datenschutz	23
4.4.1	Geschäftlicher Nutzen	23
4.4.2	Konzeptioneller Ansatz	24

4.4.3	Technische Umsetzung im Swiss AI Hub	24
4.5	Langzeit-Verfügbarkeit und Deep Observability	24
4.5.1	Geschäftlicher Nutzen	24
4.5.2	Konzeptioneller Ansatz	24
4.5.3	Technische Umsetzung im Swiss AI Hub	25
5	Kapitel 04: Plattform-Transparenz und Prüfbarkeit	25
5.1	Auf einen Blick	25
5.2	Nachvollziehbarkeit von KI-Entscheidungen	26
5.2.1	Geschäftlicher Nutzen	26
5.2.2	Konzeptioneller Ansatz	26
5.2.3	Technische Umsetzung im Swiss AI Hub	26
5.3	Revisionssichere Datenherkunft (Data Lineage)	27
5.3.1	Geschäftlicher Nutzen	27
5.3.2	Konzeptioneller Ansatz	27
5.3.3	Technische Umsetzung im Swiss AI Hub	27
5.4	Enterprise Observability und Monitoring	27
5.4.1	Geschäftlicher Nutzen	27
5.4.2	Konzeptioneller Ansatz	28
5.4.3	Technische Umsetzung im Swiss AI Hub	28
5.5	Menschliche Kontrolle (Human-in-the-Loop)	28
5.5.1	Geschäftlicher Nutzen	28
5.5.2	Konzeptioneller Ansatz	28
5.5.3	Technische Umsetzung im Swiss AI Hub	29
5.6	Qualitätssicherung und Evaluation	29
5.6.1	Geschäftlicher Nutzen	29
5.6.2	Konzeptioneller Ansatz	29
5.6.3	Technische Umsetzung im Swiss AI Hub	29
5.7	Finanzielle Transparenz und Kostenkontrolle	30
5.7.1	Geschäftlicher Nutzen	30
5.7.2	Konzeptioneller Ansatz	30
5.7.3	Technische Umsetzung im Swiss AI Hub	30
6	Kapitel 05: Administration und Governance	30

6.1	Auf einen Blick	31
6.2	Identitätsmanagement und hierarchische Zugriffskontrolle	31
6.2.1	Mehrwert für die Unternehmenssicherheit	31
6.2.2	Föderierte Identität und dynamische Sichtbarkeit	31
6.2.3	Technische Implementierung via RBAC und OIDC	31
6.3	Mandantenfähigkeit und organisatorische Trennung	32
6.3.1	Effiziente Abbildung von Konzernstrukturen	32
6.3.2	Logische Isolation und das Agenten-Unabhängigkeitsprinzip	32
6.3.3	Drei-Ebenen-Mandantenmodell in der Praxis	32
6.4	Ressourcensteuerung und Kostenmanagement	33
6.4.1	Wirtschaftliche Planungssicherheit	33
6.4.2	Proaktive Limits und Echtzeit-Monitoring	33
6.4.3	Umsetzung im LLM-Gateway	33
6.5	Operative Überwachung und Compliance-Management	33
6.5.1	Stabilität durch tiefe Observability	33
6.5.2	Standardbasierte Telemetrie und Daten-Lifecycles	34
6.5.3	Technische Realisierung mit OTel und SigNoz	34
7	Kapitel 06: Datenmanagement, Integration und Ingestion	34
7.1	Auf einen Blick	35
7.2	Strukturierte Wissensarchitektur und Scoping	35
7.2.1	Geschäftlicher Nutzen	35
7.2.2	Konzeptioneller Ansatz	35
7.2.3	Technische Umsetzung im Swiss AI Hub	35
7.3	Die Daten-zu-Wissen-Pipeline: Präzision durch Struktur	36
7.3.1	Geschäftlicher Nutzen	36
7.3.2	Konzeptioneller Ansatz	36
7.3.3	Technische Umsetzung im Swiss AI Hub	36
7.4	Organisationsgedächtnis und geteilte Fakten	37
7.4.1	Geschäftlicher Nutzen	37
7.4.2	Konzeptioneller Ansatz	37
7.4.3	Technische Umsetzung im Swiss AI Hub	37
7.5	Automatisierte Integration und Synchronisation	37

7.5.1	Geschäftlicher Nutzen	37
7.5.2	Konzeptioneller Ansatz	38
7.5.3	Technische Umsetzung im Swiss AI Hub	38
7.6	Validierung und Sicherheit beim Import	38
7.6.1	Geschäftlicher Nutzen	38
7.6.2	Konzeptioneller Ansatz	38
7.6.3	Technische Umsetzung im Swiss AI Hub	38
8	Datensicherheit und Datenfluss	39
8.1	Auf einen Blick	39
8.2	Schutz vor KI-spezifischen Bedrohungen und Systemhärtung	39
8.2.1	Geschäftlicher Nutzen	39
8.2.2	Konzeptioneller Ansatz	40
8.2.3	Technische Umsetzung im Swiss AI Hub	40
8.3	Automatisierte Anonymisierung und PII-Schutz	40
8.3.1	Geschäftlicher Nutzen	40
8.3.2	Konzeptioneller Ansatz	41
8.3.3	Technische Umsetzung im Swiss AI Hub	41
8.4	Verschlüsselungsarchitektur und Netzwerk-Isolation	41
8.4.1	Geschäftlicher Nutzen	41
8.4.2	Konzeptioneller Ansatz	41
8.4.3	Technische Umsetzung im Swiss AI Hub	42
8.5	Daten-Lebenszyklus und Revisionssichere Löschung	42
8.5.1	Geschäftlicher Nutzen	42
8.5.2	Konzeptioneller Ansatz	42
8.5.3	Technische Umsetzung im Swiss AI Hub	42
8.6	Sicherheits-Monitoring und Anomalieerkennung	43
8.6.1	Geschäftlicher Nutzen	43
8.6.2	Konzeptioneller Ansatz	43
8.6.3	Technische Umsetzung im Swiss AI Hub	43
9	Sicherheitsarchitektur	43
9.1	Auf einen Blick	44
9.2	Mehrschichtige Abwehr und Netzwerk-Isolation	44

9.2.1	Geschäftlicher Nutzen	44
9.2.2	Konzeptioneller Ansatz	44
9.2.3	Technische Umsetzung im Swiss AI Hub	45
9.3	Identitätsmanagement und Zugriffskontrolle	45
9.3.1	Geschäftlicher Nutzen	45
9.3.2	Konzeptioneller Ansatz	45
9.3.3	Technische Umsetzung im Swiss AI Hub	45
9.4	Kryptografische Absicherung und Datenintegrität	46
9.4.1	Geschäftlicher Nutzen	46
9.4.2	Konzeptioneller Ansatz	46
9.4.3	Technische Umsetzung im Swiss AI Hub	46
9.5	Anwendungssicherheit und KI-Schutzschilde	47
9.5.1	Geschäftlicher Nutzen	47
9.5.2	Konzeptioneller Ansatz	47
9.5.3	Technische Umsetzung im Swiss AI Hub	47
10	Kapitel 09: Regulatorische Compliance	47
10.1	Auf einen Blick	48
10.2	Territoriale Rechtskonformität und Datensouveränität	48
10.2.1	Geschäftlicher Nutzen	48
10.2.2	Konzeptioneller Ansatz	48
10.2.3	Technische Umsetzung im Swiss AI Hub	49
10.3	Datenschutz und Automatisierung von Betroffenenrechten	49
10.3.1	Geschäftlicher Nutzen	49
10.3.2	Konzeptioneller Ansatz	49
10.3.3	Technische Umsetzung im Swiss AI Hub	49
10.4	Konformität mit dem EU AI Act und ethische Governance	50
10.4.1	Geschäftlicher Nutzen	50
10.4.2	Konzeptioneller Ansatz	50
10.4.3	Technische Umsetzung im Swiss AI Hub	50
10.5	Inklusivität und Schweizer Mehrsprachigkeit	50
10.5.1	Geschäftlicher Nutzen	50
10.5.2	Konzeptioneller Ansatz	51

10.5.3 Technische Umsetzung im Swiss AI Hub	51
11 Kapitel 10: Deployment, Betrieb	51
11.1 Auf einen Blick	51
11.2 Flexible Betriebsmodelle und Datensouveränität	52
11.2.1 Geschäftlicher Nutzen	52
11.2.2 Konzeptioneller Ansatz	52
11.2.3 Technische Umsetzung im Swiss AI Hub	52
11.3 Sicherheitsarchitektur und Netzwerk-Isolation	53
11.3.1 Geschäftlicher Nutzen	53
11.3.2 Konzeptioneller Ansatz	53
11.3.3 Technische Umsetzung im Swiss AI Hub	53
11.4 Skalierbarkeit und operative Resilienz	53
11.4.1 Geschäftlicher Nutzen	53
11.4.2 Konzeptioneller Ansatz	54
11.4.3 Technische Umsetzung im Swiss AI Hub	54
11.5 Hochverfügbarkeit und Disaster Recovery	54
11.5.1 Geschäftlicher Nutzen	54
11.5.2 Konzeptioneller Ansatz	54
11.5.3 Technische Umsetzung im Swiss AI Hub	55
11.6 Updates und technologische Unabhängigkeit	55
11.6.1 Geschäftlicher Nutzen	55
11.6.2 Konzeptioneller Ansatz	55
11.6.3 Technische Umsetzung im Swiss AI Hub	55
11.7 Operative Transparenz und Monitoring	56
11.7.1 Geschäftlicher Nutzen	56
11.7.2 Konzeptioneller Ansatz	56
11.7.3 Technische Umsetzung im Swiss AI Hub	56
12 Kapitel 11: Integration und Interoperabilität	56
12.1 Auf einen Blick	57
12.2 Standardisierte API-Architektur und Entwickler-Schnittstellen	57
12.2.1 Geschäftlicher Nutzen	57
12.2.2 Konzeptioneller Ansatz	57

12.2.3 Technische Umsetzung im Swiss AI Hub	58
12.3 Integration in Kommunikations- und Arbeitsplattformen	58
12.3.1 Geschäftlicher Nutzen	58
12.3.2 Konzeptioneller Ansatz	58
12.3.3 Technische Umsetzung im Swiss AI Hub	59
12.4 Anbindung externer Fachsysteme und Prozessautomatisierung	59
12.4.1 Geschäftlicher Nutzen	59
12.4.2 Konzeptioneller Ansatz	59
12.4.3 Technische Umsetzung im Swiss AI Hub	59
12.5 Identitätsintegration und Single Sign-On (SSO)	60
12.5.1 Geschäftlicher Nutzen	60
12.5.2 Konzeptioneller Ansatz	60
12.5.3 Technische Umsetzung im Swiss AI Hub	60
13 Kapitel 12: User Experience und Interaktion	61
13.1 Auf einen Blick	61
13.2 Die integrierte Suite (íIntegrated Productivity Suitež)	61
13.2.1 Geschäftlicher Nutzen	61
13.2.2 Konzeptioneller Ansatz	62
13.2.3 Technische Umsetzung im Swiss AI Hub	62
13.3 Multimodale Interaktion und Barrierefreiheit	62
13.3.1 Geschäftlicher Nutzen	62
13.3.2 Konzeptioneller Ansatz	62
13.3.3 Technische Umsetzung im Swiss AI Hub	63
13.4 Vertrauen durch Quellentransparenz und Datenkontrolle	63
13.4.1 Geschäftlicher Nutzen	63
13.4.2 Konzeptioneller Ansatz	63
13.4.3 Technische Umsetzung im Swiss AI Hub	63
13.5 Nahtlose Integration in den Arbeitsalltag	64
13.5.1 Geschäftlicher Nutzen	64
13.5.2 Konzeptioneller Ansatz	64
13.5.3 Technische Umsetzung im Swiss AI Hub	64
14 Kapitel 13: AI-Agenten und Kernkonzepte	65

14.1 Auf einen Blick	65
14.2 Deterministische Workflow-Steuerung statt ´Black Box`	65
14.2.1 Geschäftlicher Nutzen	65
14.2.2 Konzeptioneller Ansatz	66
14.2.3 Technische Umsetzung im Swiss AI Hub	66
14.3 Transparenz durch das Swiss AI Agent Protokoll	66
14.3.1 Geschäftlicher Nutzen	66
14.3.2 Konzeptioneller Ansatz	66
14.3.3 Technische Umsetzung im Swiss AI Hub	67
14.4 Spezialisierung und Multi-Agenten-Kollaboration	67
14.4.1 Geschäftlicher Nutzen	67
14.4.2 Konzeptioneller Ansatz	67
14.4.3 Technische Umsetzung im Swiss AI Hub	67
14.5 Menschliche Kontrolle und Qualitätssicherung	68
14.5.1 Geschäftlicher Nutzen	68
14.5.2 Konzeptioneller Ansatz	68
14.5.3 Technische Umsetzung im Swiss AI Hub	68
15 Kapitel 14: Business-Prozessautomatisierung	68
15.1 Auf einen Blick	69
15.2 Ganzheitliche Orchestrierung und agentische Prozesse	69
15.2.1 Geschäftlicher Nutzen	69
15.2.2 Konzeptioneller Ansatz	69
15.2.3 Technische Umsetzung im Swiss AI Hub	70
15.3 Hybride Entscheidungsarchitektur und Kollaborationsmuster	70
15.3.1 Geschäftlicher Nutzen	70
15.3.2 Konzeptioneller Ansatz	70
15.3.3 Technische Umsetzung im Swiss AI Hub	70
15.4 Systemintegration und Integrationsmuster	71
15.4.1 Geschäftlicher Nutzen	71
15.4.2 Konzeptioneller Ansatz	71
15.4.3 Technische Umsetzung im Swiss AI Hub	71
15.5 Langläufer-Prozesse und persistente Zustandsverwaltung	71

15.5.1 Geschäftlicher Nutzen	71
15.5.2 Konzeptioneller Ansatz	72
15.5.3 Technische Umsetzung im Swiss AI Hub	72
16 Kapitel 15: Zuverlässigkeit und Qualitätssicherung	72
16.1 Auf einen Blick	73
16.2 Systematische Evaluierung und nAI-Richterz	73
16.2.1 Geschäftlicher Nutzen	73
16.2.2 Konzeptioneller Ansatz	73
16.2.3 Technische Umsetzung im Swiss AI Hub	73
16.3 Laufzeit-Schutzmechanismen und Halluzinationsprävention	74
16.3.1 Geschäftlicher Nutzen	74
16.3.2 Konzeptioneller Ansatz	74
16.3.3 Technische Umsetzung im Swiss AI Hub	74
16.4 Transparenz durch Quellenbelege und Nachweisketten	75
16.4.1 Geschäftlicher Nutzen	75
16.4.2 Konzeptioneller Ansatz	75
16.4.3 Technische Umsetzung im Swiss AI Hub	75
16.5 Kontinuierliches Monitoring und Feedback-Zyklen	75
16.5.1 Geschäftlicher Nutzen	75
16.5.2 Konzeptioneller Ansatz	76
16.5.3 Technische Umsetzung im Swiss AI Hub	76
16.6 Professionelles Debugging und Trace-Analyse	76
16.6.1 Geschäftlicher Nutzen	76
16.6.2 Konzeptioneller Ansatz	76
16.6.3 Technische Umsetzung im Swiss AI Hub	76
17 Kapitel 16: Erweiterbarkeit und Zukunftssicherheit	77
17.1 Auf einen Blick	77
17.2 Investitionsschutz durch Open Source und Standards	77
17.2.1 Geschäftlicher Nutzen	77
17.2.2 Konzeptioneller Ansatz	78
17.2.3 Technische Umsetzung im Swiss AI Hub	78
17.3 Modulare Architektur und Vermeidung von Modell-Lock-in	78

17.3.1 Geschäftlicher Nutzen	78
17.3.2 Konzeptioneller Ansatz	78
17.3.3 Technische Umsetzung im Swiss AI Hub	79
17.4 Erweiterbarkeit durch SDK und Plugin-System	79
17.4.1 Geschäftlicher Nutzen	79
17.4.2 Konzeptioneller Ansatz	79
17.4.3 Technische Umsetzung im Swiss AI Hub	79
17.5 Lifecycle-Management und Update-Strategie	80
17.5.1 Geschäftlicher Nutzen	80
17.5.2 Konzeptioneller Ansatz	80
17.5.3 Technische Umsetzung im Swiss AI Hub	80

1 Executive Summary

Der Swiss AI Hub löst das zentrale Dilemma, dem sich Schweizer Unternehmen bei der Einführung künstlicher Intelligenz gegenübersehen: Wie lassen sich die Vorteile moderner Sprachmodelle nutzen, ohne die Kontrolle über sensible Daten an ausländische Cloud-Anbieter abzugeben oder Jahre an Entwicklungszeit in den Aufbau eigener Infrastruktur zu investieren? Während Prototypen heute an einem Nachmittag erstellt sind, scheitern viele Projekte an der Hürde zur Produktionsreife – an Fragen der Sicherheit, der Kostenkontrolle und der Integration in bestehende Geschäftsprozesse.

Dieses Whitepaper präsentiert eine Lösung, die diese Lücke schliesst. Der Swiss AI Hub ist nicht bloss eine weitere Programmbibliothek, sondern eine vollständige Enterprise-KI-Infrastruktur, die Organisationen besitzen, kontrollieren und innerhalb von 30 Minuten in Betrieb nehmen können. Durch die konsequente Ausrichtung auf Schweizer Werte wie Datensouveränität und Transparenz sowie eine Architektur, die auf offenen Standards basiert, bietet die Plattform eine zukunftssichere Basis für die KI-Transformation.

1.1 Auf einen Blick

- **Vollständige Infrastruktur statt Baukasten:** Eine produktionsreife Plattform, die 24/7 Probleme wie Authentifizierung, Kostenkontrolle und Monitoring bereits im Standard löst.
- **Garantierte Schweizer Datensouveränität:** Die Daten verbleiben physisch in der Schweiz und innerhalb Ihres Sicherheitsperimeters; der Hub ist vollständig 100% Self-Hosted-fähig.
- **Beschleunigte Einführung durch das Stufenmodell:** Ein strukturierter Pfad führt Organisationen sicher vom einfachen KI-Zugang bis zur komplexen Prozessautomatisierung.
- **Kein Vendor Lock-in:** Dank Open-Source-Architektur (Apache 2.0) und Modell-Agnostik bleiben Unternehmen unabhängig von spezifischen KI-Providern.
- **Vertrauen durch 100% Closed Workflows:** Deterministische Agenten-Abläufe sorgen für Vorhersagbarkeit und erfüllen höchste Compliance-Anforderungen.

1.2 Strategische Datensouveränität und Schweizer Compliance

1.2.1 Geschäftlicher Nutzen

Für Schweizer Organisationen, insbesondere in regulierten Sektoren wie dem Finanzwesen, dem Gesundheitswesen oder der öffentlichen Verwaltung, ist der Einsatz öffentlicher KI-Dienste oft mit untragbaren Risiken verbunden. Das Hochladen vertraulicher Unternehmensdaten in die Cloud globaler Hyperscaler kollidiert häufig mit dem revidierten Schweizer Datenschutzgesetz (revDSG) oder internen Compliance-Vorgaben. Dies führt dazu, dass Innovationsprojekte blockiert werden. Der Swiss AI Hub löst diesen Konflikt, indem er vollständige Datensouveränität garantiert. Unternehmen müssen sich nicht länger zwischen technologischer Innovation und Rechtssicherheit entscheiden; sie erhalten die Fähigkeit, modernste KI-Modelle zu nutzen, während die Datenhoheit uneingeschränkt im eigenen Unternehmen verbleibt.

1.2.2 Konzeptioneller Ansatz

Das zugrundeliegende Prinzip ist die absolute Kontrolle über den Speicherort und den Fluss der Daten. Im Gegensatz zu SaaS-Lösungen ist der Swiss AI Hub als Infrastruktur konzipiert, die der

Kunde selbst betreibt (Self-Hosted). Ob On-Premise auf eigenen Servern oder in einer privaten Schweizer Cloud: Die Daten verlassen niemals den vom Mandanten definierten Sicherheitsperimeter. Dieses Konzept ermöglicht auch den Einsatz lokaler Open-Source-Modelle für hochsensible Personenidentifizierbare Informationen (PII), während weniger kritische Anfragen bei Bedarf über ein kontrolliertes Gateway an externe Anbieter geleitet werden können.

1.2.3 Technische Umsetzung im Swiss AI Hub

Technisch realisiert der Swiss AI Hub dies durch eine containerisierte Architektur. Kernkomponenten wie die Vektordatenbank (Milvus) für die Speicherung von Unternehmenswissen und die Daten-zu-Wissen-Pipeline operieren lokal. Zudem integriert die Plattform Presidio zur automatischen Erkennung und Anonymisierung von PII, bevor Daten an ein Modell gesendet werden. Das integrierte LLM-Gateway fungiert als zentrale Schleuse, die den Datenfluss überwacht und sicherstellt, dass alle Interaktionen den Schweizer Datenschutzstandards entsprechen.

1.3 Beschleunigte Wertschöpfung durch das Stufenmodell

1.3.1 Geschäftlicher Nutzen

Viele KI-Initiativen scheitern, weil sie versuchen, komplexe Automatisierungen einzuführen, bevor die organisatorische Basis steht. Zudem unterschätzen Unternehmen oft den Aufwand für den produktiven Betrieb – den sogenannten *ñDay 2z*. Der Swiss AI Hub reduziert dieses Risiko durch ein modulares Stufenmodell. Es ermöglicht einen schnellen Start mit minimalem Investitionsrisiko und skaliert mit der Reife der Organisation. Dies verkürzt die Time-to-Value drastisch, da die Infrastruktur nicht neu erfunden werden muss, sondern als *ñBatteries-includedz*-Produkt bereitsteht.

1.3.2 Konzeptioneller Ansatz

Der Hub verfolgt einen evolutionären Pfad in drei Stufen: Stufe 1 etabliert einen sicheren, zentralen Zugang zu KI-Modellen für alle Mitarbeitenden. Stufe 2 reichert diese Intelligenz durch die Anbindung von Unternehmensdaten (Retrieval-Augmented Generation, RAG) an, wodurch kontextspezifische Agenten-Profile entstehen. Stufe 3 orchestriert schliesslich komplexe Geschäftsprozesse, in denen Agenten, Menschen und bestehende Systeme (wie SAP oder SharePoint) nahtlos zusammenarbeiten. Dieser Ansatz stellt sicher, dass die technologische Komplexität stets im Einklang mit dem fachlichen Nutzen wächst.

1.3.3 Technische Umsetzung im Swiss AI Hub

Die Plattform ist für ein Ein-Befehl-Deployment optimiert. Mittels Docker oder Kubernetes wird der gesamte Stack inklusive Datenbanken, Message Queues und Benutzeroberflächen in wenigen Minuten bereitgestellt. Die Trennung von Plattform und SDK erlaubt es Entwicklern, sich ausschliesslich auf die Geschäftslogik der Agenten-Baupläne zu konzentrieren, während die Plattform Funktionen wie Authentifizierung via SSO/OAuth, Kostenmanagement pro Team und automatische Datenpipelines mittels Dagster und Docling übernimmt.

1.4 Vertrauen durch Transparenz und Closed Workflows

1.4.1 Geschäftlicher Nutzen

Ein zentrales Hemmnis für KI im Unternehmen ist die mangelnde Vorhersehbarkeit autonomer Systeme. Entscheidungsträger benötigen die Gewissheit, dass KI-Systeme definierte Prozesse einhalten und dass jede Entscheidung nachvollziehbar bleibt. Der Swiss AI Hub schafft dieses Vertrauen, indem er Zufall durch deterministische Abläufe ersetzt. Dies ist essenziell für interne Audits, die Akzeptanz bei den Mitarbeitenden und die Erfüllung regulatorischer Anforderungen wie dem EU AI Act.

1.4.2 Konzeptioneller Ansatz

Anstatt offenen Agentenschleifen freien Lauf zu lassen, setzt der Swiss AI Hub auf Workflow-basierte Agenten in sogenannten "Closed Workflows". Ein Agenten-Bauplan definiert exakte Schritte und Pfade. Ein Agent kann keine unvorhersehbaren Aktionen ausführen oder auf Daten zugreifen, die nicht explizit für sein Agenten-Profil freigegeben wurden. Ergänzt wird dies durch das Prinzip der vollständigen Observability, bei dem jede Interaktion protokolliert und visualisiert wird.

1.4.3 Technische Umsetzung im Swiss AI Hub

Die Nachvollziehbarkeit wird technisch durch die Integration von Phoenix für Tracing und Evaluation sichergestellt. Jeder Schritt eines Agenten erzeugt Trace-Daten, die genau aufzeigen, welche Dokumente aus der Wissensdatenbank herangezogen wurden und wie das Modell zur Antwort kam. Administratoren können über Dashboards in Echtzeit verfolgen, wie Agenten agieren, Kosten überwachen und bei Bedarf menschliche Genehmigungsschritte (Human-in-the-Loop) in die Prozesse integrieren.

1.5 Investitionsschutz durch Open Source und Unabhängigkeit

1.5.1 Geschäftlicher Nutzen

In einem sich rasant wandelnden Technologiemarkt ist die Abhängigkeit von einem einzelnen Anbieter ein erhebliches strategisches Risiko. Proprietäre Plattformen binden Kunden oft durch intransparente Preismodelle. Der Swiss AI Hub bietet hierzu einen Gegenentwurf: Als Open-Source-Plattform unter der Apache 2.0 Lizenz garantiert er maximale Unabhängigkeit. Unternehmen investieren in ihre eigene Infrastruktur, was die langfristige Portierbarkeit und Prüfbarkeit des Systems sichert.

1.5.2 Konzeptioneller Ansatz

Das System ist konsequent modell-agnostisch gestaltet. Es abstrahiert die darunterliegenden Sprachmodelle über das LLM-Gateway. Unternehmen können heute ein globales Modell nutzen und morgen nahtlos auf ein kosteneffizienteres oder ein lokales Modell wechseln, ohne ihre Agenten-Baupläne anpassen zu müssen. Dieser Ansatz stärkt die Verhandlungsposition gegenüber Providern und schützt die getätigten Entwicklungs-Investitionen.

1.5.3 Technische Umsetzung im Swiss AI Hub

Die technische Basis bildet ein moderner Technologie-Stack (PostgreSQL, Valkey, NATS), der in der Industrie weit verbreitet ist. Das LLM-Gateway (LiteLLM) vereinheitlicht die APIs verschiedener Provider. Da der Quellcode offenliegt, können interne IT-Teams die Plattform jederzeit auditieren oder erweitern. Die Datenhaltung erfolgt in offenen Formaten, was den Export und die Migration von Daten sowie des gesammelten Wissens in der Wissensdatenbank jederzeit ermöglicht.

2 Die Business-Herausforderung – AI im Unternehmen

Der aktuelle Hype um generative KI verdeckt oft eine unbequeme Wahrheit: Es ist trivial, an einem Nachmittag eine beeindruckende Demo zu erstellen, aber ausserordentlich schwierig, ein produktives, unternehmenstaugliches System zu bauen. Viele Organisationen befinden sich aktuell in einer Phase der Desillusionierung. Nach erfolgreichen ersten Tests mit Bibliotheken wie LangChain oder direkten API-Aufrufen an OpenAI stellen sie fest, dass der Weg zur Produktivsetzung durch massive infrastrukturelle Hürden blockiert ist.

Dieses Kapitel analysiert die Diskrepanz zwischen Prototyping und Engineering und beleuchtet die spezifischen Herausforderungen für Schweizer Unternehmen. Es zeigt auf, warum der Versuch, KI-Infrastruktur selbst zu bauen, oft in einer teuren Sackgasse endet und wie die Lücke zwischen dem ersten „Wow“-Effekt und einem stabilen Betrieb („Day 2“) durch einen produktorientierten Infrastruktur-Ansatz geschlossen werden kann.

2.1 Auf einen Blick

- **Infrastruktur-Lücke:** Der Schritt vom Prototyp zur Produktion scheitert meist nicht an der KI-Logik, sondern an fehlenden Enterprise-Funktionen wie Authentifizierung, Monitoring und Skalierbarkeit.
- **Schatten-IT und Fragmentierung:** Isolierte KI-Experimente in Fachabteilungen erzeugen Datensilos und unkontrollierbare Kosten, die eine zentrale Governance verunmöglichen.
- **Schweizer Datensouveränität:** Strenge regulatorische Anforderungen blockieren oft die Nutzung ausländischer Cloud-Dienste, was ohne lokale Alternativen zu einem Innovationsstau führt.
- **Investitionsschutz:** Offene Standards und eine modell-agnostische Architektur verhindern einen Vendor-Lock-in und sichern die langfristige technologische Unabhängigkeit.
- **Vertrauen durch Vorhersagbarkeit:** Für geschäftskritische Prozesse sind deterministische Abläufe („Closed Workflows“) zwingend, um das Risiko unkontrollierter KI-Entscheidungen zu eliminieren.

2.2 Die Infrastrukturlücke: Von der Demo zur Realität

2.2.1 Geschäftlicher Nutzen

Ein funktionierender Prototyp beantwortet selten die Fragen, die für den operativen Betrieb entscheidend sind: Wie skalieren wir die Lösung? Wo bleiben unsere Daten physisch? Wie kontrollieren wir die laufenden Kosten? Für Entscheidungsträger bedeutet diese Lücke ein hohes finanzielles und operatives Risiko. Projekte bleiben oft im Pilotstadium stecken („Pilot Purgatory“), weil die notwendige

Infrastruktur für Sicherheit und Governance fehlt. Dies führt zu Fehlinvestitionen, da die Time-to-Value durch den nachträglichen, mühsamen Aufbau von Basistechnologien massiv verzögert wird. IT-Teams binden wertvolle Ressourcen in der Entwicklung von Fundamenten, anstatt geschäftlichen Mehrwert zu generieren.

2.2.2 Konzeptioneller Ansatz

Das Kernproblem liegt in der Unterscheidung zwischen KI-Logik und Infrastruktur. Während Code-Bibliotheken beim Bau der Agenten helfen, ignorieren sie die betriebliche Realität. Eine Enterprise-Lösung benötigt einen *„Infrastructure as a Product“*-Ansatz. Das bedeutet, dass Komponenten wie Authentifizierung, Daten-Pipelines und Audit-Trails nicht für jedes Projekt neu erfunden werden dürfen. Sie müssen als stabile, einsatzbereite Plattform bereitstehen – quasi *„Batteries-included“*. Nur so lässt sich der Sprung vom *„Day 1“* (der ersten Demo) zum *„Day 2“* (dem stabilen Betrieb) wirtschaftlich und sicher vollziehen.

2.2.3 Technische Umsetzung im Swiss AI Hub

Der Swiss AI Hub schliesst diese Lücke, indem er die für den Betrieb notwendigen Komponenten integral mitliefert. Anstatt eigene Lösungen für die Benutzerverwaltung zu entwickeln, nutzen alle Dienste automatisch die Anbindung an den Identitätsanbieter via SSO/OAuth. Die Plattform bietet eine produktionsreife Architektur, die vom API-Gateway über Vektordatenbanken (Milvus) bis hin zu skalierbaren Daten-zu-Wissen-Pipelines (Dagster) alles umfasst. Für die operative Sicherheit sorgt eine integrierte Beobachtbarkeit auf vier Ebenen: Infrastruktur-Monitoring via OpenTelemetry, Agenten-Tracing via Phoenix, sowie detaillierte Einsichten in Workflow-Events und Datenflüsse.

2.3 Fragmentierung, Schatten-IT und Kostenkontrolle

2.3.1 Geschäftlicher Nutzen

Ohne eine zentrale Plattform tendieren Abteilungen dazu, isolierte Lösungen zu implementieren. Das Marketing nutzt ChatGPT-Abos, die IT experimentiert mit Azure OpenAI und die Entwicklung baut lokale RAG-Systeme. Diese Fragmentierung führt zu intransparenten Kostenstrukturen und fördert eine gefährliche Schatten-IT. Für den CFO wird es unmöglich, die effektiven Kosten zu ermitteln oder Budgets sinnvoll zuzuweisen. Zudem entstehen Datensilos, in denen wertvolles Wissen gefangen bleibt. Das Risiko von Compliance-Verstössen steigt mit jeder unkontrollierten Einzellösung, während Synergieeffekte ungenutzt bleiben.

2.3.2 Konzeptioneller Ansatz

Die Lösung liegt in der Konsolidierung auf einer mandantenfähigen Plattform, die als zentrales Gateway fungiert. Anstatt direkter API-Zugriffe auf Modell-Provider durch einzelne Mitarbeitende, läuft jeglicher Verkehr über eine kontrollierte Instanz. Dies ermöglicht eine zentrale Durchsetzung von Richtlinien, Quotas und Budgets für jeden Mandanten. Gleichzeitig wird verhindert, dass technologische Sackgassen entstehen, da die zugrundeliegenden Modelle ausgetauscht werden können, ohne die darüberliegenden Geschäftsprozesse zu beeinträchtigen.

2.3.3 Technische Umsetzung im Swiss AI Hub

Technisch realisiert der Swiss AI Hub diese Zentralisierung durch das LLM-Gateway (basierend auf LiteLLM). Diese Komponente abstrahiert die verschiedenen Modell-Provider und ermöglicht ein granulares Kostenmanagement in Echtzeit. Administratoren können Budgets und Ratenbegrenzungen (Tokens pro Minute) auf Benutzer- oder Team-Ebene definieren. Die Plattform verhindert Silos zudem durch zentralisierte Wissensdatenbanken, die über standardisierte Pipelines befüllt werden. So kann aufbereitetes Wissen organisationsweit sicher wiederverwendet werden, was die Effizienz steigert und die Kosten pro Anwendungsfall senkt.

2.4 Die Schweizer Compliance-Hürde und Datensouveränität

2.4.1 Geschäftlicher Nutzen

Spezifisch für Schweizer Organisationen ist die strenge Auslegung von Datenschutz und Datensouveränität. Unternehmen in regulierten Branchen oder der öffentlichen Verwaltung dürfen sensible Daten oft nicht an Cloud-Dienste im Ausland übermitteln. Dies führt häufig zu einer Blockadehaltung der IT-Sicherheit: Innovation wird untersagt, weil gängige SaaS-Lösungen die Anforderungen an die Datenresidenz nicht erfüllen. Unternehmen stehen vor dem Dilemma, entweder auf KI zu verzichten oder sich in einer rechtlichen Grauzone zu bewegen. Eine souveräne Lösung bricht diesen Kreislauf und ermöglicht Innovation innerhalb des gesetzlichen Rahmens.

2.4.2 Konzeptioneller Ansatz

Um dieses Dilemma aufzulösen, muss die Architektur eine flexible Datenhaltung ermöglichen, die sich strikt nach der Klassifizierung der Daten richtet. Datensouveränität bedeutet hier, dass der Kunde die physische Kontrolle über Speicherort und Verarbeitung behält. Es muss möglich sein, hochsensible Daten ausschliesslich On-Premise mit lokalen Modellen zu verarbeiten, während weniger kritische Workloads optional über Schweizer Cloud-Infrastrukturen laufen können. Der entscheidende Punkt ist, dass der Kunde die Infrastruktur besitzt und kontrolliert, anstatt nur einen Dienst zu abonnieren.

2.4.3 Technische Umsetzung im Swiss AI Hub

Der Swiss AI Hub adressiert dies durch seine containerbasierte Architektur, die vollständig in der Infrastruktur des Kunden betrieben wird – sei es im eigenen Rechenzentrum oder bei einem Schweizer Cloud-Anbieter. Sensible Unternehmensdaten werden lokal in der Vektordatenbank gespeichert und verarbeitet. Für zusätzliche Sicherheit sorgt die Integration von Presidio zur automatischen Erkennung und Maskierung von Personenidentifizierbaren Informationen (PII), noch bevor ein Prompt an ein Modell gesendet wird. Zudem unterstützt die Plattform den Einsatz von Open-Source-Modellen (wie Mistral oder DeepSeek) via vLLM, sodass eine vollständige Air-Gapped-Installation ohne Internetverbindung realisierbar ist.

2.5 Vertrauen durch Prozess-Stabilität und Transparenz

2.5.1 Geschäftlicher Nutzen

Ein kritisches Hindernis für den produktiven KI-Einsatz ist die mangelnde Vorhersehbarkeit. Generative Modelle neigen zu Halluzinationen oder unerwartetem Verhalten. Für geschäftskritische Prozesse ist ein „Black-Box“-Ansatz, bei dem ein Agent autonom und intransparent entscheidet, nicht akzeptabel. Unternehmen benötigen die Gewissheit, dass automatisierte Entscheidungen nachvollziehbar, prüfbar und erklärbar sind. Erst wenn die KI als verlässlicher Partner wahrgenommen wird, der definierte Leitplanken respektiert, entsteht das notwendige Vertrauen für eine tiefe Integration in die Kernprozesse.

2.5.2 Konzeptioneller Ansatz

Der Lösungsansatz setzt auf deterministische Strukturen statt offener Entscheidungsschleifen. Anstatt Agenten unkontrolliert agieren zu lassen, werden sie in definierte „Closed Workflows“ eingebettet. Ein Agenten-Workflow beschreibt exakt, welche Schritte ausgeführt werden dürfen und welche Datenquellen konsultiert werden müssen. Dies garantiert, dass die KI nicht vom definierten Pfad abweicht. Dieses Prinzip wird durch eine umfassende Transparenz ergänzt: Jede Aktion und jede herangezogene Quelle muss für den Benutzer und für Auditoren jederzeit sichtbar sein.

2.5.3 Technische Umsetzung im Swiss AI Hub

In der Plattform werden diese Konzepte durch strikte Agenten-Baupläne und konfigurierbare Agenten-Profile umgesetzt. Jeder Schritt eines Workflows ist als Event im System sichtbar und über das Phoenix-Tracing bis zum ursprünglichen Dokumenten-Snippet rückverfolgbar. Die Plattform erzwingt Typensicherheit und validierte Ausgabeformate, um sicherzustellen, dass nachgelagerte Systeme verlässliche Daten erhalten. Durch den integrierten AgentTestRunner im SDK kann das Verhalten von Agenten vor dem Deployment systematisch geprüft werden, was die Qualitätssicherung im KI-Lifecycle professionalisiert.

3 Plattform-Überblick – Die Swiss AI-Hub-Lösung

Der Swiss AI Hub definiert sich grundlegend anders als herkömmliche Angebote am Markt. Er ist weder ein reines Software-Framework, das jahrelange interne Entwicklungsarbeit erfordert, noch ein externer SaaS-Dienst, der die Datenhoheit untergräbt. Vielmehr handelt es sich um eine vollständige Enterprise-KI-Infrastruktur, die als schlüsselfertiges Produkt konzipiert ist. Unternehmen erhalten ein System, das sie selbst besitzen, kontrollieren und innerhalb von 30 Minuten in der eigenen Umgebung in Betrieb nehmen können. Dieser Ansatz schliesst die Lücke zwischen schnellen Prototypen und einem skalierbaren, sicheren Produktionsbetrieb, indem er die komplexen Infrastrukturfragen bereits im Kern löst.

3.1 Auf einen Blick

- **Infrastruktur als Produkt:** Eine "Batteries-Included"-Plattform, die alle notwendigen Komponenten wie LLM-Gateway, Datenbanken und Monitoring vorkonfiguriert mitbringt.
- **Skalierbares Stufenmodell:** Ein strukturierter Pfad ermöglicht den organischen Übergang von sicherem KI-Zugang über kontextbezogenes Wissen (RAG) bis zur Prozessautomatisierung.
- **Plattform-SDK-Synergie:** Die strikte Trennung erlaubt es Entwicklern, sich auf die Geschäftslogik zu konzentrieren, während die Plattform Sicherheit und Betrieb übernimmt.
- **Lösung des "Day 2"-Problems:** Kritische Betriebsaufgaben wie Kostenkontrolle, PII-Anonymisierung und Audit-Trails sind bereits im Standard implementiert.
- **Strategische Unabhängigkeit:** Dank Apache 2.0 Lizenz und modell-agnostischer Architektur wird ein Vendor-Lock-in effektiv ausgeschlossen.

3.2 Enterprise-Infrastruktur "Out-of-the-Box"

3.2.1 Geschäftlicher Nutzen

Für Unternehmen stellt die Zusammenstellung eines KI-Stacks oft eine unüberwindbare Einstiegshürde dar. Die Evaluierung und Integration von Vektordatenbanken, API-Gateways und Monitoring-Tools bindet IT-Ressourcen über Monate. Der Swiss AI Hub eliminiert diese "Integrationssteuer". Da die Plattform alle notwendigen Komponenten für den Betrieb bereits integriert hat, reduziert sich die Zeit bis zur Produktivsetzung drastisch. Dies ermöglicht es Organisationen, sich sofort auf wertschöpfende Use Cases zu konzentrieren, anstatt Infrastruktur-Puzzles zu lösen. Zudem entfallen versteckte Kosten und Lizenzgebühren für separate Drittanbieter-Komponenten.

3.2.2 Konzeptioneller Ansatz

Das Prinzip lautet "Infrastructure as Product". Die Plattform wird nicht als loser Baukasten geliefert, sondern als harmonisiertes Gesamtsystem, das wie ein "KI-Betriebssystem" fungiert. Es trennt strikt zwischen der stabilen Plattform-Ebene und der flexiblen Anwendungs-Ebene (SDK). Während das SDK Entwickeln erlaubt, massgeschneiderte Agenten-Baupläne zu entwerfen, übernimmt die Plattform automatisch die Schwerarbeit: Authentifizierung, Datenpersistenz, Skalierung und Sicherheit. Ein Agent erbt seine Fähigkeiten zur Zugriffskontrolle und Überwachung automatisch durch den Betrieb auf dem Hub.

3.2.3 Technische Umsetzung im Swiss AI Hub

Technisch manifestiert sich dieser Ansatz in einer containerisierten Architektur, die via Docker Compose oder Kubernetes orchestriert wird. Der Stack integriert Best-in-Class Komponenten: Das LLM-Gateway (LiteLLM) abstrahiert Modell-Provider und verwaltet Failover-Logik. Als Vektordatenbank dient Milvus, während SeaweedFS den S3-kompatiblen Objektspeicher bereitstellt. Die Sicherheit wird durch Presidio zur PII-Erkennung und eine OAuth2-Anbindung an bestehende Identitätsanbieter (z.B. Azure AD) gewährleistet. Für die Observability sammelt OpenTelemetry Metriken, die in Phoenix visualisiert werden.

3.3 Ein Stufenmodell für skalierbare KI-Adoption

3.3.1 Geschäftlicher Nutzen

Die Einführung von KI scheitert oft an einem «Alles-oder-Nichts»-Ansatz. Organisationen versuchen, komplexe Systeme zu bauen, bevor die Grundlagen etabliert sind. Der Swiss AI Hub begegnet diesem Risiko mit einem integrierten Reifegradmodell. Dies erlaubt es Unternehmen, mit geringem Risiko zu starten und die Komplexität schrittweise zu steigern. Mitarbeiter bauen Vertrauen in die Technologie auf, während die Organisation sukzessive Kompetenzen entwickelt. Investitionen wachsen linear mit dem geschäftlichen Mehrwert, nicht exponentiell mit der technischen Komplexität.

3.3.2 Konzeptioneller Ansatz

Die Plattform unterstützt vier logische Evolutionsstufen, die den organisatorischen Reifeprozess begleiten:

1. **Stufe 1 (Sicherer Zugang):** Zentraler, protokollierter Zugang zu LLMs via Web-Interface.
2. **Stufe 1+ (Integration):** KI-Funktionen in gewohnten Umgebungen wie MS Teams oder Slack.
3. **Stufe 2 (Kontext):** Einführung von Wissensdatenbanken (RAG), damit Agenten-Profile auf Unternehmensdaten zugreifen können.
4. **Stufe 3 (Prozesse):** Orchestrierung komplexer Abläufe, in denen KI-Agenten und Menschen zusammenarbeiten.

3.3.3 Technische Umsetzung im Swiss AI Hub

Für **Stufe 1** bietet der Hub die Open-WebUI mit Streaming-Support. **Stufe 1+** nutzt das Azure Bot Framework, um Kanäle wie Teams oder Outlook anzubinden. In **Stufe 2** kommen automatisierte Daten-zu-Wissen-Pipelines zum Einsatz: Dokumente werden mit Docling geparkt und als Vektoren in Milvus abgelegt. **Stufe 3** aktiviert die Prozess-Orchestrierungs-Engine, die Zustände in MongoDB verwaltet und Aufgaben zwischen KI-Agenten und menschlichen Benutzern über eine dedizierte Prozess-UI koordiniert. Integrationen zu Power Automate oder n8n ermöglichen hierbei die Anbindung an Legacy-Systeme.

3.4 Strategische Unabhängigkeit und der «Day 2»-Vorteil

3.4.1 Geschäftlicher Nutzen

Ein zentrales Versprechen des Swiss AI Hub ist der Investitionsschutz durch Vermeidung von Vendor-Lock-in. Proprietäre Plattformen binden Kunden oft durch geschlossene Ökosysteme und unvorhersehbare «Per-User»-Gebühren. Da der Swiss AI Hub unter der Apache 2.0 Lizenz bereitgestellt wird, gehört der Code dem Kunden. Es fallen keine Software-Lizenzgebühren an. Zudem adressiert die Plattform proaktiv die Probleme des «Day 2»: Kostenexplosionen werden durch zentrale Budgets verhindert, Compliance-Risiken durch Audit-Trails minimiert und die Wartbarkeit durch standardisierte Tracing-Tools gesichert.

3.4.2 Konzeptioneller Ansatz

Die Architektur ist radikal $\acute{m}$ odell-agnostisch und $\acute{n}$ provider-unabhangig. Sie abstrahiert die Intelligenz (das LLM) von der Anwendung. Dies ermoglicht es, flexibel zwischen Anbietern wie OpenAI, Google oder lokal gehosteten Modellen (wie Mistral via vLLM) zu wechseln. Das System ist durch offene Protokolle anschlussfahig, etwa durch das Model Context Protocol (MCP), welches externen Entwicklungstools sicheren Zugriff auf Plattform-Ressourcen gewahrt. So bleibt die Organisation technologisch agil und behalt die volle Kostenkontrolle.

3.4.3 Technische Umsetzung im Swiss AI Hub

Diese Freiheit wird durch die konsequente Nutzung offener Standards realisiert. Das LLM-Gateway bietet eine vereinheitlichte Schnittstelle und trackt die Token-Nutzung fur eine prazise Kostenzuordnung pro Team. PII-Daten werden durch Presidio anonymisiert, bevor sie externe Netze erreichen. Dank des SDKs konnen Agenten-Bauplane deterministisch mit dem `AgentTestRunner` gepruft werden, was die Qualitatssicherung professionalisiert. Da der gesamte Stack auf bewahrten Open-Source-Technologien basiert, bleibt das System vollstandig auditierbar und kann bei Bedarf ohne Internetverbindung (Air-Gapped) betrieben werden.

4 Datensouveranitat und vollstandige Kundenkontrolle

Die Einfuhrung von kunstlicher Intelligenz in Schweizer Unternehmen und Behorden scheitert oft nicht an der technischen Machbarkeit, sondern an der grundlegenden Frage der Datenhoheit. Wer kontrolliert die Informationen, wenn sie in Vektoren umgewandelt werden? Wo werden die Prompts verarbeitet? Und wie wird verhindert, dass strategisches Wissen in den undurchsichtigen Trainingsdaten globaler KI-Modelle aufgeht? In einer Zeit, in der Daten als strategisches Kapital gelten, ist die Souveranitat uber diese Ressourcen eine zwingende Voraussetzung fur die digitale Handlungsfahigkeit.

Der Swiss AI Hub adressiert diese Risiken durch ein Architekturdesign, das konsequent auf dem Prinzip der strikten Datensouveranitat basiert. Dieses Kapitel legt dar, wie Organisationen die uneingeschrankte Hoheit uber Speicherort, Zugriffsrechte und Informationsflusse wahren – unabhangig davon, ob die Plattform im eigenen Rechenzentrum, in einer Private Cloud oder als verwaltete Instanz in der Schweiz betrieben wird.

4.1 Auf einen Blick

- **Garantierte Datenresidenz:** Durch flexible Hosting-Modelle wie On-Premise oder Schweizer Private Cloud verbleiben samtliche persistierten Daten physisch im Hoheitsgebiet der Schweiz.
- **Harte Isolation durch Multi-Instancing:** Die Architektur ermoglicht physisch getrennte Instanzen ($\acute{n}$ Shared Nothing), um Datenlecks zwischen verschiedenen Organisationseinheiten technisch auszuschliessen.
- **Strategische Modell-Agnostik:** Das integrierte LLM-Gateway entkoppelt die Anwendung von den Providern und verhindert so einen Vendor-Lock-in bei globalen Hyperscalern.
- **Schutz durch Invisibility:** Ein granulares, hierarchisches Berechtigungssystem blendet nicht autorisierte Funktionen und Agenten-Profilen dynamisch aus, was die Angriffsflache minimiert.

- **Compliance-Automatisierung:** Integrierte Mechanismen für PII-Maskierung und tiefe Observability erfüllen die strengen Anforderungen des revDSG und der DSGVO bereits im Standard.

4.2 Physische Datenhoheit und flexible Infrastruktur

4.2.1 Geschäftlicher Nutzen

Für regulierte Industrien, das Gesundheitswesen und die öffentliche Verwaltung ist der physische Standort der Daten eine nicht verhandelbare Compliance-Vorgabe. Die Nutzung öffentlicher SaaS-Angebote scheidet oft aus, da die Datenhoheit faktisch an den Anbieter abgetreten wird und die Datenflüsse ins Ausland kaum kontrollierbar sind. Organisationen benötigen die Gewissheit, dass sensible Unternehmensdaten den definierten Rechtsraum niemals verlassen. Gleichzeitig darf diese Sicherheit nicht zu Lasten der Agilität gehen; die IT benötigt eine Lösung, die sich nahtlos in bestehende Umgebungen integriert, sei es in einem Hochsicherheits-Rechenzentrum oder einer verwalteten Schweizer Cloud.

4.2.2 Konzeptioneller Ansatz

Der Swiss AI Hub verfolgt den Ansatz *„Bring Your Own Infrastructure“*. Die Plattform wird als containerisierte Software-Lösung bereitgestellt, die vollständig innerhalb der kontrollierten Umgebung des Mandanten operiert. Dabei wird strikt zwischen Multi-Tenancy (logische Trennung innerhalb einer Instanz) und Multi-Instancing (physische Trennung) unterschieden.

Für Szenarien mit extrem hohen Sicherheitsanforderungen, wie etwa der Trennung zwischen einem Versicherungsbetrieb und dessen medizinischem Dienst, kommt das Multi-Instancing zum Tragen. Hierbei erhält jede Einheit eine eigene, autarke Infrastruktur mit dedizierten Datenbanken und Diensten. Ein Datenabfluss ist somit nicht nur durch Software-Logik, sondern durch physische Trennung unterbunden. Ergänzend ermöglicht das Modell des Air-Gapped-Betriebs eine Installation ohne jegliche Internetverbindung, wobei lokale Modelle die externe Kommunikation vollständig ersetzen.

4.2.3 Technische Umsetzung im Swiss AI Hub

Die technische Basis bildet ein Set von Docker-Containern, die eine klare Segmentierung durch eine *„Docker Network Isolation“* in fünf Zonen (Proxy, Backend, Data, Storage, Egress) erzwingen. Dies verhindert, dass ein kompromittierter Dienst direkten Zugriff auf die Datenbanken erhält. Die Datenerhaltung ist lokalisiert: Relationale Unternehmensdaten liegen in PostgreSQL, Vektoreinbettungen für die semantische Suche in Milvus und Dokumente in S3-kompatiblen Speichern wie SeaweedFS.

Sogar bei der Nutzung von Cloud-Modellen bleibt die Souveränität gewahrt, da das LLM-Gateway (LiteLLM) zustandslos arbeitet und keine Prompts oder Antworten persistiert. Für den vollständig autonomen Betrieb können lokale Inferenz-Server wie vLLM oder llama.cpp eingebunden werden, die Open-Source-Modelle direkt auf eigener Hardware ausführen.

4.3 Granulare Zugriffskontrolle und dynamische Sichtbarkeit

4.3.1 Geschäftlicher Nutzen

Datensouveränität bedeutet auch die Kontrolle über interne Informationsflüsse. Ein häufiges Hindernis für den breiten KI-Einsatz ist die Sorge, dass sensible Dokumente durch eine KI-Suche für unberechtigte Mitarbeitende sichtbar werden. C-Level-Verantwortliche benötigen die Garantie, dass das Prinzip der minimalen Rechtevergabe (Least Privilege) konsequent durchgesetzt wird. Es muss sichergestellt werden, dass ein Benutzer nur jene Agenten-Profile und Wissensdatenbanken nutzen kann, die für seine spezifische Rolle freigegeben sind, um interne Datenmissbräuche systematisch zu verhindern.

4.3.2 Konzeptioneller Ansatz

Der Swiss AI Hub implementiert das Modell *“Security by Invisibility”*. Anstatt Benutzern den Zugriff auf nicht autorisierte Funktionen durch Fehlermeldungen zu verweigern, passt sich die Benutzeroberfläche dynamisch an die Berechtigungen an. Dienste, Sammlungen oder Agenten-Profile, für die keine Zugriffsrechte bestehen, sind in der Oberfläche schlichtweg nicht vorhanden.

Dieser Zero-Trust-Ansatz stellt sicher, dass die KI-Agenten unabhängig von den Benutzerberechtigungen agieren. Ein Agent erbt nicht die Rechte des Benutzers, sondern greift auf Daten basierend auf seiner eigenen, administrativ festgelegten Konfiguration zu. Die Kontrolle erfolgt somit auf der Ebene der Agenten-Interaktion: Wer darf mit welchem Agenten sprechen? Dies vereinfacht die Governance drastisch, da nicht Millionen von Dokumentenberechtigungen mit der KI synchronisiert werden müssen.

4.3.3 Technische Umsetzung im Swiss AI Hub

Das Berechtigungssystem basiert auf einer hierarchischen Punkt-Notation im Format `aihub.[user|admin].<service>`. Ein zentraler *“Access Checker”* im Backend validiert jede Anfrage gegen die Rollen des Benutzers und die Grenzen des Mandanten.

Durch die Unterstützung von Wildcards wie `*` (einzelne Ebene) oder `>` (rekursiv) können komplexe Organisationsstrukturen effizient abgebildet werden. Die Authentifizierung erfolgt über standardisierte Protokolle wie OIDC oder OAuth2, was die nahtlose Integration bestehender Identitätssysteme wie Azure AD oder Keycloak ermöglicht. Da die Berechtigungsprüfung im Backend stattfindet, sind Manipulationen an der Benutzeroberfläche wirkungslos; der Benutzer erhält lediglich einen gefilterten Dienstkatalog, der exakt seinem Autorisierungslevel entspricht.

4.4 Modell-Agnostik und proaktiver Datenschutz

4.4.1 Geschäftlicher Nutzen

Die Abhängigkeit von einem einzelnen KI-Anbieter stellt ein erhebliches strategisches Risiko dar. Preisänderungen oder geopolitische Verschiebungen können die Verfügbarkeit kritischer Funktionen gefährden. Zudem ist das unmaskierte Senden von personenbezogenen Informationen (PII) an externe APIs oft ein direkter Verstoß gegen das revDSG. Unternehmen benötigen eine Architektur,

die als Schutzschild fungiert: Sie muss Modell-Provider austauschbar machen und sicherstellen, dass sensible Daten anonymisiert werden, bevor sie das kontrollierte Netzwerk verlassen.

4.4.2 Konzeptioneller Ansatz

Der Swiss AI Hub fungiert als intelligenter Mediator zwischen den Geschäftsanwendungen und den KI-Modellen. Durch die Abstraktion aller Modell-APIs hinter einer einheitlichen, OpenAI-kompatiblen Schnittstelle bleibt die Organisation technologisch agil. Ein Wechsel des Anbieters erfordert keine Änderung am Anwendungscode, sondern lediglich eine Anpassung im zentralen LLM-Gateway.

Zum Schutz der Privatsphäre wird das Konzept der *Anonymisierung* an der Quelle angewandt. Bevor eine Anfrage an einen externen Provider delegiert wird, scannt das System den Inhalt auf sensible Muster. Diese werden entweder maskiert oder die Anfrage wird bei hochsensiblen Datenkategorien komplett blockiert. Dies ermöglicht die Nutzung leistungsfähiger Cloud-Modelle, ohne die Compliance-Richtlinien zu verletzen.

4.4.3 Technische Umsetzung im Swiss AI Hub

Das LLM-Gateway nutzt LiteLLM für das intelligente Routing und die Kostenkontrolle. Integrierte *Guardrails* ermöglichen eine Echtzeit-Validierung von Ein- und Ausgaben. Der PII-Schutz wird durch die Integration von Presidio realisiert, wobei Administratoren zwischen einem Maskierungsmodus (Ersetzung durch Platzhalter wie [PERSON]) und einem Blockierungsmodus (Abweisung der Anfrage) wählen können.

Zusätzlich bietet die Plattform Schutzmechanismen auf Agenten-Ebene, die Antworten filtern, falls diese sensible Informationen aus internen Wissensdatenbanken enthalten könnten. Diese mehrstufige Verteidigung (*Defense-in-Depth*) stellt sicher, dass sowohl Benutzereingaben als auch KI-generierte Antworten stets den Sicherheitsvorgaben entsprechen.

4.5 Langzeit-Verfügbarkeit und Deep Observability

4.5.1 Geschäftlicher Nutzen

Investitionen in KI-Infrastrukturen müssen langfristig gesichert und revisionssicher sein. Entscheidungsträger müssen jederzeit nachweisen können, warum eine KI eine bestimmte Entscheidung getroffen hat, ohne dabei die Hoheit über die Log-Daten an externe Monitoring-Anbieter abzugeben. In regulierten Branchen ist diese Erklärbarkeit keine Option, sondern eine gesetzliche Pflicht. Ein System, das auf offenen Standards basiert, bietet hier die Gewissheit, dass das Unternehmenswissen nicht in proprietären Datensilos gefangen ist und Audits jederzeit erfolgreich bestanden werden können.

4.5.2 Konzeptioneller Ansatz

Die Transparenz der Plattform basiert auf dem Einsatz von OpenTelemetry (OTel), dem Industriestandard für Observability. Dies garantiert, dass sämtliche Telemetriedaten – also Metriken, Logs und Traces – vollständig im Besitz des Kunden bleiben. Die Architektur ermöglicht eine *Deep Observability*, bei der jeder Schritt eines Agenten-Workflows, jeder Datenbankzugriff und jeder

Modellaufruf präzise dokumentiert wird. Compliance wird so von einer manuellen Prüfaufgabe zu einer automatisierten Systemeigenschaft, die auch Anforderungen wie das *Recht auf Vergessenwerden* durch definierte Löszyklen unterstützt.

4.5.3 Technische Umsetzung im Swiss AI Hub

Die Plattform implementiert Distributed Tracing über alle Komponenten hinweg. Dabei werden *OpenInference Semantic Conventions* genutzt, um KI-spezifische Details wie Token-Verbrauch und abgerufene Dokumente sichtbar zu machen. Der *OpenTelemetry Collector* ermöglicht duale Datenströme: Während eine Pipeline detaillierte *Traces* für die Analyse an die lokale *Phoenix*-Instanz liefert, sendet eine zweite Pipeline gefilterte operative Daten an Langzeitspeicher oder bestehende Enterprise-Monitoring-Tools wie *SigNoz* oder *Dynatrace*.

Da alle Daten, einschliesslich der Vektoreinbettungen und Konfigurationen, in offenen Formaten (z. B. PostgreSQL/Milvus) gespeichert werden, ist ein Export oder Systemwechsel jederzeit ohne proprietäre Werkzeuge möglich. Dies eliminiert das Risiko eines *Vendor-Lock-ins* und sichert die strategische Handlungsfähigkeit der Organisation über den gesamten Lebenszyklus der Plattform hinweg.

5 Kapitel 04: Plattform-Transparenz und Prüfbarkeit

Eine der grössten Hürden für den produktiven Einsatz generativer KI in Schweizer Unternehmen ist das Problem der sogenannten *Black-Box*. Wenn ein KI-Modell eine Entscheidung trifft, eine Empfehlung ausspricht oder eine Analyse erstellt, bleibt oft unklar, wie dieses Ergebnis zustande kam. Für regulierte Branchen, die öffentliche Verwaltung und sicherheitsbewusste Organisationen ist dieser Zustand inakzeptabel. Compliance-Vorgaben, interne Revisionsrichtlinien und das revidierte Datenschutzgesetz (revDSG) verlangen eine lückenlose Nachvollziehbarkeit.

Der Swiss AI Hub begegnet dieser Herausforderung mit einem fundamentalen Architekturprinzip: Radikale Transparenz durch einen *White-Box*-Ansatz. Die Plattform wurde so konzipiert, dass technische Abläufe, Datenflüsse und Entscheidungsketten nicht nur ausgeführt, sondern lückenlos dokumentiert und auditierbar gemacht werden. Damit wird das Vertrauen in die Technologie durch technische Beweisbarkeit ersetzt.

5.1 Auf einen Blick

- **Lückenlose Kausalkette:** Durch das Swiss AI Agent Protokoll wird jeder logische Schritt eines Agenten als unveränderliches Ereignis dokumentiert, was Entscheidungen deterministisch nachvollziehbar macht.
- **Beweisbare Datenherkunft:** Das System verknüpft jede KI-Antwort direkt mit den spezifischen Quell-Dokumenten und Text-Chunks in der Wissensdatenbank, um Halluzinationen auditierbar auszuschliessen.
- **Dual-Pipeline Observability:** Eine innovative Architektur trennt tiefes KI-Tracing für Entwickler (*Phoenix*) von operativem Monitoring (*SigNoz*), um sowohl technische Inspektion als auch stabilen Betrieb zu gewährleisten.
- **Menschliche Letztentscheidung:** Integrierte *Human-in-the-Loop*- und *Bot-in-the-Loop*-Muster ermöglichen es, kritische Workflows für menschliche Genehmigungen via Teams oder

Slack zu unterbrechen.

- **Messbare Qualität:** Ein integriertes Evaluations-Framework ersetzt subjektive Eindrücke durch objektive Metriken wie Korrektheit, Vollständigkeit und Prägnanz basierend auf Test-Datasets.

5.2 Nachvollziehbarkeit von KI-Entscheidungen

5.2.1 Geschäftlicher Nutzen

In kritischen Geschäftsprozessen reicht ein korrektes Ergebnis allein nicht aus; der Weg dorthin muss erklärbar sein (ñExplainability). Wenn ein KI-Agent eine medizinische Zusammenfassung erstellt oder einen komplexen Vertrag analysiert, müssen Fachabteilungen und Auditoren verstehen, welche logischen Schritte durchlaufen wurden. Mangelnde Erklärbarkeit stellt ein massives Haftungsrisiko dar. Der Swiss AI Hub eliminiert dieses Risiko, indem er die internen Denkprozesse der KI sichtbar macht. Dies schafft Vertrauen bei den Anwendern und ermöglicht es Compliance-Beauftragten, die Einhaltung von Richtlinien zu verifizieren, ohne sich auf das blossе Wort der KI verlassen zu müssen.

5.2.2 Konzeptioneller Ansatz

Die Plattform verabschiedet sich vom Konzept monolithischer, undurchsichtiger Chatbots und setzt stattdessen auf Workflow-basierte Agenten. Ein Agent folgt keinem Zufallspfad, sondern einem definierten Agenten-Bauplan, der in einzelne, diskrete Schritte unterteilt ist. Jeder dieser Schritte – sei es das Analysieren einer Eingabe, das Suchen von Informationen oder das Re-Ranking von Ergebnissen – erzeugt ein unveränderliches Ereignis. Die Summe dieser Ereignisse bildet einen lückenlosen Pfad, der exakt aufzeigt, was der Agent zu welchem Zeitpunkt getan hat. Durch eine hierarchische Kontext-Struktur lassen sich dabei komplexe Prozesse logisch gruppieren und bis auf die einzelne Ausführung hinunterbrechen.

5.2.3 Technische Umsetzung im Swiss AI Hub

Technisch basiert diese Transparenz auf dem **Swiss AI Agent Protokoll**. Dieses interne Kommunikationsmodell definiert eine strikte Trennung zwischen Steuerungs- und Anzeigeinformationen mittels typisierter Events, die über NATS JetStream publiziert werden. **Control Events** steuern die Geschäftslogik und dokumentieren jeden Zustandsübergang im Backend, während **Display Events** (wie ñGedankenñ des Agenten) der Kommunikation mit dem Benutzer dienen.

Jedes Ereignis ist in einer dreistufigen Hierarchie verankert: Der **Thread-Kontext** hält den langfristigen Status einer Konversation, der **Display-Kontext** gruppiert UI-Interaktionen, und der **Run-Kontext** isoliert die technische Ausführung eines einzelnen Workflow-Durchlaufs. NATS JetStream stellt dabei sicher, dass diese Ereignisse revisionssicher gespeichert werden, wobei Administratoren zeit- oder kapazitätsbasierte Limits für die Aufbewahrung definieren können.

5.3 Revisionssichere Datenherkunft (Data Lineage)

5.3.1 Geschäftlicher Nutzen

Bei der Nutzung von Retrieval-Augmented Generation (RAG) ist die häufigste Frage von Auditoren: „Woher stammt diese Information genau?“. Halluzinationen – das Erfinden von Fakten durch die KI – stellen ein signifikantes Qualitäts- und Reputationsrisiko dar. Unternehmen müssen sicherstellen, dass Antworten ausschliesslich auf validierten Unternehmensdaten basieren. Für rechtliche Prüfungen ist es unerlässlich, beweisen zu können, welche spezifische Version eines Dokuments zu einem bestimmten Zeitpunkt als Grundlage für eine Auskunft diente. Dies ist insbesondere für Auskunftsrechte nach revDSG (Art. 25) von zentraler Bedeutung.

5.3.2 Konzeptioneller Ansatz

Das Konzept der Datenherkunft (Data Lineage) wird im Swiss AI Hub durch eine strikte Referenzierung umgesetzt. Eine generierte Antwort steht niemals für sich allein, sondern ist untrennbar mit den Quellen verknüpft. Das System protokolliert nicht nur, dass gesucht wurde, sondern exakt, welche Text-Chunks (Nodes) gefunden und mit welchem Relevanz-Score sie bewertet wurden. Dies ermöglicht eine Rekonstruktion der Informationsbasis: Auditoren können sehen, welche Wissensschnipsel dem Modell zur Verfügung standen und ob eventuell veraltete Dokumente berücksichtigt wurden.

5.3.3 Technische Umsetzung im Swiss AI Hub

Die technische Implementierung nutzt **OpenInference Semantic Conventions**, um RAG-Operationen standardisiert zu erfassen. Sobald ein Agent die Wissensdatenbank abfragt, wird ein `RetrieverEvent` generiert, das die IDs der abgerufenen Chunks speichert. In der Benutzeroberfläche des Swiss AI Hub wird dies durch ein Quellenanzeigefeld visualisiert, das neben der Antwort die exakten Textpassagen, deren Position im Originaldokument sowie die Metadaten (wie Speicherort und Titel) einblendet. Zusätzlich können **Context Sufficiency Guards** eingesetzt werden, die technisch prüfen, ob die abgerufenen Informationen ausreichen, um die Frage zu beantworten, und den Prozess bei ungenügender Datenlage stoppen.

5.4 Enterprise Observability und Monitoring

5.4.1 Geschäftlicher Nutzen

Eine KI-Plattform darf keine isolierte Insel in der IT-Landschaft sein. Betriebsteams benötigen eine zentrale Sicht auf die Gesundheit aller Systeme, um Ausfälle proaktiv zu verhindern. Proprietäre Monitoring-Tools führen oft zu Datensilos und erschweren die Fehleranalyse. CIOs fordern Lösungen, die sich nahtlos in bestehende SIEM- (Security Information and Event Management) und Monitoring-Landschaften integrieren lassen. Dies sichert die Hoheit über operative Daten und ermöglicht langfristige Trendanalysen ohne Abhängigkeit von einem spezifischen Anbieter.

5.4.2 Konzeptioneller Ansatz

Der Swiss AI Hub verfolgt eine Strategie der maximalen Interoperabilität durch offene Standards wie **OpenTelemetry (OTel)**. OTel fungiert als universelle Sprache für Telemetriedaten und stellt sicher, dass Metriken, Logs und Traces einheitlich erfasst und korreliert werden. Das Konzept sieht vor, dass der Kunde entscheidet, wohin seine Telemetriedaten fließen. Durch einen zentralen Collector werden die Daten gesammelt, gefiltert und an die entsprechenden Analyse-Systeme weitergeleitet.

5.4.3 Technische Umsetzung im Swiss AI Hub

Das Herzstück ist der **OpenTelemetry Collector**, der Telemetrie aus allen Containern, Datenbanken und Agenten-Profilen sammelt und über spezialisierte Pipelines routet. Die Plattform nutzt eine Dual-Backend-Strategie:

1. **KI-Analyse (Phoenix):** Hier fließen hochdetaillierte Traces für das LLM-Debugging ein, inklusive Token-Nutzung, Prompt-Templates und Retrieval-Qualität.
2. **Operations (SigNoz oder externe Systeme):** Hier werden operative Metriken wie CPU-Last, Latenzen und Fehlerraten überwacht.

Dank des OTLP-Protokolls kann der Hub ohne Code-Anpassungen an Enterprise-Tools wie Data-dog, Splunk oder Dynatrace angebunden werden. Administratoren können zudem Alarme für kritische Schwellenwerte, wie etwa steigende Fehlerraten oder das Erreichen von Budgetlimits, konfigurieren.

5.5 Menschliche Kontrolle (Human-in-the-Loop)

5.5.1 Geschäftlicher Nutzen

Trotz fortschrittlicher Modelle gibt es Entscheidungen, die nicht vollständig automatisiert werden dürfen – sei es aus ethischen Gründen oder aufgrund regulatorischer Vorschriften. Ein **Human-in-the-Loop**-Prozess verhindert, dass automatisierte Systeme unkontrolliert agieren, indem er die Effizienz der KI nutzt, aber die Letztentscheidung beim Menschen belässt. Dies ist besonders bei risikoreichen Aktionen wie dem Auslösen von Zahlungen oder dem Versenden von Verträgen essenziell. Jede menschliche Interaktion muss dabei ebenso revisionssicher dokumentiert werden wie die maschinellen Schritte.

5.5.2 Konzeptioneller Ansatz

Das System integriert den Menschen als aktive Komponente in den Workflow. Ein Prozess kann an definierten Punkten pausieren und seinen Zustand **einfröhen**. Erst wenn eine autorisierte menschliche Interaktion erfolgt – etwa eine Freigabe oder eine Korrektur – wird der Prozess fortgesetzt. Ein erweitertes Muster ist der **Bot-in-the-Loop**, bei dem die Eskalation nicht nur in der Plattform-UI, sondern über bestehende Kollaborations-Tools wie Microsoft Teams oder Slack erfolgt. Dies erlaubt es Experten, Anfragen in ihrer gewohnten Arbeitsumgebung zu bearbeiten, während der KI-Agent auf die Antwort wartet.

5.5.3 Technische Umsetzung im Swiss AI Hub

Die Umsetzung erfolgt über asynchrone Ereignismuster im Swiss AI Agent Protokoll. Ein Agent sendet ein `HumanInTheLoopRequestEvent`, woraufhin der Workflow stoppt und der gesamte Kontext in Redis persistiert wird. Der **Expert Asking Agent** kann diese Anfrage übernehmen und sie in einen konfigurierten Teams- oder Slack-Kanal posten. Sobald ein Mensch dort antwortet, erfasst das System dies als `BotInTheLoopResponseEvent`, rehydriert den Agenten und setzt den Workflow fort. Diese Interaktionen werden lückenlos im Audit-Log festgehalten, inklusive der Identität des menschlichen Entscheiders.

5.6 Qualitätssicherung und Evaluation

5.6.1 Geschäftlicher Nutzen

KI-Systeme in der Produktion unterliegen einer ständigen Veränderung – sei es durch neue Dokumente in der Wissensdatenbank oder durch Updates der Sprachmodelle. *ñ*Hoffnung^z ist hier keine Strategie; Unternehmen müssen die Leistung ihrer Agenten objektiv messen können. Regelmässige Evaluationen stellen sicher, dass die Antwortqualität nicht durch *ñ*Model Drift^z abnimmt und dass neue Konfigurationen tatsächlich Verbesserungen bringen. Dies dient als technischer Nachweis der Sorgfaltspflicht gegenüber Regulatoren und Kunden.

5.6.2 Konzeptioneller Ansatz

Qualität wird im Swiss AI Hub durch systematische Experimente gemessen. Dabei werden Agenten-Profile gegen vordefinierte Test-Datasets geprüft, die aus Fragen und erwarteten Referenzantworten bestehen. Anstatt sich auf subjektive Stichproben zu verlassen, nutzt die Plattform den Ansatz *ñ*LLM-as-a-Judge^z: Unabhängige KI-Modelle bewerten die Antworten des zu testenden Agenten anhand wissenschaftlich fundierter Metriken. Dies ermöglicht einen automatisierten, vergleichbaren und auditierbaren Qualitätssicherungsprozess vor jedem Deployment.

5.6.3 Technische Umsetzung im Swiss AI Hub

Der integrierte **Evaluations-Service** erlaubt die Erstellung von Datasets mit 20 bis 50 Testfällen. Bei der Ausführung eines Experiments bewerten drei unabhängige Richter-Modelle die Agenten-Antworten in drei Kategorien auf einer Skala von 0 bis 5 Sternen:

- **Korrektheit:** Faktische Genauigkeit gegenüber der Referenzantwort.
- **Vollständigkeit:** Abdeckung aller Aspekte der Anfrage.
- **Prägnanz:** Effizienz der Antwort ohne unnötige Abschweifungen.

Die Ergebnisse werden in einem Dashboard visualisiert, das Gesamtmetriken sowie eine detaillierte Aufschlüsselung pro Frage zeigt. Dies ermöglicht es Entwicklern, gezielt Wissenslücken oder Schwächen in den Agenten-Bauplänen zu identifizieren und zu beheben, bevor ein Agent produktiv gesetzt wird.

5.7 Finanzielle Transparenz und Kostenkontrolle

5.7.1 Geschäftlicher Nutzen

Die Abrechnungsmodelle grosser Sprachmodelle (Pay-per-Token) bergen erhebliche finanzielle Risiken. Eine fehlerhafte Schleife oder exzessive Nutzung kann Budgets in kürzester Zeit sprengen. CFOs benötigen Echtzeit-Transparenz und harte Limits (‘Circuit Breakers’), um die Kosten pro Abteilung, Projekt oder Benutzer steuern zu können. Dies bildet die Grundlage für eine verursachergerechte interne Leistungsverrechnung (Chargeback) und verhindert unvorhergesehene Kostenexplosionen.

5.7.2 Konzeptioneller Ansatz

Kostenkontrolle ist im Swiss AI Hub direkt in das LLM-Gateway integriert. Jede Interaktion wird vermessen, bewertet und einem Mandanten oder Benutzer zugeordnet. Das System unterscheidet zwischen verschiedenen Kostenarten (Prompt-, Completion- und Embedding-Tokens) und wendet vordefinierte Regeln an. Durch die Definition von Quotas und Ratenbegrenzungen wird sichergestellt, dass die Ressourcennutzung innerhalb der definierten Leitplanken bleibt.

5.7.3 Technische Umsetzung im Swiss AI Hub

Das **LLM-Gateway** agiert als zentraler Wächter und setzt Limits technisch durch Umgebungsvariablen wie `LITE_LLM_PROXY_USER_MAX_BUDGET` durch. Administratoren können sowohl harte Obergrenzen als auch ‘Soft Budgets’ (Warnschwellen) definieren. Zusätzlich können Limits für Tokens pro Minute (TPM) oder Anfragen pro Minute (RPM) gesetzt werden, um Missbrauch oder Amok laufende Skripte sofort zu stoppen. Jeder Aufruf erzeugt zudem ein `LLMCostEvent`, das in Echtzeit-Dashboards einfließt und detaillierte Reports über die Wirtschaftlichkeit der verschiedenen KI-Anwendungsfälle ermöglicht.

6 Kapitel 05: Administration und Governance

Der produktive Einsatz einer Enterprise-KI-Plattform erfordert weit mehr als nur den Zugriff auf leistungsfähige Sprachmodelle. Für Schweizer Unternehmen, die in einem anspruchsvollen regulatorischen Umfeld agieren, sind eine präzise Steuerung, lückenlose Nachvollziehbarkeit und strikte Kostentransparenz die Grundvoraussetzungen für den ‘Day 2’, den stabilen Dauerbetrieb. Ohne eine zentrale Governance-Instanz drohen unkontrollierte Kostenexplosionen, Schatten-IT und Compliance-Verstöße, welche die strategischen Vorteile der künstlichen Intelligenz zunichtemachen.

Dieses Kapitel erläutert, wie der Swiss AI Hub administrative Exzellenz und technische Kontrolle vereint. Durch ein tief in die Architektur integriertes Rollen- und Mandantensystem sowie automatisierte Monitoring-Tools wird sichergestellt, dass die Plattform nicht nur technologisch führend, sondern auch organisatorisch beherrschbar bleibt. Das Ziel ist eine Umgebung, in der Innovation innerhalb klar definierter Leitplanken stattfindet.

6.1 Auf einen Blick

- **Hierarchische Zugriffskontrolle (RBAC):** Ein feingliedriges Berechtigungssystem steuert den Zugriff bis auf die Ebene einzelner Agenten-Instanzen und setzt das Prinzip der minimalen Rechtevergabe (Least Privilege) konsequent um.
- **Mandantenfähigkeit mit Isolationsgarantie:** Die Plattform ermöglicht die logische Trennung von Abteilungen oder Kunden innerhalb einer Instanz, wobei das Agenten-Unabhängigkeitsprinzip für maximale Flexibilität sorgt.
- **Integriertes Kostenmanagement:** Durch das zentrale LLM-Gateway werden Budgets und Ratenlimits (Tokens per Minute) pro Benutzer oder Mandant in Echtzeit erzwungen, was finanzielle Planungssicherheit garantiert.
- **Enterprise Observability:** Basierend auf dem OpenTelemetry-Standard liefert die Plattform tiefe Einblicke in Systemgesundheit und Performance, nahtlos integrierbar in bestehende IT-Monitoring-Landschaften.
- **Automatisierte Compliance-Tools:** Vordefinierte Daten-Lifecycles (30 Tage für ephemere Daten) und Werkzeuge zur Qualitätssicherung unterstützen die Einhaltung von revDSG und DSGVO systematisch.

6.2 Identitätsmanagement und hierarchische Zugriffskontrolle

6.2.1 Mehrwert für die Unternehmenssicherheit

In einer modernen Unternehmensumgebung ist die manuelle Verwaltung von Benutzerrechten über verschiedene KI-Tools hinweg nicht nur ineffizient, sondern ein massives Sicherheitsrisiko. Das Ziel jeder IT-Strategie muss es sein, den Zugriff auf sensible Daten und teure Ressourcen so zu steuern, dass Mitarbeitende exakt die Werkzeuge sehen, die sie für ihre Arbeit benötigen – nicht mehr und nicht weniger. Eine zentrale Identitätsverwaltung reduziert den administrativen Aufwand drastisch, verhindert verwaiste Konten und stellt sicher, dass Sicherheitsrichtlinien wie Multi-Faktor-Authentifizierung (MFA) unternehmensweit durchgesetzt werden.

6.2.2 Föderierte Identität und dynamische Sichtbarkeit

Der Swiss AI Hub setzt auf das Konzept der föderierten Identität. Anstatt eine eigene, isolierte Benutzerdatenbank zu führen, integriert sich die Plattform direkt in die bestehende Identitätsinfrastruktur des Unternehmens. Die Autorisierung erfolgt über eine hierarchische rollenbasierte Zugriffskontrolle (RBAC), die über einfache Ja/Nein-Entscheidungen hinausgeht.

Ein Kernkonzept ist hierbei die dynamische Dienstsichtbarkeit. Die Benutzeroberfläche passt sich in Echtzeit an die Berechtigungen des Nutzers an. Funktionen, Wissenssammlungen oder Agenten-Profile, für die keine Autorisierung vorliegt, werden nicht nur gesperrt, sondern gar nicht erst angezeigt. Diese Security by Invisibility minimiert die Angriffsfläche und erhöht die Benutzerfreundlichkeit, da frustrierende Fehlermeldungen vermieden werden.

6.2.3 Technische Implementierung via RBAC und OIDC

Technisch basiert die Authentifizierung auf den Industriestandards OpenID Connect (OIDC) und OAuth 2.0. Dies ermöglicht die native Anbindung an Provider wie Microsoft Entra ID (ehemals Azure

AD) oder Keycloak. Nach der Anmeldung validiert die Plattform kryptografisch signierte JSON Web Tokens (JWT) und weist den Nutzer einer oder mehreren Rollen zu.

Das Berechtigungssystem nutzt eine präzise Punkt-Notation im Format `aihub.[user|admin].<service>.<resource>`. Administratoren können durch Wildcards (z. B. `aihub.user.agent.hr.*`) Gruppen von Ressourcen effizient verwalten. Ein zentraler `Access Checker` im Backend prüft bei jedem API-Aufruf die Berechtigungen, wodurch clientseitige Manipulationen ausgeschlossen sind. Jede Zugriffsentscheidung wird zudem revisionssicher im Audit-Log protokolliert.

6.3 Mandantenfähigkeit und organisatorische Trennung

6.3.1 Effiziente Abbildung von Konzernstrukturen

Grosse Organisationen bestehen oft aus unabhängigen Geschäftseinheiten, die sich zwar eine Infrastruktur teilen, aber ihre Daten und Prozesse strikt trennen müssen. Ohne eine saubere Mandantenfähigkeit (Multi-Tenancy) entstehen unweigerlich Datensilos oder gefährliche Überschneidungen. Die Herausforderung besteht darin, eine Plattform so zu strukturieren, dass Synergien bei der Wartung genutzt werden können, während die operative und datenschutzrechtliche Trennung zwischen Abteilungen wie `Recht`, `Finanz` oder `HR` gewahrt bleibt.

6.3.2 Logische Isolation und das Agenten-Unabhängigkeitsprinzip

Die Plattform löst diese Anforderung durch die Schaffung logischer Mandanten (Tenants). Jeder Mandant bildet einen isolierten Arbeitsbereich mit eigenen Benutzern, Rollen und Wissensdatenbanken. Ein entscheidendes Merkmal des Swiss AI Hub ist dabei das `Agenten-Unabhängigkeitsprinzip`.

Klassische Systeme lassen Agenten oft die Berechtigungen des Nutzers erben, was deren Einsatz in automatisierten Workflows erschwert. Im Swiss AI Hub agieren Agenten unabhängig von den individuellen Rechten des Nutzers, der mit ihnen interagiert. Der Datenzugriff eines Agenten wird exakt über sein Agenten-Profil definiert. Die Governance erfolgt darüber, welcher Benutzer Zugriff auf welchen Agenten erhält. Dies ermöglicht es beispielsweise, einen `CFO-Agenten` zu bauen, der auf alle Finanzdaten zugreift, aber nur für die Geschäftsleitung sichtbar ist.

6.3.3 Drei-Ebenen-Mandantenmodell in der Praxis

In der praktischen Umsetzung hat sich ein dreistufiges Modell bewährt, das die Plattform standardmässig unterstützt:

1. **Systemadministrator-Ebene (Sysadmin):** Ein dedizierter Mandant für die IT-Infrastruktur-Teams, die Agenten-Baupläne deployen und die Systemgesundheit überwachen.
2. **Management-Ebene:** Mandanten für Business-Administratoren, die innerhalb ihrer Geschäftseinheit Agenten-Profile konfigurieren, Nutzer zuweisen und die Kosten kontrollieren, ohne in den Programmcode einzugreifen.
3. **Endbenutzer-Ebene (Abteilungen/Kunden):** Die operative Ebene, auf der Mitarbeitende mit den für sie freigeschalteten Agenten chatten oder an Prozessen teilnehmen. Diese Struktur trennt technische Operationen sauber von der geschäftlichen Administration und schützt die Integrität der gesamten Systemlandschaft.

6.4 Ressourcensteuerung und Kostenmanagement

6.4.1 Wirtschaftliche Planungssicherheit

Die verbrauchsabhängige Abrechnung moderner KI-Modelle stellt Finanzverantwortliche vor neue Herausforderungen. Ein einziger fehlerhafter Workflow oder eine exzessive Nutzung durch eine Abteilung kann das IT-Budget innerhalb kürzester Zeit belasten. Um KI nachhaltig im Unternehmen zu etablieren, ist ein System erforderlich, das Kosten nicht nur im Nachhinein aufschlüsselt, sondern aktiv begrenzt. Nur durch absolute Transparenz über die Kosten pro Abteilung, Projekt oder Agent kann ein klarer Business Case gerechnet und der Return on Investment (ROI) belegt werden.

6.4.2 Proaktive Limits und Echtzeit-Monitoring

Die Strategie des Swiss AI Hub basiert auf einer Kombination aus Echtzeit-Tracking und harten technischen Sperren (Circuit Breakers). Das System erfasst die Token-Nutzung für jede Interaktion, unterschieden nach Eingabe (Prompt) und Ausgabe (Completion), da diese oft unterschiedlich bepreist werden.

Administratoren haben die Möglichkeit, Budgets auf verschiedenen Ebenen zu definieren: global für die gesamte Plattform oder individuell für einzelne Benutzer und Mandanten. Neben finanziellen Limiten können auch technische Ratenbegrenzungen (Rate Limiting) gesetzt werden. Diese verhindern, dass einzelne Power-User die verfügbare Bandbreite der Modell-Provider monopolisieren und so die Performance für andere Abteilungen beeinträchtigen.

6.4.3 Umsetzung im LLM-Gateway

Die technische Durchsetzung erfolgt zentral im LLM-Gateway (LiteLLM). Da jeglicher Modellverkehr diesen Punkt passieren muss, können Policies hier effektiv angewendet werden. Über Parameter wie `LITE_LLM_PROXY_USER_MAX_BUDGET` wird eine harte Obergrenze definiert. Wird dieses Limit erreicht, blockiert das Gateway weitere Anfragen für den betreffenden Nutzer automatisch.

Zusätzlich können Soft Budgets konfiguriert werden, die bei Erreichen eines Schwellenwertes (z. B. 80 Prozent des Budgets) Warnmeldungen via E-Mail oder Slack auslösen. Für die interne Verrechnung bietet das System detaillierte Exportfunktionen, welche die verursachten Kosten bis auf die Ebene einzelner Agenten-Interaktionen aufschlüsseln, was eine verursachergerechte Kostenallokation ermöglicht.

6.5 Operative Überwachung und Compliance-Management

6.5.1 Stabilität durch tiefe Observability

Für den produktiven Betrieb ist die Sichtbarkeit (Observability) der Systeme entscheidend. Wenn ein Agent eine falsche Antwort liefert oder ein Workflow stockt, muss die IT in der Lage sein, die Ursache sofort zu identifizieren. In regulierten Sektoren ist zudem die Dokumentation der Datenverarbeitung zwingend. Ein Black-Box-Betrieb ist mit Schweizer Compliance-Vorgaben nicht vereinbar. Unternehmen benötigen Werkzeuge, die den gesamten Pfad einer Information von der Quelle bis zur Antwort lückenlos nachvollziehbar machen.

6.5.2 Standardbasierte Telemetrie und Daten-Lifecycles

Die Überwachungsstrategie des Swiss AI Hub basiert auf drei Säulen: Health Checks, Metriken und Distributed Tracing. Um eine nahtlose Integration in bestehende Enterprise-Umgebungen zu ermöglichen, nutzt die Plattform den herstellerneutralen OpenTelemetry-Standard (OTel). Dies verhindert einen Vendor-Lock-in bei Monitoring-Tools und erlaubt die Nutzung vorhandener Dashboards in Splunk, Datadog oder Dynatrace.

Ein weiterer Pfeiler der Governance ist das automatisierte Datenmanagement. Um den Anforderungen der Datensparsamkeit (revDSG/DSGVO) gerecht zu werden, implementiert die Plattform strikte Daten-Lifecycles. Ephemere Daten, die nur für das Debugging oder die kurzfristige Prozesssteuerung nötig sind, werden nach einem definierten Fenster automatisch gelöscht.

6.5.3 Technische Realisierung mit OTel und SigNoz

Die technische Zentrale für alle Telemetriedaten ist der OpenTelemetry Collector. Er empfängt Daten von allen Plattform-Komponenten, filtert Rauschen heraus und leitet sie an die konfigurierten Backends weiter:

- **SigNoz:** Dient als offiziell unterstütztes Backend für die Visualisierung von Logs und System-Metriken (CPU, Speicher, Latenzen). Es bietet leistungsstarke Dashboards und ein flexibles Alarmierungssystem für kritische Dienstaussfälle.
- **Phoenix:** Wird speziell für das KI-Tracing eingesetzt. Hier werden LLM-Aufrufe, Token-Nutzung und die abgerufenen Dokumenten-Snippets visualisiert.
- **Datenaufbewahrung:** In Redis gespeicherte Ausführungsdaten verfallen automatisch nach 30 Tagen. Für permanente Daten in der NoSQL-Datenbank können Organisationen individuelle Löschrichtlinien konfigurieren, um dem «Recht auf Vergessenwerden» technisch Rechnung zu tragen.
- **Qualitätssicherung:** Über den integrierten Evaluierungs-Service können Administratoren Agenten gegen «Golden Record»-Datasets testen. Ein KI-Richter bewertet dabei die Antworten auf Korrektheit und Vollständigkeit, was eine evidenzbasierte Freigabe von Agenten-Updates ermöglicht.

7 Kapitel 06: Datenmanagement, Integration und Ingestion

Die Qualität einer KI-Lösung korreliert direkt mit der Qualität der Daten, auf die sie zugreift. Selbst das leistungsfähigste Sprachmodell liefert unzuverlässige Ergebnisse, wenn es mit veralteten, fragmentierten oder unstrukturierten Informationen gespeist wird. Während die Administration die organisatorischen Rahmenbedingungen schafft, fokussiert sich dieses Kapitel auf den technologischen Maschinenraum: Wie wird unstrukturiertes Unternehmenswissen – von der PDF-Spezifikation bis zum SharePoint-Wiki – effizient, sicher und automatisiert in eine semantisch durchsuchbare Wissensbasis transformiert?

Der Swiss AI Hub implementiert hierfür keine einfachen Upload-Skripte, sondern eine industriell gefertigte Daten-zu-Wissen-Pipeline. Dieser Ansatz garantiert, dass Unternehmensdaten nicht als statischer Datenfriedhof enden, sondern als dynamisches Organisationsgedächtnis zur Verfügung stehen, das mit jeder neuen Information mitwächst und dabei strikte Zugriffsgrenzen respektiert.

7.1 Auf einen Blick

- **Hierarchische Wissensarchitektur:** Die strikte Trennung von Daten in Wissensdatenbanken und Sammlungen verhindert Kontext-Vermischung und ermöglicht präzises Retrieval-Scoping.
- **Strukturelle Verlinkung:** Durch *„Structural Linking“* und die automatische Generierung von Zusammenfassungen (Summary Nodes) verstehen Agenten nicht nur Textfragmente, sondern den gesamten Dokumentkontext.
- **Änderungsgetriebene Automatisierung:** Dank *„Observable Assets“* synchronisiert sich die Plattform automatisch mit Enterprise-Quellen wie SharePoint, was die Aktualität ohne manuellen Aufwand sichert.
- **Institutionelles Gedächtnis:** Das Organisationsgedächtnis erlaubt es, Fakten und Richtlinien zentral zu hinterlegen, sodass alle Agenten auf einer konsistenten, geteilten Faktenbasis operieren.
- **Integrierte Ingestion-Sicherheit:** Jede Datei durchläuft strikte Validierungen (MIME-Type, Malware-Checks) und eine automatisierte Anonymisierung von PII, bevor sie verarbeitet wird.

7.2 Strukturierte Wissensarchitektur und Scoping

7.2.1 Geschäftlicher Nutzen

Ein zentrales Problem vieler KI-Pilotprojekte ist die *„Kontext-Verwässerung“*. Wenn ein KI-Agent Zugriff auf ungefilterte Datenmengen hat, vermischen sich Informationen aus der Lohnbuchhaltung mit IT-Handbüchern oder veralteten Projektnotizen. Dies führt zu ungenauen Antworten und birgt das Risiko, dass sensible Informationen im falschen Kontext auftauchen. Unternehmen benötigen eine Struktur, die Wissen logisch isoliert und sicherstellt, dass ein Agent nur jene Datenpools konsultiert, die für seine spezifische Aufgabe autorisiert wurden. Nur so lässt sich die Genauigkeit erhöhen und das *„Need-to-know“*-Prinzip auf Datenebene technisch durchsetzen.

7.2.2 Konzeptioneller Ansatz

Die Plattform organisiert Wissen in einer dreistufigen Hierarchie: Wissensdatenbanken, Sammlungen (Namespaces) und Dokumente. Wissensdatenbanken fungieren als oberste Isolationsbehälter für ganze Abteilungen oder Sensitivitätsstufen. Innerhalb dieser Datenbanken erlauben Sammlungen eine thematische Gruppierung (z.B. *„Richtlinien“*, *„Handbücher“*, *„Protokolle“*).

Der entscheidende Vorteil liegt im *„Collection-Scoping“*: Ein Administrator weist einem Agenten-Profil nicht pauschal eine Datenbank zu, sondern definiert exakt, welche Sammlungen für das Retrieval herangezogen werden. Die KI durchsucht parallel nur diese autorisierten Bereiche, was die Suchgeschwindigkeit optimiert und Halluzinationen durch irrelevanten Kontext unterbindet.

7.2.3 Technische Umsetzung im Swiss AI Hub

Technisch realisiert der Swiss AI Hub diese Architektur durch eine entkoppelte Speicherschicht. Während die Dokumentenmetadaten in FerretDB verwaltet werden, erfolgt die Vektorspeicherung in Milvus.

- **Wissensdatenbanken:** Jede Datenbank verfügt über eigene Konfigurationen und Berechtigungen.
- **Sammlungen (Namespaces):** Dokumente erhalten bei der Ingestion ein Sammlungs-Label. Da diese Strukturen flach und nicht verschachtelt sind, können Agenten hochperformant über mehrere Sammlungen hinweg suchen, ohne komplexe Verzeichnisbäume traversieren zu müssen.
- **Agenten-Integration:** In der Konfiguration des Agenten-Profiles wird festgelegt, welche Sammlungen durchsucht werden. Das System führt diese Abfragen parallel aus und führt die Ergebnisse basierend auf Relevanz-Scores zusammen.

7.3 Die Daten-zu-Wissen-Pipeline: Präzision durch Struktur

7.3.1 Geschäftlicher Nutzen

Unstrukturierte Dokumente wie komplexe PDFs oder Excel-Tabellen sind für herkömmliche Algorithmen oft unlesbar. Einfaches Text-Parsing zerstört den Zusammenhang; eine Tabellenzeile ohne ihre Kopfzeile verliert jede Bedeutung. Um verlässliche Antworten zu generieren, muss die KI die logische Struktur eines Dokuments verstehen – Überschriften, Listen und Tabellenhierarchien. Unternehmen benötigen eine Pipeline, die Dokumente nicht nur einliest, sondern deren semantische Architektur rekonstruiert, um präzise Quellenangaben und kontextbezogene Antworten zu ermöglichen.

7.3.2 Konzeptioneller Ansatz

Der Swiss AI Hub nutzt eine hochentwickelte Daten-zu-Wissen-Pipeline, die über das einfache Zerlegen von Text (Chunking) hinausgeht. Der Prozess basiert auf *Deep Parsing* und *Structural Linking*. Anstatt ein Dokument stur nach Zeichenlänge zu schneiden, erkennt das System semantische Grenzen wie Kapitelwechsel.

Einzigartig ist die Erstellung eines Wissensgraphen: Jeder Textabschnitt (Chunk) wird sowohl sequentiell (mit seinem Vorgänger/Nachfolger) als auch hierarchisch (mit einer Zusammenfassung des Kapitels) verknüpft. Findet der Agent eine relevante Stelle, kann er über diese Links den Kontext erweitern (*Context Window Expansion*), um die Antwortqualität massiv zu steigern.

7.3.3 Technische Umsetzung im Swiss AI Hub

Die Pipeline orchestriert mehrere spezialisierte Komponenten:

- **Docling:** Dieser Parser extrahiert Text, Tabellen und Strukturen aus PDFs und Office-Dateien unter Beibehaltung des Layouts.
- **Intelligentes Chunking:** Die Pipeline nutzt LlamaIndex, um Dokumente an logischen Grenzen zu teilen.
- **Summary Nodes:** Das System generiert via LLM automatisch hierarchische Zusammenfassungen für Dokumentabschnitte. Diese ermöglichen es dem Agenten, grosse Dokumentenmengen schnell zu überblicken.
- **Vektorisierung:** Text-Chunks werden mittels Embedding-Modellen transformiert und in Milvus gespeichert. Die Daten-Lineage wird dabei lückenlos gewahrt, sodass jede Antwort bis auf das exakte Textfragment im Quelldokument zurückverfolgt werden kann.

7.4 Organisationsgedächtnis und geteilte Fakten

7.4.1 Geschäftlicher Nutzen

In jeder Organisation existieren Fakten, die für alle KI-Agenten und Mitarbeitenden gleichermaßen gelten – etwa Deployment-Zyklen, Spesenreglemente oder IT-Standards. Es ist ineffizient, dieses Wissen redundant in jedem Agenten-Profil zu hinterlegen. Zudem führt dies zu widersprüchlichen Aussagen, wenn Korrekturen nicht überall nachgezogen werden. Ein zentrales Organisationsgedächtnis stellt sicher, dass Korrekturen an einem Fakt sofort allen Agenten zugutekommen. Dies schafft Konsistenz und bewahrt institutionelles Wissen auch bei Mitarbeiterwechseln.

7.4.2 Konzeptioneller Ansatz

Das Organisationsgedächtnis unterscheidet strikt zwischen individuellen Benutzerpräferenzen und objektiven Unternehmensfakten. Während das Benutzergedächtnis personalisiert ist, basiert das Organisationsgedächtnis auf explizit dokumentiertem Wissen. Es fungiert als geteilte Wissensbasis, auf die alle Agenten innerhalb eines Mandanten zugreifen können. Durch die Zuweisung zu Namespaces (z.B. *Engineering*, *HR*) wird sichergestellt, dass Agenten nur relevante Fakten abrufen, was die Präzision erhöht und Informationsüberflutung verhindert.

7.4.3 Technische Umsetzung im Swiss AI Hub

Das Organisationsgedächtnis wird als spezialisierter Service innerhalb der Plattform verwaltet.

- **Explizite Dokumentation:** Fakten werden bewusst erstellt und mit Quellen (z.B. Richtlinien-dokumenten) verknüpft.
- **Semantische Suche & Graphtraversierung:** Agenten rufen Gedächtnisinhalte mittels Vektor-Ähnlichkeit ab und navigieren durch Beziehungen zwischen Konzepten (z.B. *Projekt X* verweist auf *Architektur Y*).
- **Audit-Trail:** Jede Änderung am Organisationsgedächtnis wird protokolliert (wer, wann, was), was die regulatorische Compliance unterstützt.

7.5 Automatisierte Integration und Synchronisation

7.5.1 Geschäftlicher Nutzen

Wissensmanagement scheitert oft an manuellem Aufwand. Sobald Dokumente manuell hochgeladen werden müssen, veralten sie (*Stale Data*). Eine Enterprise-Lösung muss sicherstellen, dass die KI stets auf der *Source of Truth* arbeitet – sei es ein SharePoint-Verzeichnis oder ein S3-Speicher. Automatisierte Konnektoren reduzieren den Pflegeaufwand und garantieren, dass die KI neue Erkenntnisse oder gelöschte Dokumente nahezu in Echtzeit berücksichtigt, ohne dass die IT-Abteilung intervenieren muss.

7.5.2 Konzeptioneller Ansatz

Die Plattform verfolgt eine Strategie der änderungsgetriebenen Automatisierung. Anstatt Ressourcen durch nächtliche Voll-Indizierungen zu verschwenden, überwachen Sensoren die Quellsysteme. Nur geänderte oder neue Dateien lösen die Pipeline aus. Dabei gilt das Prinzip der Dokumenten-Isolation: Fehler bei der Verarbeitung einer einzelnen Datei stoppen niemals die gesamte Pipeline. Datenbanken können entweder im manuellen Modus oder im "Auto-Sync"-Modus betrieben werden, um Eindeutigkeit über die Datenquelle zu wahren.

7.5.3 Technische Umsetzung im Swiss AI Hub

Die Orchestrierung erfolgt durch Dagster, eine Workflow-Engine für Data Engineering.

- **SharePoint-Konnektor:** Synchronisiert Dateien automatisch in den internen S3-Speicher (SeaweedFS).
- **Observable Assets:** Ein Job prüft regelmässig Hashes und Zeitstempel der Quellen. Bei Änderungen löst ein Sensor die Verarbeitung aus.
- **Lebenszyklus-Management:** Wird ein Dokument in der Quelle gelöscht, entfernt die Pipeline automatisch alle zugehörigen Vektoren, Chunks und Zusammenfassungen aus der Wissensdatenbank.

7.6 Validierung und Sicherheit beim Import

7.6.1 Geschäftlicher Nutzen

Der Import externer Dokumente ist ein potenzieller Angriffsvektor. Manipulierte Dateien könnten versuchen, die Plattform-Infrastruktur zu kompromittieren oder die Vektordatenbank mit böswilligen Inhalten zu vergiften. Zudem müssen Personenidentifizierbare Informationen (PII) geschützt werden, bevor sie verarbeitet oder an externe Sprachmodelle gesendet werden. Eine robuste Ingestion-Pipeline muss daher als Sicherheitsfilter fungieren, der Dokumente validiert, säubert und anonymisiert, bevor sie in das System integriert werden.

7.6.2 Konzeptioneller Ansatz

Sicherheit ist integraler Bestandteil des Ingestion-Prozesses ("Secure by Design"). Jede Datei wird als potenziell unsicher betrachtet. Der Prozess umfasst die Prüfung auf Dateitypen (Whitelisting), Malware-Scans und den Schutz vor Path-Traversal-Angriffen. Ein wesentlicher Bestandteil ist die automatische Erkennung und Maskierung von PII. Dies stellt sicher, dass die Plattform auch in Umgebungen mit hohen Datenschutzerfordernissen (revDSG) rechtssicher operiert.

7.6.3 Technische Umsetzung im Swiss AI Hub

Die Plattform implementiert mehrstufige Sicherheitschecks:

- **MIME-Type & Whitelist:** Nur validierte Formate (ca. 40 Enterprise-Typen wie PDF, DOCX, JSON) werden akzeptiert. Die Erweiterung wird gegen den tatsächlichen Dateiinhalt geprüft.

- **Anonymisierung:** Integration von Presidio zur automatischen Maskierung sensibler Datenmuster während des Chunking-Prozesses.
- **Quarantäne & Audit:** Dokumente, die die Validierung nicht bestehen, werden isoliert und im Dagster-Audit-Log protokolliert.
- **Ressourcen-Limits:** Grössenbeschränkungen verhindern Denial-of-Service-Attacken durch manipulierte Grossdateien.

8 Datensicherheit und Datenfluss

In den vorangegangenen Kapiteln wurde dargelegt, wie Daten in die Plattform gelangen und dort verwaltet werden. Sobald Unternehmensdaten jedoch den Sicherheitsperimeter eines KI-Systems betreten, verschieben sich die Anforderungen von reiner Logistik hin zu kompromissloser Sicherheit. In einer Ära, in der Daten das wertvollste Asset darstellen, ist der Schutz vor Diebstahl, Manipulation und unbefugtem Zugriff nicht verhandelbar. Der Übergang zum *íDay 2ž*, dem stabilen Produktivbetrieb, erfordert eine Architektur, die nicht nur Daten speichert, sondern diese aktiv über ihren gesamten Lebenszyklus hinweg verteidigt.

Dieses Kapitel beleuchtet die Sicherheitsarchitektur des Swiss AI Hub, die weit über traditionelle Firewalls hinausgeht. Es beschreibt, wie die Plattform proaktiv gegen KI-spezifische Angriffsvektoren gehärtet wird, sensible Informationen (PII) dynamisch schützt und den gesamten Datenfluss – von der technischen Eingabevalidierung bis zur unwiderruflichen Löschung – absichert.

8.1 Auf einen Blick

- **Defense-in-Depth:** Ein mehrschichtiges Sicherheitsmodell schützt Daten durch strikte Netzwerk-Isolation in fünf Zonen, Container-Härtung und validierte Eingabeprozesse.
- **Aktiver Schutz vor KI-Angriffen:** Spezialisierte *íInput Guardrailsž* und technische Whitelists blockieren Prompt-Injection-Versuche und Schadcode-Uploads auf Protokoll- und Inhaltsebene.
- **Automatisierte PII-Anonymisierung:** Integrierte Erkennungsverfahren via Presidio identifizieren und maskieren Personenidentifizierbare Informationen (PII) dynamisch, bevor diese externe Sprachmodelle erreichen.
- **Verschlüsselung nach Industriestandard:** Durchgängige Verschlüsselung mittels TLS 1.2+ für Datenübertragungen (Data-in-Transit) und LUKS-basierte Volume-Verschlüsselung (Data-at-Rest) sichern die Vertraulichkeit.
- **Automatisierter Daten-Lebenszyklus:** Ephemere Daten werden nach festen Fristen von 30 Tagen automatisch gelöscht, um das *íRecht auf Vergessenwerdenž* technisch und ohne manuellen Aufwand zu erzwingen.

8.2 Schutz vor KI-spezifischen Bedrohungen und Systemhärtung

8.2.1 Geschäftlicher Nutzen

Die Integration generativer KI eröffnet Unternehmen nicht nur neue Möglichkeiten, sondern exponiert sie auch gegenüber neuartigen Bedrohungen. Angriffe wie *íPrompt Injectionž*, bei denen bösartige Akteure versuchen, die Sicherheitsrichtlinien eines Modells durch manipulative Eingaben zu umgehen, oder das Einschleusen von Schadcode über Datei-Uploads stellen reale Risiken dar.

Ein erfolgreicher Angriff könnte zur Exfiltration vertraulicher Daten oder zur Reputationsschädigung durch manipulierte Antworten führen. Sicherheitsverantwortliche benötigen daher eine Verteidigungslinie, die spezifisch auf die Natur von LLM-Interaktionen zugeschnitten ist und Angriffe abwehrt, bevor sie die Kernsysteme erreichen.

8.2.2 Konzeptioneller Ansatz

Der Swiss AI Hub verfolgt eine „Defense-in-Depth“-Strategie. Sicherheit wird nicht als einzelne Schale um die Anwendung gelegt, sondern in jeder Verarbeitungsphase durchgesetzt. Das Konzept unterscheidet zwischen klassischer Eingabevalidierung, Container-Sicherheit und semantischen Schutzmechanismen (Guards). Während die Validierung sicherstellt, dass Dateiformate und Protokolle den Spezifikationen entsprechen, analysieren semantische Wächter den Inhalt der Kommunikation. Dies gilt sowohl für eingehende Daten (Input Guards) als auch für ausgehende Antworten der KI (Output Guards), um zu verhindern, dass Modelle halluzinieren oder schädliche Inhalte generieren.

8.2.3 Technische Umsetzung im Swiss AI Hub

Auf technischer Ebene implementiert die Plattform rigide Filtermechanismen für jeden Daten-In- und Egress. Bei Datei-Uploads greift eine strikte Whitelist, die etwa 40 genehmigte Dateierweiterungen wie PDF, DOCX oder JSON zulässt. Das System validiert dabei nicht nur die Endung, sondern prüft den tatsächlichen MIME-Typ des Inhalts, um „Extension Spoofing“ – das Tarnen einer ausführbaren Datei als harmloses Dokument – sowie Path-Traversal-Versuche und Null-Byte-Injections zu unterbinden.

Für den Schutz der Interaktionsebene kommen spezialisierte Guardrails zum Einsatz. Eingangsschutzmechanismen analysieren den Benutzer-Prompt, bevor er an das Agenten-Profil übergeben wird. Sie blockieren themenfremde Anfragen mittels eines Agentenbeschreibungs-Schutzmechanismus. Auf Infrastrukturebene wird die Angriffsfläche durch gehärtete Container minimiert. Dienste laufen standardmässig als nicht privilegierter Benutzer (UID 1000), was die Auswirkungen potenzieller Container-Ausbrüche massiv reduziert. Die Erstellung der Container erfolgt über Multi-Stage-Builds, sodass Build-Werkzeuge nicht im finalen Produktions-Image enthalten sind. Als Basis dienen minimale Slim-Images, die regelmässig neu gebaut werden, um aktuelle Sicherheitspatches zu integrieren.

8.3 Automatisierte Anonymisierung und PII-Schutz

8.3.1 Geschäftlicher Nutzen

Der grösste Hemmschuh für die Nutzung von KI-Modellen in der Cloud ist der Datenschutz. Das unbedachte Senden von Personenidentifizierbaren Informationen (PII) wie Namen, AHV-Nummern oder Kreditkartendaten an externe Anbieter stellt oft einen Verstoß gegen interne Compliance-Vorgaben, das Schweizer Datenschutzgesetz (revDSG) oder die DSGVO dar. Unternehmen stehen vor dem Dilemma, entweder auf leistungsfähige externe Modelle zu verzichten oder rechtliche Risiken einzugehen. Der Swiss AI Hub löst diesen Konflikt durch eine intelligente Zwischenschicht, die als automatischer Filter fungiert und sicherstellt, dass sensible Informationen den internen Sicherheitsperimeter niemals ungeschützt verlassen.

8.3.2 Konzeptioneller Ansatz

Das Prinzip lautet "Sanitization at the Gateway". Bevor eine Anfrage das kontrollierte Netzwerk der Plattform verlässt, muss sie bereinigt werden. Das System ist in der Lage, PII im laufenden Datenstrom zu erkennen und kontextabhängig zu entscheiden, ob diese Informationen maskiert oder die gesamte Anfrage blockiert werden soll. Dieser Schutz erfolgt zentral im LLM-Gateway, damit er für alle angeschlossenen Agenten-Profilen gleichermassen wirksam ist, ohne dass für jedes Projekt eigene Filterlogiken implementiert werden müssen. Ergänzend dazu schützen Ausgangs-Filter den Benutzer vor der Anzeige sensibler Daten, die eventuell aus internen Wissensdatenbanken abgerufen wurden.

8.3.3 Technische Umsetzung im Swiss AI Hub

Zentraler Baustein für diese Funktion ist die Integration von Presidio in das LLM-Gateway. Presidio analysiert jeden Prompt mittels Mustererkennung und Named Entity Recognition (NER) auf PII in mehreren Sprachen, einschliesslich Deutsch, Französisch und Italienisch. Das System bietet zwei primäre Betriebsmodi:

Im Maskierungsmodus werden erkannte Entitäten durch Platzhalter ersetzt, wodurch beispielsweise ein Name zu [PERSON] wird. Das externe Modell erhält den Kontext, aber keine echten Daten. Im Blockierungsmodus wird die Anfrage bei hochsensiblen Datenkategorien wie Kreditkartennummern komplett abgelehnt. Zusätzlich prüfen "Ausgangs-Schutzmechanismen" auf Agenten-Ebene die generierten Antworten. Ein Schutzmechanismus für sensible Informationen redigiert PII, die aus internen Dokumenten im RAG-Kontext stammen könnten, vor der Anzeige im Chatfenster zu [REDACTED].

8.4 Verschlüsselungsarchitektur und Netzwerk-Isolation

8.4.1 Geschäftlicher Nutzen

Daten sind sowohl im Ruhezustand als auch während der Übertragung potenziellen Angriffen ausgesetzt. Ein physischer Diebstahl von Festplatten oder das Abhören von Netzwerkverkehr im Firmennetzwerk darf nicht zur Kompromittierung von Geschäftsgeheimnissen führen. Für Auditoren und Compliance-Abteilungen ist der Nachweis einer durchgängigen Verschlüsselungskette und einer strikten Segmentierung der Netzwerke essenziell, um die Vertraulichkeit und Integrität der verarbeiteten Informationen zu attestieren. Eine klare Trennung der Netzwerke begrenzt zudem den Schadensradius im Falle einer Kompromittierung einzelner Komponenten.

8.4.2 Konzeptioneller Ansatz

Die Sicherheitsarchitektur basiert auf Isolation und Kryptografie nach Industriestandards. Netzwerkseitig gilt das Prinzip der minimalen Exposition: Nur zwingend notwendige Schnittstellen sind nach aussen sichtbar, während alle internen Dienste in einem privaten Netzwerk kommunizieren. Die Plattform segmentiert den Verkehr in fünf isolierte Zonen für Proxy, Backend, Daten, Storage und Egress. Kryptografisch setzt der Swiss AI Hub auf bewährte Protokolle wie TLS für die Übertragung und Konzepte zur Vollverschlüsselung der Speichermedien, um den Zugriff auf physischer Ebene zu verunmöglichen.

8.4.3 Technische Umsetzung im Swiss AI Hub

Das Netzwerkdesign implementiert eine strikte Trennung mittels isolierter Docker-Netzwerke. Der Traefik Reverse Proxy ist die einzige Komponente, die über die Ports 80 und 443 erreichbar ist. Er terminiert TLS-Verbindungen (erzwingt TLS 1.2+), verwaltet Zertifikate via Let's Encrypt und leitet den Verkehr an die internen Dienste weiter. Backend-Komponenten wie Datenbanken oder das LLM-Gateway sind niemals direkt dem öffentlichen Internet ausgesetzt. Ein spezielles Egress-Netzwerk ermöglicht ausgehende Verbindungen zu LLM-Providern, wobei die Inter-Container-Kommunikation (ICC) deaktiviert ist, um seitliche Bewegungen von Angreifern zu verhindern.

Für die Datensicherheit gelten folgende kryptografische Massnahmen:

- **Data-in-Transit:** Die gesamte Kommunikation ist TLS-verschlüsselt. Sicherheits-Header wie HSTS und X-Content-Type-Options werden durch Traefik erzwungen. Auch WebSocket-Verbindungen nutzen das sichere WSS-Protokoll mit Origin-Validierung.
- **Data-at-Rest:** Persistente Daten werden auf Docker-Volumes gespeichert, die mittels LUKS (Linux Unified Key Setup) mit AES-256 verschlüsselt sind. Dies schützt Anwendungsdatenbanken, Vektordatenbank-Indizes und Dokumentenspeicher vor physischem Zugriff.

8.5 Daten-Lebenszyklus und Revisionssichere Löschung

8.5.1 Geschäftlicher Nutzen

Datenschutzgesetze fordern nicht nur den Schutz von Daten, sondern auch deren Begrenzung und rechtzeitige Löschung. Unternehmen dürfen Daten nicht unbegrenzt horten, da dies rechtliche Altlasten erzeugt und die Speicherkosten erhöht. Ein KI-System muss in der Lage sein, auf Anfragen von Betroffenen (Data Subject Access Requests) zu reagieren und das *Recht auf Vergessenwerden* technisch umzusetzen. Ein automatisierter Daten-Lebenszyklus reduziert die Compliance-Risiken und stellt sicher, dass nur Informationen aufbewahrt werden, die für den Betrieb oder gesetzliche Nachweispflichten zwingend erforderlich sind.

8.5.2 Konzeptioneller Ansatz

Der Swiss AI Hub unterscheidet konzeptionell zwischen ephemeren (flüchtigen) und permanenten Daten. Flüchtige Daten, die für den unmittelbaren Betrieb oder das Caching notwendig sind, besitzen ein automatisches Verfallsdatum. Permanente Daten wie Wissensdatenbanken oder Audit-Logs unterliegen definierten Aufbewahrungsrichtlinien. Dieser Ansatz stellt sicher, dass das System sich selbst bereinigt. Zudem stehen Mechanismen bereit, um Daten auf explizite Anforderung gezielt und nachweisbar zu löschen, ohne die Integrität der Audit-Trails für Sicherheitsanalysen zu gefährden.

8.5.3 Technische Umsetzung im Swiss AI Hub

Die Plattform setzt diese Anforderungen durch technische Automatismen um. Hochgeschwindigkeits-Daten im Arbeitsspeicher (Redis) wie Konversations-Caches unterliegen einer automatischen Ablauffrist (TTL) von 30 Tagen. Nach Ablauf dieses Fensters werden die Daten ohne manuelles Zutun gelöscht. Workflow-Ereignisse werden via NATS JetStream verwaltet, wobei doppelte Limits greifen:

Daten werden entweder nach 30 Tagen oder beim Erreichen einer Kapazitätsgrenze von 10 Millionen Nachrichten rotiert.

Die Plattform unterstützt Administratoren zudem bei der Erfüllung von Betroffenenrechten. Über APIs können Benutzerprofile, spezifische Konversationsstränge oder Konto-Daten permanent entfernt werden. Während Inhalte gelöscht werden, bleiben strukturelle Audit-Logs unveränderlich erhalten, um die Nachweisbarkeit von Aktionen gegenüber Revisoren sicherzustellen.

8.6 Sicherheits-Monitoring und Anomalieerkennung

8.6.1 Geschäftlicher Nutzen

Sicherheit ist kein statischer Zustand, sondern ein kontinuierlicher Prozess. Um auf Vorfälle reagieren zu können, benötigen IT-Teams Echtzeit-Transparenz. Es muss jederzeit beantwortet werden können, wer auf welche Ressourcen zugegriffen hat und ob Unregelmässigkeiten im Datenverkehr vorliegen. Eine lückenlose Protokollierung von Sicherheitsereignissen ist Voraussetzung für Zertifizierungen und ermöglicht eine schnelle Reaktion auf potenzielle Bedrohungen. Durch proaktives Monitoring können Angriffsversuche wie Brute-Force oder exzessive Datenexporte erkannt werden, bevor ein Schaden entsteht.

8.6.2 Konzeptioneller Ansatz

Der Ansatz basiert auf vollständiger Observability mittels offener Standards. Sämtliche Authentifizierungs- und Autorisierungsereignisse werden strukturiert erfasst. Das System nutzt OpenTelemetry, um Sicherheits-Logs mit Metadaten anzureichern und zentral bereitzustellen. Dies ermöglicht die Korrelation von Ereignissen über verteilte Systemkomponenten hinweg. Das Monitoring umfasst dabei nicht nur die technische Verfügbarkeit, sondern auch die Sicherheitsebene, einschliesslich der Überwachung von API-Schlüssel-Nutzung und Budgetüberschreitungen im LLM-Gateway.

8.6.3 Technische Umsetzung im Swiss AI Hub

Sämtliche sicherheitsrelevanten Aktionen werden protokolliert. Die Zugriffs-Logs erfassen jeden Login-Versuch und jede Berechtigungsprüfung im Rahmen der rollenbasierten Zugriffskontrolle (RBAC). Jede Anfrage an die API wird mit Benutzeridentität und der Autorisierungsentscheidung gespeichert. Sicherheitsteams können über Dashboards in SigNoz Authentifizierungsmuster überwachen und auf Anomalien reagieren. Die Plattform unterstützt den Export dieser Logs an externe SIEM-Systeme. Zusätzlich überwacht das LLM-Gateway die Kosten und Token-Nutzung in Echtzeit, wobei automatische Budget-Sperren (Circuit Breakers) greifen, sobald vordefinierte Schwellenwerte erreicht werden, was einen wirksamen Schutz vor finanziellem Missbrauch bietet.

9 Sicherheitsarchitektur

In der Ära von Enterprise-KI ist Sicherheit kein nachgelagertes Merkmal, sondern das fundamentale Fundament jeder vertrauenswürdigen Architektur. Ein System, das tiefgreifende Einblicke in geschäftskritisches Unternehmenswissen gewährt, muss nach den strengsten Standards gehärtet

sein. Der Swiss AI Hub verfolgt hierbei eine ganzheitliche Strategie, welche die Sicherheit in jede Schicht der Plattform integriert – von der physischen Isolation über den Netzwerkverkehr bis hin zur semantischen Filterung von KI-Inhalten.

Dieses Kapitel detailliert die Sicherheitsarchitektur, die konsequent dem Prinzip der *„Defense-in-Depth“* (Verteidigung in der Tiefe) folgt. Es beschreibt, wie Identitäten föderiert, Daten kryptografisch geschützt und Angriffsvektoren proaktiv neutralisiert werden, um die Vertraulichkeit, Integrität und Verfügbarkeit aller Informationen dauerhaft zu gewährleisten.

9.1 Auf einen Blick

- **Defense-in-Depth Architektur:** Ein mehrschichtiges Sicherheitsmodell kombiniert strikte Netzwerkisolation in fünf Zonen mit gehärteten Container-Umgebungen.
- **Unternehmenstaugliche Identitätsföderation:** Native Integration von Microsoft Entra ID via OIDC und OAuth 2.0 inklusive PKCE für höchste Authentifizierungsstandards.
- **Lückenlose Datenverschlüsselung:** Erzwingung von TLS 1.2+ für den Datentransfer sowie LUKS-basierte Verschlüsselung für ruhende Daten (*„Data-at-Rest“*).
- **KI-spezifische Schutzmechanismen:** Plattformweiter PII-Schutz mittels Presidio sowie granulare Eingangs- und Ausgangsfilter (Guards) auf Agenten-Ebene.
- **Automatisierte Validierung:** Strenge technische Filter blockieren Path-Traversal, Malware-Uploads und Prompt-Injections bereits am Netzwerkrand.

9.2 Mehrschichtige Abwehr und Netzwerk-Isolation

9.2.1 Geschäftlicher Nutzen

Die Bedrohungslandschaft für moderne IT-Infrastrukturen ist hochdynamisch und erfordert Schutzmassnahmen, die über eine klassische Perimeter-Firewall hinausgehen. Unternehmen benötigen eine Architektur, die auch bei der Kompromittierung einzelner Komponenten widerstandsfähig bleibt und den Schadensradius (*„Blast Radius“*) effektiv begrenzt. Für Entscheidungsträger bedeutet dies die Sicherstellung der Business Continuity sowie den Schutz vor lateralen Bewegungen von Angreifern innerhalb des Netzwerks. Eine robuste Isolation schützt zudem die Reputation, indem sie sicherstellt, dass sensible Backend-Systeme niemals direkt dem öffentlichen Internet ausgesetzt sind.

9.2.2 Konzeptioneller Ansatz

Der Swiss AI Hub implementiert eine strikte Segmentierung auf Netzwerk- und Prozessebene. Das Konzept basiert auf der Annahme, dass kein Dienst implizit vertrauenswürdig ist (Zero-Trust). Statt einer flachen Netzwerkstruktur werden Dienste in logische Sicherheitszonen unterteilt. Die Kommunikation zwischen diesen Zonen ist streng reglementiert und folgt dem Prinzip der minimalen Rechtevergabe. Ergänzt wird dies durch eine *„Immutable Infrastructure“*-Strategie: Container werden bei jedem Update vollständig ersetzt statt gepatcht, was eine konsistente und geprüfte Sicherheitskonfiguration über alle Umgebungen hinweg garantiert.

9.2.3 Technische Umsetzung im Swiss AI Hub

Die technische Realisierung basiert auf einer Isolation mittels fünf dedizierter Docker-Netzwerke:

- **Zoneneinteilung:** Die Netzwerke umfassen *ñProxyz* (externer Traffic via Traefik), *ñBack-endz* (Anwendungsdienste), *ñDataz* (Datenbanken), *ñStoragez* (Dateisysteme) und *ñEgressz* (reiner ausgehender Internetverkehr).
- **Single Entry Point:** Traefik fungiert als einziger Ingress-Controller. Nur die Ports 80 und 443 sind nach aussen geöffnet. Alle Backend-Dienste wie das LLM-Gateway oder die Vektordatenbank bleiben für das Internet unsichtbar.
- **Egress-Härtung:** Das ausgehende Netzwerk für Dienste wie Web-Scraper ist so konfiguriert, dass die Inter-Container-Kommunikation (ICC) deaktiviert ist. Dies verhindert, dass ein kompromittierter Scraper andere interne Dienste angreifen kann.
- **Container-Sicherheit:** Alle Prozesse werden als Nicht-Root-Benutzer (UID/GID 1000) ausgeführt. Die Verwendung minimaler *ñSlim-Imagesz* und Multi-Stage-Builds reduziert die Angriffsfläche, da unnötige Systemwerkzeuge und Compiler aus den Produktionsumgebungen entfernt werden.

9.3 Identitätsmanagement und Zugriffskontrolle

9.3.1 Geschäftlicher Nutzen

In einer Enterprise-Umgebung ist die fragmentierte Verwaltung von Benutzerzugängen ein erhebliches Sicherheits- und Effizienzrisiko. Mitarbeitende fordern einen nahtlosen Zugriff via Single Sign-On (SSO), während die IT-Administration eine zentrale Kontrolle über Berechtigungen und den sofortigen Entzug von Zugriffen bei Austritten sicherstellen muss. Eine moderne Identitätsstrategie eliminiert die Gefahr schwacher Passwörter durch die Durchsetzung von Multi-Faktor-Authentifizierung (MFA) und stellt sicher, dass jede Aktion innerhalb der Plattform einer eindeutigen Identität zugeordnet werden kann.

9.3.2 Konzeptioneller Ansatz

Der Swiss AI Hub nutzt föderierte Identitäten, um die Authentifizierung an bewährte Enterprise Identity Provider (IDP) zu delegieren. Die Plattform selbst speichert keine Passwörter, sondern vertraut kryptografisch signierten Tokens. Die Autorisierung ist strikt von der Authentifizierung getrennt: Während der IDP bestätigt, wer ein Benutzer ist, bestimmt die Plattform basierend auf einem hierarchischen Rollensystem, was dieser Benutzer tun darf. Dies ermöglicht eine feingranulare Steuerung, bei welcher der Zugriff auf Agenten-Profile und Wissensdatenbanken exakt auf die organisatorische Rolle zugeschnitten ist.

9.3.3 Technische Umsetzung im Swiss AI Hub

Die Umsetzung erfolgt konsequent über offene Industriestandards:

- **Protokolle:** Die Plattform implementiert OpenID Connect (OIDC) und OAuth 2.0. Für interaktive Anmeldungen wird der Authorization Code Flow mit PKCE (Proof Key for Code Exchange) verwendet, um Abfangversuche von Codes zu verhindern.

- **Integration:** Microsoft Entra ID (Azure AD) wird nativ unterstützt. Die Plattform ruft via Microsoft Graph API Profilinformationen und Gruppenmitgliedschaften ab, die automatisch auf interne Rollen wie die *WissensVerwalter-Rolle* gemappt werden.
- **Token-Validierung:** Jeder API-Aufruf erfordert einen gültigen JSON Web Token (JWT). Die Validierung erfolgt gegen die öffentlichen Schlüssel (JWKS) des Identity Providers, wobei Signatur, Aussteller, Zielgruppe und Ablaufzeit geprüft werden.
- **Audit-Protokollierung:** Alle Authentifizierungs- und Autorisierungsereignisse werden als strukturierte OpenTelemetry-Events erfasst. Dies schafft einen lückenlosen Audit-Trail für Compliance-Prüfungen und ermöglicht die Echtzeit-Überwachung von Anomalien.

9.4 Kryptografische Absicherung und Datenintegrität

9.4.1 Geschäftlicher Nutzen

Der Schutz der Vertraulichkeit von Unternehmensdaten ist im Kontext des Schweizer Datenschutzgesetzes (revDSG) eine gesetzliche Pflicht. Datenverluste durch das Abhören von Netzwerkleitungen oder den physischen Diebstahl von Speichermedien können existenzbedrohende finanzielle Folgen und Reputationsschäden nach sich ziehen. Eine durchgängige Verschlüsselung stellt sicher, dass Informationen für unbefugte Dritte wertlos bleiben, selbst wenn physische oder netzwerkbasierende Barrieren überwunden werden. Dies ist die Voraussetzung für das Vertrauen von Kunden und Partnern in die digitale Integrität des Unternehmens.

9.4.2 Konzeptioneller Ansatz

Die Sicherheitsstrategie erzwingt Verschlüsselung in allen Zuständen. Während der Übertragung (ñData-in-Transit) wird eine Punkt-zu-Punkt-Verschlüsselung zwischen Client, Plattform und externen Modellanbietern sichergestellt. Für ruhende Daten (ñData-at-Rest) sieht das Architekturkonzept eine vollständige Abstraktion der Speicherschicht vor. Die Schlüsselverwaltung erfolgt unabhängig von den Datenbeständen, was eine regelmässige Schlüsselrotation ohne Beeinträchtigung der Datenverfügbarkeit ermöglicht.

9.4.3 Technische Umsetzung im Swiss AI Hub

- **Verschlüsselung im Transit:** Trafik erzwingt TLS 1.2 oder TLS 1.3 für alle Verbindungen. Veraltete Chiffren werden abgelehnt. HSTS (Strict-Transport-Security) sorgt dafür, dass Browser ausschliesslich verschlüsselte Verbindungen nutzen. Auch die Kommunikation zu LLM-Providern (z.B. Azure OpenAI) erfolgt ausschliesslich über HTTPS.
- **Verschlüsselung im Ruhezustand:** Das System nutzt Docker-Volumes, die mittels LUKS (Linux Unified Key Setup) verschlüsselt werden können. Dies bietet eine AES-256-Verschlüsselung auf Blockebene für PostgreSQL, Milvus und den Dokumentenspeicher SeaweedFS.
- **Sicherheits-Header:** Zur Abwehr von Web-Angriffen werden Header wie Content-Security-Policy (CSP) und X-Frame-Options gesetzt, die das Einbetten in fremde Frames und MIME-Typ-Vortäuschungen verhindern.
- **Integritätsprüfung:** Alle Verbindungen zu externen Diensten validieren die Zertifikatsketten gegen vertrauenswürdige Root-Zertifizierungsstellen, um Man-in-the-Middle-Angriffe auszuschliessen.

9.5 Anwendungssicherheit und KI-Schutzschilde

9.5.1 Geschäftlicher Nutzen

KI-Systeme führen neue Risikoklassen ein, die durch klassische Firewalls nicht abgedeckt werden. Manipulative Eingaben (z.B. Prompt Injections) können versuchen, interne Anweisungen zu extrahieren oder Filter zu umgehen. Zudem besteht die Gefahr, dass Personenidentifizierbare Informationen (PII) unbeabsichtigt an Cloud-Modelle gesendet werden. Ein umfassender Schutzmechanismus muss daher sowohl die technische Integrität (Malware-Schutz) als auch die semantische Ebene (Inhaltsschutz) absichern. Dies ermöglicht es Unternehmen, die Innovationskraft grosser Sprachmodelle zu nutzen, ohne die Kontrolle über den Informationsabfluss zu verlieren.

9.5.2 Konzeptioneller Ansatz

Der Swiss AI Hub implementiert ein mehrstufiges Filtersystem aus Input Guards und Output Guards. Jede Interaktion wird als potenziell bösartig eingestuft, bis sie validiert ist. Auf Plattformebene werden Daten anonymisiert, bevor sie den geschützten Bereich verlassen. Auf Agentenebene wird sichergestellt, dass die Antworten der KI qualitativ hochwertig sind und keine sensiblen Daten aus internen Wissensdatenbanken preisgeben.

9.5.3 Technische Umsetzung im Swiss AI Hub

Die Plattform kombiniert technische Validierung mit semantischer Analyse:

- **Eingabevalidierung:** Datei-Uploads werden gegen eine Whitelist von über 40 Typen geprüft. Der tatsächliche MIME-Typ wird validiert, um getarnte ausführbare Dateien zu blockieren. Dateinamen werden von Zeichen gereinigt, die Path-Traversal-Angriffe (z.B. ../) ermöglichen könnten.
- **PII-Anonymisierung (Presidio):** Im LLM-Gateway scannt Presidio jeden Prompt. Im Maskierungsmodus werden Namen oder E-Mails durch Platzhalter wie [PERSON] ersetzt. Im Blockierungsmodus werden hochsensible Anfragen (z.B. Kreditkartennummern) sofort abgewiesen.
- **Agenten-Guards:** Spezialisierte Wächter prüfen die Interaktion. Der Kontext-Ausreichend-Schutzmechanismus verhindert Halluzinationen, indem er Antworten blockiert, die nicht durch Quellen in der Wissensdatenbank belegt sind. Ein PII-Guard auf der Ausgangsseite redigiert sensible Daten aus Agenten-Antworten zu [REDACTED], bevor der Benutzer diese sieht.
- **Daten-Lifecycle:** Ephemere Daten in Caches und temporären Speichern werden nach 30 Tagen automatisch gelöscht, um die Datensparsamkeit gemäss revDSG technisch zu erzwingen.

10 Kapitel 09: Regulatorische Compliance

Die Einführung von künstlicher Intelligenz in Schweizer Unternehmen ist untrennbar mit der Einhaltung strenger gesetzlicher Vorgaben verbunden. Mit dem Inkrafttreten des revidierten Datenschutzgesetzes (revDSG) am 1. September 2023, der extraterritorialen Wirkung der europäischen DSGVO (GDPR) sowie der schrittweisen Umsetzung des EU AI Acts stehen Organisationen vor

einer komplexen Compliance-Landschaft. Ein KI-System darf in diesem Umfeld keine juristische „Black Box“ sein, sondern muss als prüfbarer Bestandteil der Corporate Governance fungieren.

Dieses Kapitel legt dar, wie der Swiss AI Hub regulatorische Anforderungen nicht durch bürokratische Hürden, sondern durch integrierte Architektur-Merkmale löst. Die Plattform transformiert Compliance von einem manuellen Kontrollaufwand in einen automatisierten Standardprozess, der rechtliche Risiken minimiert und die notwendige Transparenz für interne und externe Auditoren schafft.

10.1 Auf einen Blick

- **Territoriale Rechtskonformität:** Durch isolierte Betriebsmodelle und lokale Datenhaltung verbleiben sensible Informationen im schweizerischen Rechtsraum und unterstehen ausschliesslich dem revDSG.
- **Privacy by Design:** Automatisierte Daten-Lebenszyklen und konfigurierbare Löschfristen verankern den Datenschutz tief in der technischen Architektur der Wissensdatenbanken.
- **Konformität mit dem EU AI Act:** Die Plattform unterstützt die regulatorischen Anforderungen für Hochrisiko-Systeme durch Transparenzmechanismen, Rückverfolgbarkeit und zwingende menschliche Aufsicht.
- **Automatisierte Betroffenenrechte:** Integrierte APIs zur Umsetzung von Auskunft- und Löschbegehren (DSAR) reduzieren den administrativen Aufwand und sichern die gesetzlichen Fristen.
- **Inklusivität durch Mehrsprachigkeit:** Die native Unterstützung der Schweizer Landessprachen gewährleistet den diskriminierungsfreien Zugang und erfüllt die Anforderungen des Service Public.

10.2 Territoriale Rechtskonformität und Datensouveränität

10.2.1 Geschäftlicher Nutzen

Für Schweizer Organisationen, insbesondere in der öffentlichen Verwaltung, im Gesundheitswesen und im Finanzsektor, ist der physische Standort der Daten entscheidend. Die Nutzung globaler Cloud-Dienste kollidiert oft mit dem Risiko, dass Daten gemäss ausländischem Recht (z.B. US CLOUD Act) abgegriffen werden könnten. Um Konflikte mit dem revDSG und der DSGVO zu vermeiden, benötigen Unternehmen die Garantie, dass sensible Daten den schweizerischen Rechtsraum niemals verlassen. Eine souveräne Infrastruktur erleichtert Audit-Prozesse massiv und stärkt das Vertrauen von Bürgern und Kunden in die digitale Integrität der Organisation.

10.2.2 Konzeptioneller Ansatz

Der Swiss AI Hub löst das Problem internationaler Datentransfers durch das Prinzip der absoluten Datensouveränität. Da die Plattform vollständig in der Infrastruktur des Kunden betrieben wird, entfällt die Notwendigkeit für komplexe rechtliche Konstrukte wie Standardvertragsklauseln (SCCs) für Datentransfers in unsichere Drittstaaten. Das Konzept unterstützt isolierte Betriebsmodelle, bei denen Wissen lokal verarbeitet wird. Durch den EU-Angemessenheitsbeschluss für die Schweiz ist zudem der Datenverkehr mit europäischen Partnern rechtlich abgesichert, solange die Datenhoheit innerhalb der definierten Perimeter gewahrt bleibt.

10.2.3 Technische Umsetzung im Swiss AI Hub

Die Plattform ermöglicht verschiedene Deployment-Szenarien zur Wahrung der territorialen Integrität. Im On-Premise-Betrieb oder in einer Schweizer Private Cloud verbleiben sämtliche Datenbanken und Vektorspeicher unter der direkten Kontrolle des Mandanten. Für höchste Sicherheitsstufen unterstützt das System Air-Gap-Installationen, bei denen die Plattform physisch vom Internet getrennt ist. Hierbei kommen lokal gehostete Modelle via vLLM oder llama.cpp zum Einsatz, sodass keine API-Aufrufe an externe Anbieter gesendet werden müssen. Dies garantiert technisch, dass kein einziges Byte den definierten Schweizer Sicherheitsperimeter verlässt.

10.3 Datenschutz und Automatisierung von Betroffenenrechten

10.3.1 Geschäftlicher Nutzen

Das revDSG und die DSGVO gewähren Einzelpersonen weitreichende Rechte, darunter Auskunft über gespeicherte Daten, Berichtigung und Löschung. Unter dem Schweizer revDSG können Verstösse gegen diese Pflichten zu persönlichen Bussen für Verantwortliche von bis zu CHF 250'000 führen. Die manuelle Bearbeitung solcher Anfragen (Data Subject Access Requests, DSAR) innerhalb der gesetzlichen Frist von 30 Tagen ist zeitaufwändig und fehleranfällig. Eine Enterprise-Lösung muss diese Prozesse standardisieren, um den administrativen Aufwand zu reduzieren und Compliance-Verstösse durch menschliches Versagen auszuschliessen.

10.3.2 Konzeptioneller Ansatz

Die Plattform verankert «Privacy by Design» durch ein striktes Lebenszyklus-Management. Das Konzept unterscheidet zwischen flüchtigen Interaktionsdaten und permanentem Wissen in der Wissensdatenbank. Durch konfigurierbare Aufbewahrungsrichtlinien (Retention Policies) reinigt sich das System selbstständig. Zudem sind Mechanismen vorhanden, um Personenidentifizierbare Informationen (PII) auf Anfrage gezielt zu identifizieren, zu korrigieren oder unwiderruflich zu entfernen. Dies stellt sicher, dass die Datenminimierung kein Lippenbekenntnis bleibt, sondern technisch erzwungen wird.

10.3.3 Technische Umsetzung im Swiss AI Hub

Technisch werden diese Anforderungen durch automatische Ablaufmechanismen und administrative APIs umgesetzt:

- **Ephemere Daten:** Caches und Sitzungsdaten im Arbeitsspeicher (Valkey/Redis) besitzen eine harte Lebensdauer (TTL) von 30 Tagen.
- **Workflow-Ereignisse:** Event-Logs in NATS JetStream unterliegen doppelten Beschränkungen – sie werden nach 30 Tagen oder beim Erreichen von 10 Millionen Nachrichten automatisch rotiert.
- **DSAR-Unterstützung:** Über die Benutzerprofil-API können Datenkopien für das Auskunftsrecht (Art. 25 revDSG) exportiert werden. Administratoren können Profile aktualisieren (Berichtigung) oder Nutzer aus Konversations-Threads entfernen (Löschung). Da Audit-Logs revisionssicher bleiben müssen, werden PII dort bei Löschbegehren pseudonymisiert, während der operative Zugriff entzogen wird.

10.4 Konformität mit dem EU AI Act und ethische Governance

10.4.1 Geschäftlicher Nutzen

Mit dem Inkrafttreten des EU AI Acts im August 2024 entsteht ein globaler Massstab für die Regulierung von KI. Schweizer Unternehmen, die im EU-Markt agieren oder Hochrisiko-Anwendungen (z.B. in der Personalrekrutierung oder Kreditprüfung) einsetzen, müssen Transparenz, menschliche Aufsicht und Risikomanagement nachweisen. Die Nichteinhaltung kann nicht nur horrenden Strafen nach sich ziehen, sondern auch den Marktzugang gefährden. Eine gesetzeskonforme Plattform schützt die Investitionen, indem sie die notwendigen Dokumentations- und Kontrollfunktionen bereits im Kern bereitstellt.

10.4.2 Konzeptioneller Ansatz

Der Swiss AI Hub ist darauf ausgelegt, die Anforderungen für verschiedene Risikoklassen des AI Acts zu erfüllen. Das zentrale Element ist die Erklärbarkeit: Es muss jederzeit nachvollziehbar sein, auf welcher Datenbasis eine Antwort generiert wurde. Für kritische Entscheidungen implementiert die Plattform das Prinzip „Human-in-the-Loop“. Dies stellt sicher, dass eine Maschine niemals ohne menschliche Letztentscheidung in sensiblen Kontexten agiert, was auch die Anforderungen des revDSG an das Hochrisikoprofiling abdeckt.

10.4.3 Technische Umsetzung im Swiss AI Hub

Die Plattform bietet spezifische Werkzeuge zur Erfüllung der regulatorischen Pflichten:

- **Transparenz und Tracing:** Durch Phoenix-Tracing und Quellenzuordnung wird jede Antwort mit ihren Ursprungsdokumenten in der Wissensdatenbank verknüpft, was Halluzinationen offenlegt.
- **Human-in-the-Loop:** Die Workflow-Engine unterstützt Unterbrechungspunkte (HumanInTheLoopEvents), an denen ein Prozess stoppt, bis ein autorisierter Benutzer das Ergebnis prüft. Alternativ ermöglicht „Bot-in-the-Loop“ die Eskalation via Slack oder Teams.
- **Auditierung:** Lückenlose Logs aller Interaktionen und die Versionierung von Agenten-Profilen erlauben es Auditoren, exakt zu rekonstruieren, welches Modell zu welchem Zeitpunkt mit welchen Daten gearbeitet hat. Dies unterstützt die Erstellung von Datenschutz-Folgenabschätzungen (DPIA).

10.5 Inklusivität und Schweizer Mehrsprachigkeit

10.5.1 Geschäftlicher Nutzen

Für Institutionen in der Schweiz ist Mehrsprachigkeit eine gesetzliche Pflicht. Eine Compliance-Plattform muss sicherstellen, dass Mitarbeitende und Bürger in allen Sprachregionen gleichberechtigten Zugang zu KI-Diensten haben. Diskriminierung durch Sprachbarrieren widerspricht dem Service Public und internen Diversitätsrichtlinien. Zudem müssen regulatorische Dokumentationen und Benutzerhinweise in den Landessprachen vorliegen, um die Transparenzanforderungen (Art. 19 revDSG) vollumfänglich zu erfüllen.

10.5.2 Konzeptioneller Ansatz

Internationalisierung ist als Kernfunktion verankert. Das Konzept sieht vor, dass alle vier Landessprachen (Deutsch, Französisch, Italienisch, Englisch) gleichberechtigt behandelt werden. Dies betrifft nicht nur die Benutzeroberfläche, sondern auch die semantische Verarbeitung. Ein Agenten-Profil muss in der Lage sein, Dokumente in einer Sprache zu verstehen und Fragen in einer anderen Sprache präzise zu beantworten, ohne an Qualität zu verlieren.

10.5.3 Technische Umsetzung im Swiss AI Hub

Die Umsetzung erfolgt durchgängig auf allen Ebenen:

- **Lokalisierte UI:** Sämtliche Menüs, Fehlermeldungen und Hilfetexte sind vollständig übersetzt. Die Sprachwahl wird im Profil des Benutzers gespeichert.
- **Sprachspezifische Suche:** Die Ingestion-Pipeline und die Vektordatenbank unterstützen sprachspezifische Tokenisierung und Stemming für alle vier Sprachen. Dies stellt sicher, dass Suchanfragen beispielsweise in Italienisch auch relevante italienische Dokumente finden.
- **Regionale Formatierung:** Zahlen, Daten und Währungen werden automatisch gemäss den Schweizer Konventionen formatiert, was die Korrektheit der Datenrepräsentation über Sprachgrenzen hinweg sichert.

11 Kapitel 10: Deployment, Betrieb

Der Übergang von einem funktionierenden Prototypen zu einer stabilen Enterprise-Lösung markiert oft die kritischste Phase in KI-Projekten. Während in der Entwicklungsphase Agilität und Schnelligkeit dominieren, erfordert der produktive Betrieb (ñDay 2 Operationsz) Stabilität, Skalierbarkeit und die nahtlose Integration in bestehende IT-Landschaften. CIOs und IT-Leiter stehen vor der Herausforderung, eine KI-Infrastruktur bereitzustellen, die nicht nur heute funktioniert, sondern auch unter Last skaliert, Ausfälle toleriert und strengen Sicherheitsvorgaben genügt.

Dieses Kapitel beleuchtet die betrieblichen Aspekte des Swiss AI Hub. Es zeigt auf, wie die Architektur flexible Bereitstellungsmodelle unterstützt – von der eigenen Private Cloud über Managed Services bis zum isolierten Hochsicherheitsrechenzentrum – und wie moderne Container-Technologien einen wartungsarmen, hochverfügbaren 24/7-Betrieb gewährleisten. Der Swiss AI Hub wird dabei nicht als blosses Framework, sondern als ñInfrastruktur als Produktz bereitgestellt, das bereits gelöste Lösungen für Authentifizierung, Kostenkontrolle und Monitoring mitliefert.

11.1 Auf einen Blick

- **Infrastruktur-Agnostik:** Volle Flexibilität zwischen On-Premise, Private Cloud (BYOC) oder Schweizer SaaS-Hosting, ohne Anpassung der Applikationslogik.
- **Harte Isolation:** Unterstützung für Multi-Instancing-Szenarien (ñShared Nothingz), um maximale Datentrennung zwischen Organisationseinheiten technisch zu garantieren.
- **Air-Gap-Fähigkeit:** Vollständiger Offline-Betrieb ohne Internetverbindung durch lokale Inferenz-Server (vLLM, llama.cpp), um höchste Souveränitätsansprüche zu erfüllen.

- **Skalierung durch Design:** Ereignisgesteuerte Architektur (Event-Driven) via NATS ermöglicht die horizontale Skalierung von Workern für hohe Lastspitzen.
- **Vollständige Observability:** Native Integration von OpenTelemetry, SigNoz und Phoenix für ein lückenloses Monitoring von Infrastruktur, Kosten und KI-Performance.

11.2 Flexible Betriebsmodelle und Datensouveränität

11.2.1 Geschäftlicher Nutzen

Es gibt im Schweizer Markt keine *“One-Size-Fits-All”*-Lösung für das Hosting. Eine Kantonale Bank unterliegt anderen regulatorischen Zwängen als ein Industrieunternehmen oder eine Bundesbehörde. Die Entscheidung über den Speicherort der Daten und den Betrieb der Infrastruktur muss allein beim Kunden liegen und darf nicht durch die Architektur der Software diktiert werden. Die Fähigkeit, die Plattform exakt dort zu betreiben, wo die Datenhoheit am besten gewahrt wird – sei es im eigenen Rechenzentrum oder in einer zertifizierten Schweizer Cloud – eliminiert Compliance-Risiken und ermöglicht den Einsatz von KI auch in Szenarien, die bisher aufgrund von Cloud-Verboten undenkbar waren.

11.2.2 Konzeptioneller Ansatz

Der Swiss AI Hub folgt dem Prinzip *“Bring Your Own Infrastructure”*. Die Plattform ist als infrastruktur-agnostische Lösung konzipiert, die als vollständiger Stack (*“Batteries-included”*) bereitgestellt wird. Das Spektrum der unterstützten Betriebsmodelle umfasst drei Hauptszenarien: On-Premise (Betrieb auf eigener Hardware), Private Cloud (Betrieb im eigenen Tenant bei Azure, AWS oder GCP) sowie SaaS via Schweizer Cloud-Hosting, bei dem die Datenresidenz in der Schweiz rechtlich und physisch garantiert bleibt. Ein zentrales Konzept ist zudem das Multi-Instancing, welches eine physische Trennung zwischen hochsensiblen Organisationseinheiten erlaubt, um Datenlecks technisch auszuschliessen.

11.2.3 Technische Umsetzung im Swiss AI Hub

Technisch basiert die Bereitstellung auf Containerisierung mittels Docker. Die gesamte Plattform lässt sich mit einem einzigen Orchestrierungs-Befehl (`docker compose up`) in etwa 30 Minuten bereitstellen.

- **Infrastruktur-Komponenten:** Das Deployment umfasst den gesamten Stack inklusive API (FastAPI), Vektorspeicherung (Milvus), Objektspeicher (SeaweedFS S3), Nachrichtenwarteschlange (NATS) und Datenbanken (PostgreSQL, FerretDB).
- **Ressourcen-Anforderungen:** Für einen stabilen Betrieb werden mindestens 8 CPU-Kerne und 32 GB RAM empfohlen, wobei SSD-Speicher für die Datenbankperformance essenziell ist.
- **Isolation:** Über spezifische Konfigurationsprofile passt sich das System an. Während im lokalen Deployment selbstsignierte Zertifikate (via mkcert) genutzt werden, verwaltet das System in der Produktion automatisch Let's Encrypt SSL-Zertifikate für bis zu sieben Subdomains (z. B. aihub, dagster, datalake).
- **Air-Gap-Support:** Da die Plattform lokale Modelle via vLLM oder Hugging Face TEI unterstützt, ist keine ausgehende Verbindung zu externen APIs notwendig.

11.3 Sicherheitsarchitektur und Netzwerk-Isolation

11.3.1 Geschäftlicher Nutzen

Die Sicherheit einer KI-Plattform darf nicht erst an der Applikationsgrenze beginnen. In einer Enterprise-Umgebung ist es entscheidend, dass der Schadensradius bei einer potenziellen Kompromittierung einzelner Komponenten minimal bleibt. IT-Verantwortliche benötigen die Sicherheit, dass Datenbanken und interne Logik-Bausteine niemals direkt aus dem Internet erreichbar sind. Eine tiefgreifende Segmentierung der Infrastruktur schützt nicht nur vor externen Angriffen, sondern verhindert auch unbefugte Datenflüsse innerhalb der Plattform, was die Einhaltung strengster Sicherheitsaudits ermöglicht.

11.3.2 Konzeptioneller Ansatz

Der Swiss AI Hub implementiert das Prinzip der "Defense-in-Depth" durch eine strikte Zonen-Einteilung auf Netzwerkebene. Anstatt alle Container in einem flachen Netzwerk zu betreiben, werden Dienste in funktionale Gruppen unterteilt. Kommunikation zwischen diesen Zonen ist nur über definierte Schnittstellen möglich. Ein zentrales Gateway (Reverse Proxy) agiert als einziger "Entry Point" und übernimmt die Verschlüsselung sowie die Authentifizierung, bevor eine Anfrage die internen Dienste erreicht.

11.3.3 Technische Umsetzung im Swiss AI Hub

Die Plattform erzwingt eine Segmentierung in fünf isolierte Docker-Netzwerke:

- **Proxy-Netzwerk:** Beinhaltet Traffic als API-Gateway und nimmt externen Traffic auf Port 443 entgegen.
- **Backend-Netzwerk:** Isoliert Verarbeitungsdienste wie die API, KI-Agenten und die Dokumentenverarbeitung (Docling).
- **Data-Netzwerk:** Reserviert für persistente Datenspeicher (PostgreSQL, Milvus, Valkey) und den Message-Broker (NATS).
- **Storage-Netzwerk:** Dediziert für den verteilten Objektspeicher SeaweedFS.
- **Egress-Netzwerk:** Ein spezieller Bereich für Dienste, die Internetzugang benötigen (z. B. Web-Scraper), wobei die Inter-Container-Kommunikation (ICC) deaktiviert ist, um seitliche Bewegungen von Angreifern zu verhindern. Alle Container laufen als Nicht-Root-Benutzer (UID 1000), was die Systemsicherheit zusätzlich härtet.

11.4 Skalierbarkeit und operative Resilienz

11.4.1 Geschäftlicher Nutzen

KI-Systeme unterliegen oft stark schwankenden Lastprofilen. Ein Monatsabschluss oder eine neue Daten-Ingestion können die Anfragen an das System kurzfristig vervielfachen. Eine starre Infrastruktur würde hier entweder zu teuren Überkapazitäten im Leerlauf oder zu Systemabstürzen unter Last führen. Unternehmen benötigen eine Architektur, die dynamisch mit den Anforderungen mitwächst,

um Service-Level-Agreements (SLAs) stabil zu halten, ohne dass die Betriebskosten unkontrolliert steigen.

11.4.2 Konzeptioneller Ansatz

Die Skalierungsstrategie basiert auf einer ereignisgesteuerten Architektur (Event-Driven Architecture) und der Zustandslosigkeit der Komponenten. Durch die Entkopplung von Anfrage und Verarbeitung über eine Nachrichtenwarteschlange können rechenintensive Aufgaben asynchron abgearbeitet werden. Da die Agenten-Logik keinen lokalen Zustand hält, kann jede Aufgabe von jedem verfügbaren Worker übernommen werden. Dies ermöglicht eine horizontale Skalierung: Bei steigender Last werden einfach zusätzliche Instanzen der benötigten Dienste gestartet.

11.4.3 Technische Umsetzung im Swiss AI Hub

Das zentrale Nervensystem für die Skalierung ist **NATS JetStream**.

- **Zustandslose Worker:** Dienste für die Dokumentenverarbeitung (Pipelines) oder die Agenten-Ausführung können mehrfach instanziiert werden. NATS verteilt die anfallenden Events automatisch auf die verfügbaren Instanzen (Load Balancing).
- **Asynchrone Ingestion:** Zeitintensive Prozesse wie das Parsing grosser Dokumentmengen via Docling blockieren nicht die Benutzeroberfläche. Die API nimmt Dokumente entgegen und übergibt sie an die Dagster-basierte Pipeline-Infrastruktur.
- **Optimierte Ressourcennutzung:** Inferenz-Server für lokale Modelle können auf GPU-Knoten ausgelagert werden, während die Verwaltungslogik auf kostengünstigen CPU-Knoten operiert. Dies erlaubt eine präzise Steuerung der Hardware-Investitionen.

11.5 Hochverfügbarkeit und Disaster Recovery

11.5.1 Geschäftlicher Nutzen

Für geschäftskritische Anwendungen ist Ausfallsicherheit keine Option, sondern Pflicht. Der Ausfall einer einzelnen Komponente darf nicht zum Stillstand ganzer Geschäftsprozesse führen. IT-Verantwortliche benötigen Garantien für kurze Wiederherstellungszeiten (RTO) und minimale Datenverluste (RPO). Ein robustes System muss Fehler auf Infrastrukturebene tolerieren und sich selbst heilen können, um einen unterbrechungsfreien Betrieb zu gewährleisten.

11.5.2 Konzeptioneller Ansatz

Der Ansatz zur Ausfallsicherheit beruht auf Redundanz und granularen Sicherungsverfahren. Die Plattform ist so konzipiert, dass kritische Dienste im Cluster-Betrieb laufen können. Die Backup-Strategie verfolgt einen zweigleisigen Weg: Vollständige System-Snapshots für eine schnelle Gesamtwiederherstellung und komponentenspezifische Backups für maximale Flexibilität. Dies erlaubt es, im Notfall gezielt einzelne Datenbanken oder Vektorsammlungen wiederherzustellen, ohne das Gesamtsystem zurücksetzen zu müssen.

11.5.3 Technische Umsetzung im Swiss AI Hub

Die Plattform nutzt bewährte Mechanismen zur Sicherung der Geschäftskontinuität:

- **Granulare Backups:** Unterstützung für pg_basebackup und WAL-Archivierung (Write-Ahead Logging) für PostgreSQL sowie etcd-Snapshots für die Metadaten von SeaweedFS und Milvus.
- **Vektordaten-Sicherung:** Milvus-Kollektionen können direkt in den S3-Speicher exportiert werden.
- **Self-Healing:** Docker Health Checks überwachen kontinuierlich die Endpunkte (/health). Reagiert ein Dienst nicht mehr, wird der Container automatisch neu gestartet.
- **Daten-Persistenz:** Kritische Daten liegen auf verschlüsselten Docker-Volumes (LUKS), die vom Lebenszyklus der Container unabhängig sind.

11.6 Updates und technologische Unabhängigkeit

11.6.1 Geschäftlicher Nutzen

Die Innovationszyklen in der KI sind extrem kurz. Unternehmen müssen in der Lage sein, neue Funktionen, Sicherheits-Patches und verbesserte Modelle schnell zu adaptieren, ohne den laufenden Betrieb zu stören. Gleichzeitig ist die Abhängigkeit von einem einzelnen Modell-Anbieter (Vendor Lock-in) ein strategisches Risiko. Eine moderne Plattform muss es ermöglichen, Modelle wie Bausteine auszutauschen oder redundant auszulegen, um die Verhandlungsmacht zu behalten und die Geschäftskontinuität zu sichern.

11.6.2 Konzeptioneller Ansatz

Der Swiss AI Hub trennt architektonisch strikt zwischen der stabilen Kernplattform (Core) und dem flexiblen Kundencode (Agents/Pipelines). Beide Bereiche verfügen über unabhängige Lebenszyklen und Versionierungen. Das integrierte LLM-Gateway (LiteLLM) fungiert als Abstraktionsschicht: Ein Agent kommuniziert nie direkt mit einem spezifischen Modell eines US-Anbieters, sondern mit einer universellen Schnittstelle. Dies erlaubt automatisierte Failover-Szenarien und den nahtlosen Wechsel zwischen Cloud-Modellen und lokalen Instanzen.

11.6.3 Technische Umsetzung im Swiss AI Hub

Das Update-Management nutzt semantische Versionierung und Container-Tags (latest, nightly, vX.Y.Z).

- **Modell-Agnostik:** LiteLLM bietet eine OpenAI-kompatible API für über 100 Anbieter. Ein Modellwechsel erfordert lediglich eine Konfigurationsänderung in der YAML-Datei, kein Umschreiben des Agenten-Codes.
- **Kostenkontrolle:** Das Gateway trackt den Token-Verbrauch in Echtzeit. Administratoren können via Umgebungsvariablen wie LITE_LLM_PROXY_USER_MAX_BUDGET harte Budgets und Ratenlimits pro Benutzer oder Team erzwingen.

- **Geringe Downtime:** Durch die Nutzung von Container-Orchestrierung können neue Versionen parallel zu alten gestartet werden (Rolling Updates), wobei der Verkehr erst umgeleitet wird, wenn die neue Instanz als bereit gemeldet wird.

11.7 Operative Transparenz und Monitoring

11.7.1 Geschäftlicher Nutzen

In einer komplexen KI-Infrastruktur ist operative Blindheit fatal. Performance-Engpässe, schleichende Kostenanstiege oder Modell-Fehler müssen erkannt werden, bevor sie die Benutzererfahrung beeinträchtigen. Ein integriertes Monitoring reduziert die Zeit bis zur Fehlerbehebung (MTTR) drastisch und liefert die Datenbasis für Kapazitätsplanung und interne Leistungsverrechnung (Chargeback). Transparenz schafft zudem Vertrauen bei den Stakeholdern, da der Nutzen und die Kosten der KI objektiv messbar werden.

11.7.2 Konzeptioneller Ansatz

Die Observability-Strategie basiert auf den drei Säulen: Health Checks, Metriken und Logs. Anstatt proprietäre Tools zu erzwingen, setzt der Swiss AI Hub auf offene Standards wie **OpenTelemetry (OTel)**. Dies ermöglicht eine nahtlose Integration in bestehende Enterprise-Monitoring-Lösungen (wie Datadog, Splunk oder Dynatrace), liefert aber standardmässig einen vollständigen, vorkonfigurierten Analyse-Stack mit. Ein zentraler OTel-Collector dient dabei als Hub, der Daten sammelt, filtert und an die entsprechenden Visualisierungswerkzeuge verteilt.

11.7.3 Technische Umsetzung im Swiss AI Hub

Die Plattform bietet spezialisierte Ansichten für verschiedene operative Rollen:

- **SigNoz:** Dient als zentrales Dashboard für Infrastruktur-Metriken (CPU, RAM, Netzwerk) und aggregierte Logs. Hier werden auch Alarme bei Dienstaussfällen oder Performance-Einbrüchen konfiguriert.
- **Phoenix:** Ermöglicht tiefes KI-Tracing. Es visualisiert den Token-Verbrauch, die Latenzen pro Modellaufruf und den vollständigen Kontext von RAG-Abfragen (Retrieval-Augmented Generation).
- **Integrierte Dashboards:** Traefik liefert Einblicke in das Request-Routing und den TLS-Status, während Dagster die Gesundheit und Historie aller Daten-Pipelines überwacht.
- **Audit-Trails:** Sämtliche Authentifizierungsereignisse und API-Aufrufe werden strukturiert erfasst, was die Einhaltung regulatorischer Anforderungen (revDSG) ohne Zusatzaufwand unterstützt.

12 Kapitel 11: Integration und Interoperabilität

In einer modernen Enterprise-IT-Landschaft darf eine KI-Plattform keine isolierte Insel sein. Der wahre Wert künstlicher Intelligenz entfaltet sich erst dann, wenn sie tief in die bestehenden Systeme, Datenquellen und Kommunikationskanäle eines Unternehmens eingebettet ist. Datensilos

und proprietäre Schnittstellen sind die grössten Feinde der digitalen Transformation, da sie den Informationsfluss hemmen und die Komplexität unnötig erhöhen.

Der Swiss AI Hub begegnet dieser Herausforderung mit einer Strategie der radikalen Offenheit. Dieses Kapitel beschreibt, wie sich die Plattform nahtlos in heterogene Umgebungen einfügt. Von der API-Kompatibilität, die eine Migration bestehender Anwendungen in Minuten ermöglicht, bis hin zur nativen Präsenz in Microsoft Teams und Slack, ist die Architektur darauf ausgelegt, technische Hürden abzubauen und KI dort bereitzustellen, wo die Arbeit tatsächlich stattfindet.

12.1 Auf einen Blick

- **API-First-Strategie:** Die vollständige OpenAI-Kompatibilität ermöglicht die sofortige Migration bestehender Anwendungen, während native APIs tiefen Zugriff auf komplexe Agenten-Workflows bieten.
- **Dynamische Endpunkt-Generierung:** Das System erstellt automatisch massgeschneiderte REST-Endpunkte für neu bereitgestellte Agenten und Prozesse, was manuelle API-Entwicklung überflüssig macht.
- **Multichannel-Kollaboration:** Durch den Azure Bot Service wird KI direkt in Microsoft Teams, Slack und Outlook integriert, einschliesslich der Fähigkeit zur Eskalation an menschliche Experten via Bot-in-the-Loop.
- **Model Context Protocol (MCP):** Die Unterstützung des MCP-Standards erlaubt es KI-Entwicklungstools, den Plattform-Status direkt abzufragen und Agenten während der Entwicklung zu inspizieren.
- **Föderierte Identität:** Ein nahtloses Single Sign-On (SSO) über Industriestandards wie OIDC und OAuth 2.0 garantiert die Einhaltung zentraler Sicherheitsrichtlinien ohne zusätzliche Passwortverwaltung.

12.2 Standardisierte API-Architektur und Entwickler-Schnittstellen

12.2.1 Geschäftlicher Nutzen

Für Unternehmen, die bereits erste Erfahrungen mit KI-Entwicklung gesammelt haben, stellt der Wechsel auf eine neue Plattform oft ein erhebliches Risiko dar. Investitionen in bestehenden Code, der auf den Schnittstellen von globalen Marktführern basiert, drohen verloren zu gehen, was die Modernisierung der Infrastruktur bremst. IT-Leiter benötigen die Sicherheit, dass eine Migration auf eine souveräne Schweizer Plattform kein komplettes Neuschreiben der Applikationen erfordert. Gleichzeitig muss die Schnittstellenlandschaft flexibel genug sein, um sowohl einfache Chat-Anfragen als auch hochkomplexe, ereignisgesteuerte Geschäftsprozesse abzubilden, ohne neue Flaschenhälse in der Entwicklung zu erzeugen.

12.2.2 Konzeptioneller Ansatz

Die Integrationsstrategie verfolgt einen hybriden API-Ansatz, der Standardisierung mit nativer Leistungsfähigkeit kombiniert. Einerseits bietet die Plattform volle Kompatibilität zu etablierten Industriestandards, um die Einstiegshürde so niedrig wie möglich zu halten. Das System verhält sich nach aussen wie ein Standard-LLM-Provider, was den Austausch der Backend-Infrastruktur ohne Anpassung der Geschäftslogik ermöglicht. Andererseits stehen erweiterte, plattformspezifische Schnittstellen bereit, um die volle Macht der Agenten-Orchestrierung zu nutzen. Ein besonderer

Schwerpunkt liegt auf der Automatisierung: Anstatt APIs manuell zu definieren, erkennt die Plattform neue Fähigkeiten selbstständig und stellt diese programmatisch bereit.

12.2.3 Technische Umsetzung im Swiss AI Hub

Der Swiss AI Hub implementiert vier spezifische Schnittstellentypen auf Basis von FastAPI, um unterschiedliche Integrationsbedürfnisse abzudecken. Die OpenAI-kompatible REST-API spiegelt die Spezifikationen der OpenAI-API exakt wider, sodass Anwendungen, die mit Standard-SDKs entwickelt wurden, lediglich die Basis-URL und den API-Schlüssel ändern müssen. Dies umfasst Chat Completions, Embeddings sowie die Audioverarbeitung. Für native Anwendungen bietet die Agenten-Interaktions-REST-API tiefen Zugriff auf die Plattformlogik, wodurch Entwickler Agenten-Workflows steuern, den Status langlaufender Aufgaben abfragen und auf den Ereignisverlauf zugreifen können.

Ein technologisches Highlight sind die dynamischen Agenten- und Prozess-Endpunkte. Ein Discovery-Dienst scannt kontinuierlich das interne NATS-System nach verfügbaren Komponenten und generiert automatisch typisierte REST-Endpunkte basierend auf deren Ereignisspezifikationen. Ergänzt wird dies durch die WebSocket-API für bidirektionale Echtzeit-Kommunikation, die das Streaming von Antworten sowie die Übermittlung von Zwischenschritten (Thought Events) erlaubt. Schliesslich implementiert der Swiss AI Hub einen Model Context Protocol (MCP) Server, der die plattforminternen Ressourcen für KI-gestützte Entwicklungsumgebungen wie Cursor oder Claude Code zugänglich macht, was die Entwicklerproduktivität massiv steigert.

12.3 Integration in Kommunikations- und Arbeitsplattformen

12.3.1 Geschäftlicher Nutzen

Die Akzeptanz neuer Technologien scheitert in der Praxis oft daran, dass Mitarbeitende gezwungen werden, ihre gewohnten Arbeitsumgebungen zu verlassen. Ein separates Webportal für KI-Anfragen erzeugt einen Medienbruch, der die tägliche Produktivität senkt und die Hemmschwelle zur Nutzung erhöht. Um dies zu vermeiden, muss die KI als virtueller Kollege dort präsent sein, wo die tägliche Kommunikation stattfindet. Dies steigert die Nutzungsrate nachweislich und senkt den Schulungsaufwand erheblich. Zudem ermöglicht die tiefe Integration in Kollaborationstools neuartige Szenarien der Zusammenarbeit, bei denen die KI bei Unsicherheiten proaktiv Experten um Rat fragen kann, ohne den digitalen Raum zu wechseln.

12.3.2 Konzeptioneller Ansatz

Anstatt für jeden Messenger eine isolierte Integration zu entwickeln, setzt der Swiss AI Hub auf eine Abstraktionsschicht für Konversationskanäle. Das Ziel ist eine «Write Once, Deploy Anywhere»-Strategie, bei der ein Agenten-Profil einmal konfiguriert und anschliessend flexibel verschiedenen Kanälen zugewiesen wird. Die Plattform behandelt externe Chat-Nachrichten technisch identisch zu internen API-Aufrufen, übersetzt jedoch die spezifischen Formate der Drittanbieter automatisch. Ein zentraler Bestandteil dieses Konzepts ist das Bot-in-the-Loop-Muster, welches die Lücke zwischen autonomer KI-Verarbeitung und menschlicher Expertise schliesst, indem es Arbeitsschritte an kritischen Entscheidungspunkten unterbricht.

12.3.3 Technische Umsetzung im Swiss AI Hub

Die technische Brücke bildet die Integration des Azure Bot Service in Kombination mit einer ereignis-gesteuerten Architektur via NATS. Dieser Dienst verbindet den Swiss AI Hub nativ mit Microsoft Teams, Slack, Outlook und weiteren Kanälen wie Skype oder Web-Chat-Widgets. Die Authentifizierung erfolgt dabei über die bestehende Identitätsinfrastruktur des Unternehmens, wodurch Sicherheitsrichtlinien gewahrt bleiben. Ein Alleinstellungsmerkmal ist die Bot-in-the-Loop-Infrastruktur: Ein Agent kann seine Ausführung pausieren und eine strukturierte Frage in einen definierten Slack- oder Teams-Kanal posten.

Sobald ein menschlicher Experte im entsprechenden Thread antwortet, erfasst das System diese Information als Ereignis, nimmt den Kontext wieder auf und setzt den Workflow des Agenten automatisch fort. Dieser Zustand wird persistent in der Datenbank verwaltet, sodass auch bei längeren Wartezeiten kein Wissen verloren geht. Die Integration unterstützt zudem Rich Media, einschliesslich des Austauschs von Dokumenten und Bildern, die direkt in die Daten-zu-Wissen-Pipeline des Agenten fliessen. Für eine natürliche Nutzererfahrung werden Echtzeit-Tipp-Indikatoren und inkrementelle Streaming-Antworten über alle Kanäle hinweg unterstützt.

12.4 Anbindung externer Fachsysteme und Prozessautomatisierung

12.4.1 Geschäftlicher Nutzen

Künstliche Intelligenz entfaltet ihren grössten geschäftlichen Nutzen, wenn sie nicht nur Informationen liefert, sondern aktiv handelt. Isolierte Chatbots können zwar Fragen beantworten, aber keine komplexen Geschäftsprozesse auslösen. Unternehmen benötigen eine Plattform, die als intelligenter Orchestrator fungiert und bestehende Fachanwendungen wie ERP-, CRM- oder Ticketsysteme aktiv steuert. Dies ermöglicht einen hohen Automatisierungsgrad, bei dem die KI Routineaufgaben übernimmt, wie das Auslesen einer Rechnung und das anschliessende Verbuchen in einem System, und so die Mitarbeitenden von repetitiven Tätigkeiten entlastet.

12.4.2 Konzeptioneller Ansatz

Die Interoperabilität mit Drittsystemen erfolgt bidirektional und richtet sich nach den Anforderungen an Latenz und Datenvolumen. Zum einen können Agenten externe Systeme aktiv aufrufen, um Aktionen auszuführen oder Daten abzufragen. Zum anderen können externe Systeme die KI als spezialisierten Dienst ansprechen, beispielsweise um bei Eingang eines neuen Dokuments automatisch eine Klassifizierung oder Zusammenfassung zu triggern. Die Architektur vermeidet dabei starre Punkt-zu-Punkt-Verbindungen und setzt auf standardisierte Protokolle sowie eine ereignis-gesteuerte Kommunikation, die sicherstellt, dass Systeme entkoppelt bleiben und unabhängig voneinander skalieren können.

12.4.3 Technische Umsetzung im Swiss AI Hub

Der Swiss AI Hub stellt für diese Anforderungen vier etablierte Integrationsmuster bereit:

- **Direkte Agenten-API-Aufrufe:** Innerhalb eines Agenten-Workflows können Standard-Bibliotheken genutzt werden, um REST-, SOAP- oder GraphQL-Schnittstellen externer Systeme in Echtzeit

anzusprechen. Dies ist ideal für den Abruf von Kundendaten während einer Interaktion.

- **Plattform-API-Integration:** Externe Fachanwendungen rufen die Agenten-Interaktions-API auf, um KI-Analysen auszulösen. Der Traefik-Proxy regelt hierbei die Authentifizierung und das Rate-Limiting zum Schutz der Infrastruktur.
- **Daten-zu-Wissen-Pipelines:** Für den Massendatenabgleich synchronisieren Dagster-Pipelines kontinuierlich Daten aus Quellen wie SharePoint, Confluence oder S3-Buckets in die Wissensdatenbank. Diese Batch-Synchronisierung stellt sicher, dass die KI stets auf dem aktuellen Stand der Unternehmensdaten operiert.
- **Webhook-Integration:** Die Plattform lässt sich über Webhooks als intelligente Komponente in übergeordnete Automatisierungswerkzeuge wie Microsoft Power Automate, n8n oder UiPath integrieren, um systemübergreifende Workflows effizient zu steuern.

12.5 Identitätsintegration und Single Sign-On (SSO)

12.5.1 Geschäftlicher Nutzen

In der Enterprise-IT ist die Verwaltung von Benutzeridentitäten ein sicherheitskritischer Aspekt der Governance. Eine KI-Plattform, die eine separate Benutzerdatenbank mit eigenen Passwörtern erfordert, erhöht nicht nur den administrativen Aufwand, sondern schafft auch zusätzliche Sicherheitsrisiken und senkt die Benutzerakzeptanz. Organisationen fordern eine nahtlose Einbindung in das zentrale Identity and Access Management (IAM). Mitarbeitende sollen sich mit ihren gewohnten Zugangsdaten anmelden können, während die IT sicherstellen muss, dass beim Austritt eines Mitarbeitenden der Zugriff auf alle KI-Ressourcen automatisch und ohne Verzug entzogen wird.

12.5.2 Konzeptioneller Ansatz

Der Swiss AI Hub speichert konsequent keine Passwörter, sondern basiert auf dem Prinzip der föderierten Identität. Die Plattform delegiert den gesamten Authentifizierungsprozess an den vertrauenswürdigen Identity Provider (IdP) des Unternehmens. Nach der erfolgreichen Anmeldung erhält die Plattform ein kryptografisch signiertes Token, das die Identität und die Gruppenzugehörigkeiten des Benutzers bestätigt. Dies ermöglicht eine zentrale Steuerung von Sicherheitsrichtlinien, wie die Erzwingung von Multi-Faktor-Authentifizierung (MFA), direkt im IdP. Das Berechtigungssystem der Plattform nutzt diese Informationen, um den Zugriff auf spezifische Agenten-Profile und Wissensdatenbanken dynamisch zu steuern.

12.5.3 Technische Umsetzung im Swiss AI Hub

Die technische Realisierung stützt sich auf die Industriestandards OpenID Connect (OIDC) und OAuth 2.0. Die Plattform integriert sich out-of-the-box mit Microsoft Entra ID (ehemals Azure AD), Keycloak, Okta oder ZITADEL. Bei jedem API-Aufruf validiert das System das übergebene JSON Web Token (JWT) mittels RSA-256 gegen den öffentlichen Schlüssel des Identity Providers.

Ein besonderes Merkmal ist das automatische Rollen-Mapping: Benutzergruppen aus dem Verzeichnisdienst werden über die Microsoft Graph API abgefragt und direkt auf interne Rollen, wie etwa die AgentVerwender-Rolle oder die WissensVerwalter-Rolle, abgebildet. Dadurch erhält ein neuer Mitarbeitender ab dem ersten Tag automatisch Zugriff auf die für seine Abteilung relevanten Agenten, ohne dass ein Administrator manuell eingreifen muss. Für automatisierte Prozesse unterstützt

die Plattform zudem den OAuth 2.0 Client Credentials Flow, wodurch auch technische Benutzer sicher und auditierbar auf die KI-Dienste zugreifen können.

13 Kapitel 12: User Experience und Interaktion

Die Akzeptanz einer Enterprise-KI-Plattform steht und fällt mit ihrer Benutzerfreundlichkeit. Selbst die leistungsfähigsten Modelle und sichersten Architekturen bleiben wirkungslos, wenn die Bedienung komplex ist oder etablierte Arbeitsweisen stört. Mitarbeitende erwarten heute von Unternehmenssoftware denselben Komfort (ñConsumer Grade Experiencež), den sie von privaten Applikationen gewohnt sind – ohne dabei Kompromisse bei der Datensicherheit einzugehen.

Dieses Kapitel beleuchtet die Interaktionsschicht des Swiss AI Hub. Es zeigt auf, wie die Plattform durch eine integrierte Suite, multimodale Eingaben und eine radikale Transparenz Vertrauen schafft und Barrieren abbaut, um KI von einem Expertenwerkzeug zu einem intuitiven Begleiter für die gesamte Belegschaft zu transformieren.

13.1 Auf einen Blick

- **Integrierte Produktivitäts-Suite:** Eine einheitliche Benutzeroberfläche bündelt Chat, Wissensverwaltung, Prozessmonitoring und Evaluation, um Kontextwechsel zu minimieren.
- **Barrierefreie Multimodalität:** Die nahtlose Unterstützung von Spracheingabe (inkl. Schweizerdeutsch), Dokumenten-Uploads und Vision-Fähigkeiten ermöglicht natürliche Interaktionsformen.
- **Evidenzbasierte Transparenz:** KI-Antworten werden durch interaktive Zitationen direkt mit den Quellen verknüpft, während Tracing-Dashboards die Argumentationskette der Agenten offenlegen.
- **Kanal-Unabhängigkeit:** Durch die Integration in Microsoft Teams und Slack holt die Plattform den Nutzer dort ab, wo die Zusammenarbeit stattfindet, inklusive Experten-Eskalation (ñBot-in-the-Loopž).
- **Nutzerzentrierte Datenhoheit:** Granulare Funktionen für den Export und die Löschung von Chat-Verläufen sowie die Verwaltung des Benutzergedächtnisses sichern die Einhaltung von Betroffenenrechten.

13.2 Die integrierte Suite (ñIntegrated Productivity Suitež)

13.2.1 Geschäftlicher Nutzen

In vielen Unternehmen führt die Einführung von KI zu einer gefährlichen Tool-Fragmentierung. Mitarbeitende müssen zwischen isolierten Anwendungen wechseln – einem Chatbot für HR-Fragen, einem separaten Tool für die Dokumentenanalyse und einem weiteren für das Prozessmonitoring. Dieser ständige Kontextwechsel (ñContext Switchingž) vernichtet Produktivität und erhöht den Schulungsaufwand massiv. Unternehmen benötigen eine zentrale Anlaufstelle, die alle KI-Dienste unter einer einheitlichen Oberfläche bündelt. Dies reduziert die Lernkurve, da Navigationskonzepte und Designsprache konsistent bleiben, und steigert die Effizienz durch einen nahtlosen Informationsfluss zwischen den Diensten.

13.2.2 Konzeptioneller Ansatz

Der Swiss AI Hub verfolgt den Ansatz einer integrierten Suite, vergleichbar mit modernen Office-Umgebungen. Die Benutzeroberfläche ist kein loses Sammelsurium von Werkzeugen, sondern ein kohärentes Ökosystem. Ein zentraler Service-Katalog dient als Einstiegspunkt für alle autorisierten Rollen. Das Design-Prinzip der Kontext-Persistenz stellt sicher, dass Nutzer nahtlos zwischen Aufgaben wechseln können – etwa von der Analyse eines Dokuments im Wissensmanagement direkt zur Interaktion mit einem darauf spezialisierten Agenten-Profil –, ohne den Faden zu verlieren. Das System passt sich dabei durch dynamische Dienstsichtbarkeit (ñSecurity by Invisibilityž) automatisch an die Berechtigungen des Nutzers an.

13.2.3 Technische Umsetzung im Swiss AI Hub

Die Benutzeroberfläche basiert auf einer tief integrierten Implementierung der Open WebUI, die als primäre Chat-Schnittstelle dient und um unternehmensspezifische Module erweitert wurde:

- **Zentraler Service-Katalog:** Über eine persistente Seitenleiste greifen Nutzer auf spezialisierte Dienste zu: Agentenverwaltung, Thread-Management (Konversationshistorie), Wissensverwaltung, Prozessverwaltung und den Evaluierungsdienst.
- **Intelligentes UI-Framework:** Die Oberfläche nutzt WebSockets für Echtzeit-Updates und Streaming-Antworten (ñToken-by-Tokenž). Skeleton-Screens sorgen für eine gefühlte hohe Performance während der Ladezeiten.
- **Integrationsarchitektur:** Open WebUI ist via iframe eingebettet und kommuniziert über eine sichere PostMessage-API mit der Suite-Plattform. Dies ermöglicht die Synchronisation von Authentifizierung (SSO) und den Austausch von Metadaten zwischen Chat und Backend-Diensten.
- **PWA-Unterstützung:** Die Plattform kann als Progressive Web App installiert werden, was eine native Nutzung auf mobilen Endgeräten inklusive Push-Benachrichtigungen ermöglicht.

13.3 Multimodale Interaktion und Barrierefreiheit

13.3.1 Geschäftlicher Nutzen

Menschliche Kommunikation ist nicht auf getippten Text beschränkt. In vielen Arbeitssituationen – etwa im Aussendienst, bei der schnellen Erfassung von Sitzungsprotokollen oder bei der Analyse von Diagrammen – ist die Tastatur ein Hindernis. Eine inklusive Plattform muss verschiedene Eingabekanäle unterstützen, um Barrieren abzubauen. Zudem ist in der Schweiz die Unterstützung lokaler Landessprachen und Dialekte eine Grundvoraussetzung für die Akzeptanz. Eine multimodale Schnittstelle erhöht die Datenerfassungsgeschwindigkeit und ermöglicht es auch Mitarbeitenden mit physischen Einschränkungen, die Vorteile der KI uneingeschränkt zu nutzen.

13.3.2 Konzeptioneller Ansatz

Die Plattform löst sich von der reinen Text-Eingabe und ermöglicht eine intuitive, multimodale Interaktion. Nutzer können mit dem System sprechen, Bilder zur Analyse hochladen oder Dokumente per Drag-and-Drop direkt in einen Chat ziehen. Das Konzept sieht vor, dass die KI den Kontext

unabhängig vom Medium versteht. Ein gesprochener Satz wird ebenso präzise verarbeitet wie ein hochgeladener Screenshot einer Fehlermeldung. Durch die Integration von Vision-Modellen transformiert sich die KI von einem reinen Text-Statisten zu einem visuellen Partner, der komplexe Informationen interpretieren kann.

13.3.3 Technische Umsetzung im Swiss AI Hub

Der Swiss AI Hub integriert fortschrittliche Eingabetechnologien direkt in die Schnittstelle:

- **Sprachverarbeitung:** Über eine integrierte Aufnahmefunktion können Nachrichten diktiert werden. Die Plattform unterstützt Transkription für Deutsch (inkl. Schweizerdeutsch), Französisch, Italienisch und Englisch. Antworten können via Text-to-Speech vorgelesen werden.
- **Ad-hoc RAG & Dokumenten-Interaktion:** Dateien (PDF, Office, TXT) lassen sich direkt in den Chat hochladen. Die Plattform nutzt spezialisierte Parser wie PyMuPDF, um Inhalte sofort für den Agenten zugänglich zu machen, ohne sie permanent in eine Wissensdatenbank ingestieren zu müssen.
- **Vision-Fähigkeiten:** Nutzer können Bilder oder Screenshots einfügen. Modelle mit Sehfunktionen analysieren diese, extrahieren Texte oder erklären komplexe Diagramme und Mermaid-Visualisierungen.
- **Markdown- & LaTeX-Support:** Antworten werden reichhaltig formatiert dargestellt, einschliesslich mathematischer Notationen, Tabellen und Code-Blöcken mit Syntaxhervorhebung.

13.4 Vertrauen durch Quellentransparenz und Datenkontrolle

13.4.1 Geschäftlicher Nutzen

KI-Antworten sind im geschäftlichen Umfeld nur dann wertvoll, wenn sie verifizierbar sind. Nutzer müssen wissen, ob eine Aussage auf einer aktuellen Richtlinie basiert oder eine Halluzination des Modells ist. Transparenz ist der Schlüssel zur Risikominimierung und zur Einhaltung regulatorischer Vorgaben wie dem revDSG. Gleichzeitig müssen Nutzer die volle Kontrolle über ihre digitalen Spuren behalten. Die Möglichkeit, eigene Daten einzusehen, zu exportieren oder zu löschen, ist nicht nur ein Komfortmerkmal, sondern eine rechtliche Notwendigkeit zur Erfüllung von Betroffenenrechten.

13.4.2 Konzeptioneller Ansatz

Um dem «Black-Box-Phänomen» entgegenzuwirken, implementiert die Plattform Mechanismen zur evidenzbasierten Interaktion. Jede Behauptung eines Agenten, die auf Retrieval-Augmented Generation (RAG) beruht, wird proaktiv mit Belegen untermauert. Parallel dazu wird die Argumentationskette des Agenten (Tracing) offengelegt. Das Konzept der Datenhoheit wird durch ein dediziertes Gedächtnis-Management ergänzt, bei dem Nutzer genau steuern können, welche persönlichen Präferenzen sich das System über Konversationen hinweg merken darf.

13.4.3 Technische Umsetzung im Swiss AI Hub

- **Interaktives Quellen-Panel:** Bei RAG-Antworten werden Referenzen eingeblendet. Ein Klick öffnet ein Panel mit dem Originaltext-Abschnitt («Chunk»), den Metadaten des Dokuments

und dem Relevanz-Score.

- **Observability-Integration:** Über eine Ereignisanzeige (basierend auf Arize Phoenix) können Nutzer die *„Gedankenschritte“* eines Agenten einsehen – von der Tool-Wahl bis zur Datenabfrage.
- **Gedächtnisverwaltung:** Der Benutzerspeicher erlaubt es, gelernte Fakten (z. B. *„Nutzer bevorzugt Python“*) einzusehen, zu korrigieren oder zu löschen. Das Organisationsgedächtnis dient hingegen als geteilte Faktenbasis für das gesamte Unternehmen.
- **Feedback-System & Arena-Modus:** Nutzer können Antworten bewerten. Im Arena-Modus können zwei Modelle parallel verglichen werden, wobei die Bewertungen in ein internes Elo-Rating einfließen, um die besten Modelle für spezifische Aufgaben zu identifizieren.

13.5 Nahtlose Integration in den Arbeitsalltag

13.5.1 Geschäftlicher Nutzen

Die effektivste KI ist jene, die dort präsent ist, wo die Zusammenarbeit bereits stattfindet. Wenn Mitarbeitende ihren gewohnten Arbeitsplatz in Microsoft Teams oder Slack verlassen müssen, um eine KI zu konsultieren, entsteht eine Hürde, die die Nutzungshäufigkeit senkt. Durch die Einbettung der KI in bestehende Kanäle wird sie zu einem virtuellen Teammitglied. Dies ermöglicht nicht nur schnellere Antworten, sondern auch hybride Workflows, bei denen die KI bei komplexen Entscheidungen menschliche Experten proaktiv einbezieht.

13.5.2 Konzeptioneller Ansatz

Der Swiss AI Hub verfolgt eine Strategie der Kanal-Unabhängigkeit. Die Plattform fungiert als zentrales Hirn, das verschiedene Kommunikationskanäle gleichzeitig bedient. Das Konzept des *„Bot-in-the-Loop“* ermöglicht es KI-Agenten, Aufgaben autonom zu bearbeiten und bei Bedarf Experten-Feedback via Messenger einzuholen. Sobald der Mensch antwortet, nimmt der Agent den Kontext wieder auf und führt den Prozess fort. Dies sichert die Qualität und behält die menschliche Kontrolle (*„Human Oversight“*) bei geschäftskritischen Aufgaben.

13.5.3 Technische Umsetzung im Swiss AI Hub

Die Anbindung erfolgt über die Bot Framework API und den Azure Bot Service:

- **Native Messenger-Integration:** Agenten agieren als vollwertige Kontakte in Microsoft Teams und Slack. Sie unterstützen Thread-Kontexte, Datei-Uploads und Echtzeit-Streaming.
- **Escalations-Workflows:** Agenten können strukturierte Fragen in Experten-Kanäle posten. Die Antwort des Menschen wird automatisch erfasst und in den laufenden Prozess integriert.
- **Zentrale Konfiguration:** Über die `bot_paths` in der MongoDB werden interne Routing-Pfade definiert, die festlegen, welches Agenten-Profil auf welche Kanal-Anfrage reagiert.
- **Datenschutz:** Für alle Messenger-Interaktionen gelten dieselben Aufbewahrungsrichtlinien (z. B. 30 Tage für ephemere Daten) und Sicherheitsstandards wie für die Web-Oberfläche.

14 Kapitel 13: AI-Agenten und Kernkonzepte

Während die vorangegangenen Kapitel die Infrastruktur, Sicherheit und Datenintegration beleuchtet haben, widmet sich dieser Abschnitt dem Herzstück der Wertschöpfung: den KI-Agenten selbst. In der öffentlichen Wahrnehmung werden Agenten oft mit autonomen Chatbots gleichgesetzt, die frei improvisieren. Im Unternehmenskontext ist Improvisation jedoch ein Risiko. Geschäftsprozesse verlangen nach Konsistenz, Nachvollziehbarkeit und strikter Kontrolle.

Der Swiss AI Hub bricht mit dem Paradigma der undurchsichtigen „Black Box“. Anstatt monolithische Modelle unkontrolliert entscheiden zu lassen, setzt die Plattform auf eine Architektur aus spezialisierten, workflow-basierten Komponenten. Dieses Kapitel beschreibt, wie durch deterministische Baupläne, das Swiss AI Agent Protokoll und menschliche Interventionsmöglichkeiten („Human-in-the-Loop“) verlässliche KI-Systeme entstehen, die auch komplexen regulatorischen Anforderungen genügen.

14.1 Auf einen Blick

- **Deterministische Workflows:** Agenten folgen fest definierten Pfaden (Closed Workflows) statt autonomer Improvisation, was das Verhalten vorhersagbar und auditierbar macht.
- **Transparenz durch Protokoll:** Das Swiss AI Agent Protokoll trennt strikt zwischen Steuerungslogik („Control Events“) und Benutzerinformation („Display Events“) für eine lückenlose Nachvollziehbarkeit.
- **Managed State & Context:** Eine dreistufige Kontext-Hierarchie (Run, Display, Thread) isoliert technische Ausführungen und sichert das Langzeitgedächtnis über 30 Tage.
- **Human- & Agent-in-the-Loop:** Kritische Prozesse können asynchron pausieren, um menschliche Genehmigungen einzuholen oder Aufgaben an spezialisierte Worker-Agenten zu delegieren.
- **Aktive Qualitätssicherung:** Integrierte Schutzmechanismen (Guards) validieren Eingaben und prüfen Antworten auf Faktenbasis (Context Sufficiency), um Halluzinationen technisch zu unterbinden.

14.2 Deterministische Workflow-Steuerung statt „Black Box“

14.2.1 Geschäftlicher Nutzen

Ein fundamentaler Hinderungsgrund für den KI-Einsatz in kritischen Bereichen ist die Unvorhersehbarkeit. Wenn ein Sprachmodell halluziniert oder eine Entscheidung auf einer undurchsichtigen Basis trifft, entstehen Haftungs- und Prozessrisiken. Unternehmen und Behörden benötigen die Gewissheit, dass ein Agent definierten Regeln folgt. Ein „Workflow-basierter Agent“ bietet diese Sicherheit. Er garantiert, dass Prozesse immer denselben validierten Pfaden folgen, Audit-Anforderungen erfüllen und nicht vom vorgesehenen Skript abweichen. Dies verwandelt KI von einem unberechenbaren Experiment in ein stabiles Werkzeug für die professionelle Prozessautomatisierung.

14.2.2 Konzeptioneller Ansatz

Das Konzept unterscheidet strikt zwischen der *Intelligenz* des Sprachmodells und der *Steuerung* des Prozesses. Anstatt dem Modell eine vage Anweisung zu geben und auf eine korrekte Werkzeugwahl zu hoffen, wird der Agent in einen *Closed Workflow* eingebettet. Dieser Workflow definiert eine präzise Kette von Schritten, die deterministisch ausgeführt werden. Das Sprachmodell wird dabei lediglich als kognitiver Motor innerhalb einzelner Schritte genutzt – etwa um Text zu analysieren oder zu formulieren –, während die Entscheidungslogik über den nächsten Schritt (Verzweigungen, Schleifen, Abbruchbedingungen) fest im Code verankert bleibt.

14.2.3 Technische Umsetzung im Swiss AI Hub

Im Swiss AI Hub wird dieses Konzept durch die Trennung von **Agenten-Bauplan** und **Agenten-Profil** sowie den **Agent Dispatcher** realisiert:

- **Agenten-Bauplan:** Dies ist der unveränderliche Python-Code, der die Logik und die Abfolge der Schritte definiert. Der Bauplan legt fest, wie Ereignisse verarbeitet werden und welche Aktionen (z. B. Datenbankabfrage via RAG) erlaubt sind.
- **Agenten-Profil:** Dies ist die instanziierte Konfiguration eines Bauplans. Ein Profil bestimmt, auf welche spezifischen Wissensdatenbanken oder Modelle der Agent zugreifen darf. So können auf demselben Bauplan basierend ein *HR-Agent* und ein *Rechts-Agent* erstellt werden, die strikt getrennt operieren.
- **Agent Dispatcher:** Diese Kernkomponente orchestriert die Ausführung. Durch Introspektion analysiert der Dispatcher die Schritte des Bauplans und injiziert mittels *Dependency Injection* automatisch notwendige Objekte wie die Konfiguration, den *RunContext* (temporärer Speicher) oder den *ThreadContext* (langfristiges Gedächtnis).

14.3 Transparenz durch das Swiss AI Agent Protokoll

14.3.1 Geschäftlicher Nutzen

Um Vertrauen in automatisierte Systeme zu schaffen, muss jede Aktion erklärbar sein. Auditoren müssen rekonstruieren können, warum ein Agent zu einem bestimmten Ergebnis kam. Proprietäre Frameworks verstecken diese internen Abläufe oft. Eine offene Standardisierung der Kommunikation ermöglicht hingegen eine lückenlose Beobachtbarkeit (*Observability*) und Fehleranalyse. Dies ist essenziell, um regulatorische Anforderungen an die Erklärbarkeit von KI-Entscheidungen zu erfüllen, ohne sich in proprietäre Abhängigkeiten zu begeben.

14.3.2 Konzeptioneller Ansatz

Die Plattform nutzt für die interne Kommunikation das **Swiss AI Agent Protokoll**. Dieses ereignisgesteuerte Modell definiert eine klare Sprache für alle Interaktionen. Kernprinzip ist die strikte Unterscheidung zwischen Steuerung und Anzeige. Während Steuerungsereignisse den logischen Fluss vorantreiben, dienen Anzeigeereignisse der Information des Nutzers (z. B. Gedankenprotokolle). Jedes Ereignis ist ein unveränderlicher Faktennachweis, der in einer dreistufigen Hierarchie (Run, Display, Thread) verortet ist.

14.3.3 Technische Umsetzung im Swiss AI Hub

Das Protokoll wird über einen zentralen Message Bus (NATS) abgewickelt und definiert präzise Ereignis-Typen:

- **Control Events:** Ereignisse wie `StartEvent`, `UserMessageEvent` oder `StopEvent` sind die einzigen Trigger, die einen Zustandsübergang im Workflow auslösen dürfen.
- **Display Events:** Ereignisse wie `ThoughtEvent` oder `ChunkEvent` streamen Zwischenstände oder Überlegungen des Agenten an das Frontend, ohne den Prozessstatus zu beeinflussen.
- **Hierarchische Scopes:** Jedes Ereignis trägt Metadaten zu seinem Scope. Der Run-Kontext isoliert die technische Ausführung, während der Thread-Kontext den persistenten Zustand über Konversationen hinweg speichert (bis zu 30 Tage). Dies stellt sicher, dass Agenten sich an frühere Interaktionen erinnern, während die Zugriffskontrolle auf Thread-Ebene gewahrt bleibt.

14.4 Spezialisierung und Multi-Agenten-Kollaboration

14.4.1 Geschäftlicher Nutzen

Der Versuch, einen einzigen *Super-Agenten* für alle Unternehmensaufgaben zu bauen, führt zu komplexen und schwer wartbaren Systemen. Effizienter ist der Einsatz spezialisierter Experten-Agenten, die jeweils eine Aufgabe perfekt beherrschen. Die Fähigkeit, diese Spezialisten dynamisch zu Teams zu verknüpfen, ermöglicht die Lösung komplexer Probleme durch Arbeitsteilung. Dies erhöht die Wiederverwendbarkeit von Modulen und die Robustheit des Gesamtsystems, da Fehler in einem Teil-Agenten nicht den gesamten Prozess gefährden.

14.4.2 Konzeptioneller Ansatz

Die Architektur unterstützt Multi-Agenten-Systeme durch das *Agent-in-the-Loop*-Muster. Ein primärer Orchestrator-Agent zerlegt eine komplexe Anfrage in Teilaufgaben und delegiert diese an spezialisierte Worker-Agenten. Diese Worker operieren in ihren eigenen isolierten Workflows. Ein besonderes Muster ist hierbei die Parallelverarbeitung (*Fan-Out / Fan-In*), bei der Aufgaben gleichzeitig an mehrere Agenten verteilt und deren Ergebnisse anschliessend aggregiert werden.

14.4.3 Technische Umsetzung im Swiss AI Hub

Die Plattform stellt verschiedene Muster und spezialisierte Agenten bereit:

- **RAG-Agent:** Nutzt Retrieval-Augmented Generation, um Antworten ausschliesslich auf Basis der Wissensdatenbank zu generieren. Er verwendet *Multi-Hop-Retrieval*, um Informationen über mehrere Dokumente hinweg zu synthetisieren.
- **Expert Asking Agent:** Wenn die Wissensbasis nicht ausreicht, eskaliert dieser Agent die Frage an menschliche Experten via Microsoft Teams oder Slack. Die Antwort wird erfasst und kann automatisch in die Wissensdatenbank zurückgespeist werden, wodurch das System organisch lernt.

- **Orchestrierung:** Über `AgentInTheLoop.invoke()` kann ein Agent einen anderen aufrufen. Dabei kann konfiguriert werden, ob der Thread-Kontext geteilt wird (`share_thread_id`), um eine nahtlose Konversationshistorie über Agentengrenzen hinweg zu wahren.

14.5 Menschliche Kontrolle und Qualitätssicherung

14.5.1 Geschäftlicher Nutzen

Trotz aller Fortschritte gibt es Situationen, in denen eine KI nicht autonom entscheiden darf – etwa bei hohen finanziellen Freigaben oder rechtlich sensiblen Fragen. Unternehmen benötigen einen *Not-Aus-Schalter* und Freigabeprozesse. Das Prinzip *Human-in-the-Loop* integriert menschliche Entscheider direkt in den technischen Workflow. Dies ermöglicht Automatisierung bis zum Entscheidungspunkt und wahrt gleichzeitig die menschliche Hoheit über kritische Resultate.

14.5.2 Konzeptioneller Ansatz

Ein Agenten-Workflow im Swiss AI Hub kann asynchron pausieren. Der Agent sendet eine Anfrage an einen Menschen und friert seinen aktuellen Zustand (Speicher, Variablen) ein. Erst wenn die menschliche Interaktion erfolgt, wird der Agent *aufgeweckt* und setzt seine Arbeit fort. Parallel dazu sorgen automatisierte Schutzmechanismen (*Guards*) dafür, dass sowohl die Eingaben der Nutzer als auch die Ausgaben der Agenten vordefinierte Qualitäts- und Sicherheitsstandards erfüllen.

14.5.3 Technische Umsetzung im Swiss AI Hub

Die Qualitätssicherung wird durch zwei komplementäre Mechanismen durchgesetzt:

- **Human-in-the-Loop:** Durch `HumanInTheLoop.request` wird der Workflow gestoppt und eine Aufgabe im Frontend generiert. Der Agent behält alle Zwischenergebnisse im Speicher, bis die Antwort (`HumanInTheLoop.response`) eintrifft.
- **Schutzmechanismen (Guards):** Diese validieren Interaktionen in Echtzeit:
 - **Eingangsschutzmechanismen:** Der *Agentenbeschreibungs-Schutzmechanismus* oder *Few-shot-Schutzmechanismus* prüft, ob eine Anfrage thematisch zulässig ist.
 - **Ausgangsschutzmechanismen:** Der *Context Sufficiency Guard* prüft vor dem Absenden, ob die gefundenen Quellen die Antwort tatsächlich belegen. Der *Schutzmechanismus für sensible Informationen* redigiert PII (Personenidentifizierbare Informationen), die aus internen Dokumenten stammen könnten, bevor sie dem Benutzer angezeigt werden.

15 Kapitel 14: Business-Prozessautomatisierung

Die vorangegangenen Kapitel haben dargelegt, wie KI-Agenten Wissen abrufen, verstehen und im Kontext interagieren. Doch der wahre wirtschaftliche Hebel der digitalen Transformation liegt nicht im Chatten, sondern im Handeln. Unternehmen bestehen aus Prozessen: Rechnungsfreigaben,

Kunden-Onboarding, Beschwerdemanagement oder komplexe Antragsprüfungen in der öffentlichen Verwaltung. Solange KI nur als passiver Auskunftgeber fungiert, bleibt sie ein Assistenzsystem. Zur treibenden Kraft wird sie erst, wenn sie aktive Verantwortung in End-to-End-Prozessen übernimmt.

Dieses Kapitel erläutert die Prozess-Engine des Swiss AI Hub, welche die höchste Stufe des technologischen Reifegradmodells (Stufe 3) darstellt. Es beschreibt, wie die Plattform eine Brücke schlägt zwischen statischen Workflows, autonomen Agenten und der menschlichen Belegschaft. Ziel ist die Schaffung robuster Geschäftsanwendungen, die Medienbrüche eliminieren, die Durchlaufzeiten drastisch verkürzen und dabei jederzeit transparent und kontrollierbar bleiben.

15.1 Auf einen Blick

- **Ganzheitliche Orchestrierung:** Transformation von passiven Chatbots zu aktiven Prozess-Akteuren, die Aufgaben zwischen KI, Menschen und Programmen koordinieren.
- **Zero-Config API-Generierung:** Automatische Erstellung von typensicheren REST-Endpunkten für jeden Prozess und Agenten, was die Integrationszeit massiv verkürzt.
- **Hybride Intelligenz:** Nahtlose Eskalation von KI an Menschen via *Human-in-the-Loop* oder *Bot-in-the-Loop* (Teams/Slack), inklusive automatischer Wissensrückführung.
- **Langlebige Persistenz:** Technische Unterstützung für Prozesse, die Tage oder Wochen andauern, durch persistentes State-Management auf Basis von NATS JetStream.
- **Vier Integrationsmuster:** Flexible Anbindung von Fachsystemen (ERP, CRM, eGovernment) sowohl durch aktive Agenten-Aufrufe als auch durch automatisierte Daten-Pipelines.

15.2 Ganzheitliche Orchestrierung und agentische Prozesse

15.2.1 Geschäftlicher Nutzen

Traditionelle Automatisierungslösungen (RPA) sind oft starr und scheitern an unstrukturierten Daten oder Variabilität im Prozess. Die Entwicklung massgeschneiderter Schnittstellen (APIs) für jeden neuen KI-Prozess ist zudem zeitaufwändig und teuer. Unternehmen benötigen eine Agilität, bei der ein neuer Geschäftsprozess – etwa eine automatisierte Posteingangsverarbeitung – sofort technisch verfügbar und integrierbar ist, ohne dass IT-Teams wochenlang neue API-Gateways konfigurieren müssen. Dies reduziert die *Time-to-Market* für neue Automatisierungslösungen signifikant und ermöglicht es, komplexe Abläufe als dynamische Kollaborationen zu gestalten.

15.2.2 Konzeptioneller Ansatz

Der Swiss AI Hub erweitert das Konzept des einzelnen Agenten um die übergeordnete Entität des *agentischen Prozesses*. Ein Prozess ist ein langlebiger, zustandsbehafteter Ablauf, der die Zusammenarbeit zwischen vier Entitätstypen koordiniert: Agenten (KI-Logik), Menschen (Entscheidungsträger), Programme (externe APIs) und andere Prozesse. Ein Prozess fungiert dabei als Dirigent, der Aufgaben an spezialisierte *Worker* delegiert, anstatt die Logik selbst auszuführen. Ein zentrales Konzept ist hierbei die Dienstentdeckung (Service Discovery): Die Plattform erkennt automatisch, welche Fähigkeiten verfügbar sind, und stellt diese der Aussenwelt dynamisch zur Verfügung.

15.2.3 Technische Umsetzung im Swiss AI Hub

Die Plattform realisiert dies durch die Basisklasse `AgenticProcess` und intelligente Discovery-Dienste, die den NATS-Message-Bus kontinuierlich scannen. Entwickler definieren Prozessschritte mittels des `@process_step()`-Decorators, welcher als Delegationspunkt fungiert.

Sobald ein neuer Agenten-Bauplan oder Prozess bereitgestellt wird, generiert der `ProcessEndpointsDiscoveryService` automatisch entsprechende REST-Endpunkte unter Pfaden wie `/api/v1/processes/{process_class}/{process_id}`. Der integrierte `ñJambo SchemaConverter` wandelt die Ereignisschemata der Prozesse zur Laufzeit in Pydantic-Modelle um. Dies garantiert, dass externe API-Aufrufe validiert werden, bevor sie die Geschäftslogik erreichen, und erzeugt automatisch eine aktuelle OpenAPI-Dokumentation (Swagger UI).

15.3 Hybride Entscheidungsarchitektur und Kollaborationsmuster

15.3.1 Geschäftlicher Nutzen

Ein vollständig autonomes System ist in regulierten Umfeldern oft weder rechtlich zulässig noch wünschenswert. Kritische Entscheidungen – etwa im Kreditwesen oder bei behördlichen Verfügungen – erfordern menschliches Urteilsvermögen oder die strikte Einhaltung deterministischer Regelwerke. Das Risiko von KI-Halluzinationen muss eliminiert werden. Unternehmen benötigen daher eine hybride Architektur, die KI für Vorarbeit und Analyse nutzt, die Letztentscheidung aber bei Unsicherheiten nahtlos an Fachexperten übergibt, ohne dass der Prozesskontext verloren geht.

15.3.2 Konzeptioneller Ansatz

Die Plattform setzt auf das Delegationsmuster (Delegation Pattern) und zwei Formen der menschlichen Integration. Beim `ñHuman-in-the-Loop` (HITL) fordert der Agent über die Plattform-Oberfläche eine Eingabe an. Beim `ñBot-in-the-Loop` (BITL) erfolgt die Eskalation über Kollaborationstools wie Microsoft Teams oder Slack. Stösst der Orchestrator auf Unsicherheiten, nutzt er das Prinzip des `ñExpert Asking Agent`: Die KI versucht nicht zu raten, sondern triggert einen Eskalationspfad. Die Antwort des Experten löst nicht nur das aktuelle Problem, sondern wird als neues Wissen in der Wissensdatenbank persistiert (Learning Loop), sodass die KI beim nächsten Mal autonom agieren kann.

15.3.3 Technische Umsetzung im Swiss AI Hub

Dieses Muster wird technisch durch spezialisierte Ereignisse realisiert:

- **Agent-in-the-Loop (AITL):** Die Klasse `AgentInTheLoop` ermöglicht es einem Orchestrator, Sub-Agenten aufzurufen. Über Parameter wie `share_thread_id=True` teilen sich diese Agenten das Konversationsgedächtnis, während `share_run_id=False` eine saubere technische Trennung gewährleistet.
- **Human-in-the-Loop:** Ereignisse wie `HumanInTheLoop.request` unterbrechen den technischen Workflow und erzeugen eine Aufgabe. Der Prozess verharrt in einem Wartezustand, bis ein `HumanInTheLoop.response`-Ereignis eintrifft.

- **Bot-in-the-Loop:** Via `BotInTheLoop.invoke()` postet der Agent eine Frage in einen Slack- oder Teams-Kanal. Die Antwort des Experten im Thread wird vom System erfasst, validiert und der Prozess automatisch fortgesetzt.

15.4 Systemintegration und Integrationsmuster

15.4.1 Geschäftlicher Nutzen

Ein Prozess, der keine Daten aus Fachsystemen lesen oder schreiben kann, bleibt isoliert. Der ROI von KI-Automatisierung entsteht primär durch die Integration in die bestehende IT-Landschaft – sei es das Verbuchen im SAP, das Aktualisieren eines Status im CRM oder das Ablegen eines Dokuments im eGovernment-Dossier (z. B. CMI Axioma oder Gever). Die Herausforderung liegt darin, unterschiedliche Integrationsrichtungen (Push/Pull) und Latenzanforderungen (Echtzeit/Batch) mit einer einheitlichen Plattform abzudecken, ohne für jedes System Punkt-zu-Punkt-Verbindungen bauen zu müssen.

15.4.2 Konzeptioneller Ansatz

Der Swiss AI Hub verfolgt eine umfassende Integrationsstrategie, die vier spezifische Muster unterstützt, um sowohl Echtzeit-Interaktionen als auch Massendatenverarbeitung abzudecken. Die Plattform fungiert dabei als Drehscheibe, die sowohl aktiv agieren (Outbound) als auch passiv gesteuert werden kann (Inbound).

15.4.3 Technische Umsetzung im Swiss AI Hub

Die Plattform unterstützt technisch vier definierte Integrationsmuster:

1. **Direkte Agenten-API-Aufrufe (Outbound):** Innerhalb eines Agenten-Bauplans nutzen Agenten Bibliotheken wie `httpx`, um externe REST-, SOAP- oder GraphQL-Schnittstellen synchron aufzurufen (z. B. `ñKundenstatus` abfragen).
2. **Plattform-API-Integration (Inbound):** Externe Systeme nutzen die Agent Interaction REST API, um Prozesse zu triggern. Der Traefik Reverse Proxy sichert diese Endpunkte via OAuth 2.0 oder API-Keys ab.
3. **Daten-Pipelines (Batch):** Für die Synchronisation grosser Datenmengen (z. B. aus Share-Point) nutzt die Plattform Dagster. Diese Pipelines laden Daten in die Wissensdatenbank, damit RAG-Prozesse stets auf aktuellen Unternehmensdaten operieren.
4. **Model Context Protocol (MCP):** Für Entwickler-Workflows stellt die Plattform einen MCP-Server bereit. Dies erlaubt es KI-Assistenten, den Systemzustand abzufragen und die API-Struktur dynamisch zu explorieren.

15.5 Langläufer-Prozesse und persistente Zustandsverwaltung

15.5.1 Geschäftlicher Nutzen

Reale Geschäftsprozesse sind selten in Millisekunden abgeschlossen. Eine Vertragsprüfung kann Tage dauern, weil auf die Unterschrift eines Vorgesetzten gewartet werden muss. Technische Sys-

teme dürfen während solcher Wartezeiten keine Ressourcen blockieren oder in Timeouts laufen. Die Zuverlässigkeit eines Automatisierungssystems misst sich daran, ob es Prozesse über Tage oder Wochen stabil halten kann, ohne den Kontext zu verlieren, selbst wenn Server neu gestartet oder aktualisiert werden.

15.5.2 Konzeptioneller Ansatz

Der Swiss AI Hub behandelt Zeit als fundamentalen Faktor. Die Architektur ist auf Asynchronität und Persistenz ausgelegt. Ein Prozess, der auf ein externes Ereignis wartet, verbraucht keine Rechenleistung (íSleep Modež). Sein gesamter Zustand – Variablen, bisherige Schritte, Dokumente – wird serialisiert und sicher in der Datenbank abgelegt. Sobald das erwartete Ereignis eintritt, wird der Prozess írehydriertž und setzt die Arbeit exakt an der Stelle fort, an der er pausiert hat.

15.5.3 Technische Umsetzung im Swiss AI Hub

Die technische Basis bildet eine Kombination aus NATS JetStream und robusten Persistenz-Schichten:

- **Event-Sourcing:** Jeder Schritt im Prozess erzeugt ein Ereignis. Der Zustand des Prozesses ist die Summe dieser Ereignisse. Dies ermöglicht nicht nur das Pausieren, sondern auch eine lückenlose Auditierung (íWer hat wann was genehmigt?ž).
- **Wiederherstellung:** Da der Zustand persistent ist, überleben Prozesse auch Neustarts der Container-Infrastruktur oder Updates der Plattform.
- **Observation:** Über integrierte Monitoring-Tools (Phoenix/SigNoz) können Administratoren den Status langlaufender Prozesse einsehen. Sie erkennen sofort, an welchem Schritt ein Prozess wartet (z. B. íBlocked by Userž) und können bei Bedarf manuell eingreifen.

16 Kapitel 15: Zuverlässigkeit und Qualitätssicherung

Das Vertrauen in künstliche Intelligenz ist im Unternehmenseinsatz keine Selbstverständlichkeit, sondern das Ergebnis messbarer und beweisbarer Qualität. In vielen Organisationen herrscht die berechtigte Sorge, dass generative KI-Systeme im produktiven Betrieb falsche Fakten erfinden (Halluzinationen), sensible Informationen preisgeben oder im Laufe der Zeit an Leistungsfähigkeit einbüßen. Ein Chatbot, der Kunden falsche Vertragsdetails nennt, oder ein interner Assistent, der veraltete Compliance-Richtlinien zitiert, verursacht nicht nur operative Schäden, sondern untergräbt die Akzeptanz der Technologie nachhaltig.

Der Swiss AI Hub begegnet diesen Herausforderungen mit einer integrierten Suite für Qualitätssicherung und íLLMOpsž (Large Language Model Operations). Dieses Kapitel beschreibt, wie die Plattform von der Entwicklung bis zum Betrieb sicherstellt, dass KI-Agenten verlässliche, faktentreue und richtlinienkonforme Ergebnisse liefern. Es wird aufgezeigt, wie subjektive Eindrücke durch objektive Metriken ersetzt werden und wie ein kontinuierlicher Regelkreis aus Feedback, Schutzmechanismen und Tracing die Systemqualität dauerhaft stabilisiert.

16.1 Auf einen Blick

- **Evidenzbasierte Evaluierung:** Automatisierte KI-Richter bewerten Agenten anhand fester Metriken (Korrektheit, Vollständigkeit, Prägnanz) gegen kuratierte Golden Records.
- **Echtzeit-Schutzschilde:** Integrierte Guardrails (z.B. Context Sufficiency Guard) überwachen Interaktionen zur Laufzeit und blockieren Halluzinationen oder unbefugte Datenflüsse proaktiv.
- **Nachvollziehbare Quellen:** Eine interaktive Quellenanzeige verknüpft jede KI-Antwort direkt mit den zugrundeliegenden Dokumenten-Chunks und deren Relevanz-Scores.
- **Benutzergetriebene Optimierung:** Feedback-Mechanismen wie der Arena-Modus und das Elo-Rating-System identifizieren empirisch die besten Modelle für spezifische Unternehmensaufgaben.
- **Tiefgreifende Observability:** Vollständiges Distributed Tracing via OpenTelemetry und Phoenix erlaubt es, Fehlerursachen bis auf die Ebene einzelner Vektor-Abrufe visuell zu diagnostizieren.

16.2 Systematische Evaluierung und KI-Richter

16.2.1 Geschäftlicher Nutzen

Die grösste Hürde für den produktiven Einsatz von Large Language Models (LLMs) ist ihre inhärente Unvorhersehbarkeit. Für Schweizer Unternehmen, die auf Präzision und Rechtskonformität angewiesen sind, ist das Prinzip Trial and Error inakzeptabel. Manuelle Tests durch Menschen skalieren jedoch nicht – es ist unmöglich, nach jeder Änderung an der Wissensdatenbank hunderte von Fragen händisch zu prüfen. Unternehmen benötigen einen automatisierten TÜV für ihre KI-Agenten, der Qualität messbar macht und Regressionen verhindert, bevor sie den Endanwender erreichen. Dies schafft die notwendige Entscheidungsgrundlage für Freigaben und sichert den Investitionsschutz.

16.2.2 Konzeptioneller Ansatz

Die Strategie zur Qualitätssicherung basiert auf quantifizierbaren Experimenten statt auf subjektiven Stichproben. Agenten werden gegen kuratierte Datasets getestet, die repräsentative Fragen und ideale Referenzantworten (Golden Records) enthalten. Anstatt Menschen mühsam vergleichen zu lassen, nutzt der Ansatz spezialisierte Sprachmodelle als unparteiische KI-Richter. Diese bewerten die Generierung des Agenten objektiv anhand vordefinierter Kriterien. Dieser Prozess ermöglicht es, die Performance über Zeit zu tracken und die Auswirkungen von Änderungen an Prompts oder Datenquellen sofort zu validieren.

16.2.3 Technische Umsetzung im Swiss AI Hub

Der Swiss AI Hub implementiert hierfür den zentralen **Bewertungsdienst (Evaluation Service)**:

- **Datasets:** Fachexperten pflegen Sammlungen von Testfällen. Ein Dataset enthält Fragen, Referenzantworten und bei Bedarf spezifische Edge-Cases.
- **Automatisierte Experimente:** Ein Experiment sendet die Fragen des Datasets an den Agenten. Drei unabhängige KI-Richter bewerten das Ergebnis auf einer Skala von 0 bis 5 Sternen in drei Dimensionen:

- **Korrektheit:** Faktische Genauigkeit und Freiheit von Halluzinationen im Vergleich zur Referenz.
- **Vollständigkeit:** Abdeckung aller Aspekte der Anfrage, inklusive impliziter Bedürfnisse.
- **Prägnanz:** Effizienz der Formulierung ohne unnötiges Füllmaterial.
- **Analyse und Audit:** Die Ergebnisse werden in Dashboards aggregiert. Niedrige Werte triggern gezielte Optimierungen an der Wissensdatenbank oder den System-Prompts. Phoenix kann zudem für tiefere Untersuchungen der Roh-Telemetriedaten herangezogen werden.

16.3 Laufzeit-Schutzmechanismen und Halluzinationsprävention

16.3.1 Geschäftlicher Nutzen

Selbst ein umfassend getesteter Agent kann im Live-Betrieb mit Anfragen konfrontiert werden, für die seine Wissensbasis nicht ausreicht. In solchen Momenten neigen generative Modelle dazu, plausibel klingende, aber falsche Informationen zu erfinden. In kritischen Sektoren wie dem Finanzwesen oder der öffentlichen Verwaltung ist dies ein Haftungsrisiko. Es ist geschäftlich weitaus wertvoller, wenn eine KI ehrlich ihre Unkenntnis zugibt, als wenn sie falsche Fakten behauptet. Sicherheitsmechanismen müssen daher in Echtzeit eingreifen, um die Integrität der Marke und die Verlässlichkeit der Prozesse zu schützen.

16.3.2 Konzeptioneller Ansatz

Der Schutz erfolgt durch sogenannte *Guard*s (Wächter), die als aktive Filter in den Kommunikationsfluss integriert sind. Man unterscheidet zwischen Eingangs-Schutzmechanismen (validieren die Benutzeranfrage) und Ausgangs-Schutzmechanismen (validieren die KI-Antwort). Besonders bei der Nutzung von Retrieval-Augmented Generation (RAG) ist das *Grounding* entscheidend: Eine Antwort darf nur dann freigegeben werden, wenn die abgerufenen Dokumente die Information tatsächlich belegen. Dies transformiert die KI von einer kreativen Schreibmaschine zu einem regelbasierten Informationssystem.

16.3.3 Technische Umsetzung im Swiss AI Hub

Die Plattform integriert spezifische LLM-Schutzmechanismen direkt in die Agenten-Architektur:

- **Context-Ausreichend-Schutzmechanismus:** Dieser Ausgangs-Guard analysiert das Verhältnis zwischen den abgerufenen Chunks und der generierten Antwort. Reicht der Kontext nicht aus, wird die Antwort blockiert und durch einen Standardhinweis auf fehlende Informationen ersetzt.
- **Agentenbeschreibungs-Schutzmechanismus:** Ein Eingangs-Filter, der prüft, ob eine Anfrage überhaupt in den Kompetenzbereich des Agenten fällt (z.B. blockiert er Fragen zu Kochrezepten bei einem Compliance-Agenten).
- **Schutzmechanismus für sensible Informationen:** Ergänzend zur plattformweiten Presidio-Anonymisierung scannt dieser Guard die finale Antwort auf PII, die eventuell aus internen Dokumenten stammen, und redigiert diese zu [REDACTED].

16.4 Transparenz durch Quellenbelege und Nachweisketten

16.4.1 Geschäftlicher Nutzen

In regulierten Branchen und qualitätskritischen Bereichen reicht eine richtige Antwort allein nicht aus – sie muss belegbar sein. Das „Black-Box-Problem“ der KI wird zum Akzeptanzkiller, wenn Entscheidungsträger nicht prüfen können, auf welcher Grundlage eine Empfehlung ausgesprochen wurde. Eine systematische Quellenangabe reduziert den Rechercheaufwand für die Verifizierung massiv und ermöglicht es Wissensmanagern, Lücken in der Dokumentation frühzeitig zu erkennen. Transparenz schafft Vertrauen und ist die Voraussetzung für die menschliche Aufsicht („Human Oversight“).

16.4.2 Konzeptioneller Ansatz

Jede Interaktion muss eine lückenlose Nachweiskette („Chain of Evidence“) hinterlassen. Dies bedeutet, dass nicht nur das Endresultat gespeichert wird, sondern auch der gesamte Abrufprozess. Das System muss visualisieren, welche Dokumente gefunden wurden, welche Textpassagen (Knotenpunkte) tatsächlich in den Prompt flossen und wie relevant diese für die Fragestellung waren. Dieser Ansatz macht die KI-Arbeit prüfbar und verwandelt jede Antwort in ein referenzierbares Dokument.

16.4.3 Technische Umsetzung im Swiss AI Hub

Die Plattform realisiert dies durch eine interaktive Quellenverwaltung:

- **Quellenanzeige-Panel:** In der Chat-Oberfläche kann ein Panel eingeblendet werden, das alle informierenden Dokumente auflistet.
- **Detaillierte Metadaten:** Benutzer sehen für jede Quelle den Datenbankstandort, den Namespace (Sammlung) und den exakten Titel.
- **Knotenpunkt-Inspektion:** Das System zeigt die spezifischen Textpassagen an, inklusive deren Relevanzbewertung und der Überschriftenhierarchie des Originaldokuments.
- **Deep Linking:** Ein direkter Klick führt von der zitierten Passage zum vollständigen Quelldokument im Wissensmanagementdienst, was eine sofortige Validierung im Gesamtkontext erlaubt.

16.5 Kontinuierliches Monitoring und Feedback-Zyklen

16.5.1 Geschäftlicher Nutzen

Ein KI-System ist ein lebendes Ökosystem. Modelle entwickeln sich weiter, Datenbestände ändern sich und Nutzererwartungen steigen. Um die Qualität langfristig stabil zu halten, benötigen Unternehmen eine „Voice of the Customer“ direkt im System. Nur durch die systematische Erfassung von Nutzerfeedback und das operative Monitoring von Latenzen und Kosten lässt sich der wirtschaftliche Erfolg der KI-Strategie objektiv bewerten. Proaktive Alarmierung bei Qualitätsverschlechterungen verhindert, dass schleichende Probleme (Model Drift) unbemerkt bleiben.

16.5.2 Konzeptioneller Ansatz

Qualitätsmessung wird direkt in den Arbeitsfluss integriert. Feedback ist kein separater Prozess, sondern erfolgt per Mausklick während der Konversation. Besonders wertvoll ist der Vergleich verschiedener Konfigurationen im realen Einsatz. Durch den Einsatz von Elo-Ratings, wie man sie aus dem Schachsport kennt, lässt sich empirisch ermitteln, welche Modelle oder Prompt-Varianten für die spezifischen Unternehmensdaten am besten performen. Dies ermöglicht datengetriebene Entscheidungen über die Modellwahl und Ressourcenallokation.

16.5.3 Technische Umsetzung im Swiss AI Hub

Die Plattform stellt native Instrumente für das operative Qualitätsmanagement bereit:

- **Feedback-Snapshots:** Bei einer Daumen-hoch/runter-Bewertung erstellt das System einen Schnappschuss des gesamten Chat-Kontextes für die spätere Analyse durch Administratoren.
- **Arena-Modus:** Nutzer können anonymisierte Antworten zweier Modelle vergleichen. Die Auswahl fließt in ein globales Leaderboard ein, das die Leistung über Themenbereiche (Tags) wie Support oder Recht hinweg aggregiert.
- **SigNoz & Alerting:** Operative Metriken (Fehlerraten, Latenzen, Token-Verbrauch) werden via OpenTelemetry an SigNoz gesendet. Administratoren konfigurieren Alarmer, die bei Schwellenwertüberschreitungen proaktiv via Slack oder Teams benachrichtigen.

16.6 Professionelles Debugging und Trace-Analyse

16.6.1 Geschäftlicher Nutzen

Wenn ein Agent ein unerwartetes Verhalten zeigt, benötigen IT-Teams mehr als einfache Log-Dateien. Die Fehlersuche in komplexen, ereignisgesteuerten KI-Workflows ist ohne visuelle Unterstützung extrem zeitaufwändig. Trace-gesteuertes Debugging ermöglicht es Entwicklern, jeden Denkschritt der KI wie in einem klassischen Software-Debugger nachzuvollziehen. Dies verkürzt die Zeit bis zur Fehlerbehebung (MTTR) drastisch und professionalisiert den Betrieb von KI-Systemen auf Enterprise-Niveau.

16.6.2 Konzeptioneller Ansatz

Die Observability-Strategie basiert auf Distributed Tracing. Jede Operation erhält eine eindeutige ID, die alle Aktivitäten über Dienste, Agenten und Datenbanken hinweg verbindet. Dabei werden KI-spezifische Standards (OpenInference) genutzt, um nicht nur technische Latenzen, sondern auch semantische Ereignisse wie die Token-Nutzung oder das Multi-Hop-Retrieval zu erfassen. Ergänzend wird das Verhalten durch Behavior-Driven Development (BDD) definiert: Tests werden in natürlicher Sprache verfasst, um die Erwartungen von Fachbereich und Technik zu synchronisieren.

16.6.3 Technische Umsetzung im Swiss AI Hub

Für das technische Debugging stellt das SDK umfassende Werkzeuge bereit:

- **AgentTestRunner:** Erlaubt das Testen von Agenten in einer isolierten Sandbox. In Kombination mit `pytest-bdd` wird sichergestellt, dass Agenten definierte Pfade und Bedingungen einhalten.
- **Phoenix Integration:** Über `localhost:6006` steht eine lokale Instanz von Phoenix bereit. Hier können Entwickler jeden Trace visuell inspizieren – von der Benutzereingabe über die Vektorsuche bis zur finalen Synthese.
- **Dual-Pipeline-Strategie:** Der OpenTelemetry Collector trennt detaillierte Entwicklungs-Traces (für Phoenix) von gefilterten Produktions-Metriken (für SigNoz), was die Analyse vereinfacht und Kosten für die Datenhaltung optimiert.

17 Kapitel 16: Erweiterbarkeit und Zukunftssicherheit

Die technologische Halbwertszeit im Bereich der künstlichen Intelligenz ist extrem kurz. Modelle, die heute als Marktführer gelten, können morgen bereits veraltet sein. Für Unternehmen stellt dies ein erhebliches Investitionsrisiko dar, da sich die Frage stellt, wie man eine langfristige Infrastruktur auf einem Fundament baut, das sich ständig bewegt. Eine starre Plattform, die eng an einen spezifischen Anbieter oder eine momentane Technologiegeneration gekoppelt ist, wird schnell zur technischen Schuld.

Der Swiss AI Hub begegnet dieser Dynamik mit einer Architektur, die radikal auf Wandelbarkeit ausgelegt ist. Dieses Kapitel beschreibt, wie die Plattform durch Modularität, offene Standards und eine strikte Trennung von Kernsystem und Kundenlogik sicherstellt, dass Ihre Investition auch in Jahren noch werthaltig ist. Es wird aufgezeigt, wie Sie eigene Innovationen nahtlos in die Suite integrieren, ohne die Update-Fähigkeit des Gesamtsystems zu gefährden.

17.1 Auf einen Blick

- **Lizenzrechtliche Unabhängigkeit:** Die Veröffentlichung unter der Apache 2.0 Lizenz garantiert, dass der Quellcode dauerhaft prüfbar, anpassbar und frei von Lizenzgebühren bleibt.
- **Vermeidung von Vendor-Lock-in:** Ein modulares LLM-Gateway ermöglicht den Austausch von Modell-Anbietern, beispielsweise von Azure zu Google oder lokalen Modellen, rein durch Konfiguration.
- **Native Erweiterbarkeit:** Das `Controller-Pattern` erlaubt Entwicklern, eigene Dienste zu bauen, die automatisch erkannt und nahtlos in die Benutzeroberfläche und Infrastruktur integriert werden.
- **Automatisierte API-Generierung:** Das System erstellt on-the-fly typensichere REST-Endpunkte für jeden neuen Agenten, was manuelle Entwicklungsengpässe eliminiert.
- **Sicheres Lifecycle-Management:** Durch `Version Pinning` in der Projektkonfiguration bleiben kundenspezifische Erweiterungen stabil, auch wenn die Kernplattform aktualisiert wird.

17.2 Investitionsschutz durch Open Source und Standards

17.2.1 Geschäftlicher Nutzen

Ein klassisches Risiko bei der Beschaffung von Enterprise-Software ist der `Vendor Lock-in`. Kunden geraten in eine Abhängigkeit, in der sie Preiserhöhungen, Lizenzänderungen oder Strate-

giewechsel des Herstellers ausgeliefert sind. Im schlimmsten Fall stellt ein Anbieter den Betrieb ein, und das darauf aufgebaute Unternehmenswissen geht verloren. CIOs und Einkäufer fordern daher Garantien für langfristige Verfügbarkeit und Unabhängigkeit. Eine Plattform muss sicherstellen, dass das Unternehmen jederzeit Eigentümer seiner Architektur und Daten bleibt, unabhängig von externen Marktkräften.

17.2.2 Konzeptioneller Ansatz

Der Swiss AI Hub basiert auf der Philosophie der technologischen Souveränität. Dies wird primär durch die Veröffentlichung unter der Apache 2.0 Lizenz gewährleistet. Diese liberale Open-Source-Lizenz garantiert, dass der Quellcode der Plattform für den Mandanten einsehbar, modifizierbar und dauerhaft nutzbar ist. Ergänzend dazu setzt die Architektur konsequent auf offene Industriestandards statt auf proprietäre Formate. Dies betrifft Schnittstellen, Datenhaltung und Kommunikationsprotokolle, was eine nahtlose Portabilität und Interoperabilität gewährleistet.

17.2.3 Technische Umsetzung im Swiss AI Hub

Die technische Basis bildet ein Stack aus bewährten Open-Source-Komponenten, die keine „Black Boxes“ darstellen. Da der Kerncode offenliegt, können interne Sicherheitsteams die Integrität der Software jederzeit verifizieren. Es werden keine proprietären Speicherformate verwendet. Vektordaten residieren in Milvus, relationale Daten in PostgreSQL und Dateien in S3-kompatiblen Objektspeichern wie SeaweedFS. Ein Export der Daten ist durch Standard-Datenbank-Tools jederzeit möglich. Durch die Unterstützung des „Model Context Protocol“ (MCP) öffnet sich die Plattform zudem für externe KI-Assistenten und Entwicklungsumgebungen, die den Plattformstatus über standardisierte Endpunkte inspizieren können.

17.3 Modulare Architektur und Vermeidung von Modell-Lock-in

17.3.1 Geschäftlicher Nutzen

Der Markt für Large Language Models (LLMs) ist volatil. Während heute vielleicht ein bestimmtes Modell führt, könnten morgen spezialisierte Open-Source-Modelle das beste Preis-Leistungs-Verhältnis bieten. Eine Anwendung, deren Code fest auf die API eines einzelnen Anbieters zugeschnitten ist, erfordert bei jedem Wechsel ein teures Refactoring. Unternehmen benötigen eine Infrastruktur, die „modell-agnostisch“ ist und es erlaubt, die Intelligenz im Hintergrund auszutauschen, ohne die Geschäftsprozesse im Vordergrund zu stören oder Sicherheitsrichtlinien neu definieren zu müssen.

17.3.2 Konzeptioneller Ansatz

Die Plattform verfolgt das Prinzip der losen Kopplung. Kritische Komponenten, insbesondere das Sprachmodell, die Vektordatenbank und der Embeddings-Provider, werden als austauschbare Module betrachtet. Eine Abstraktionsschicht entkoppelt die Anwendungslogik von der spezifischen Implementierung. Dies erlaubt Administratoren, Komponenten durch Konfiguration statt durch Programmierung zu wechseln. Das System ist somit „Batteries Included, but Swappable“, was bedeutet, dass es mit funktionierenden Standardkomponenten geliefert wird, aber den Kunden nicht zwingt, diese dauerhaft zu nutzen.

17.3.3 Technische Umsetzung im Swiss AI Hub

Zentrales Element für diese Flexibilität ist das LLM-Gateway, welches durch LiteLLM implementiert wird. Dieses Gateway normalisiert die APIs von über 100 Anbietern. Ein Wechsel von Azure OpenAI zu Google Gemini oder zu einem lokalen Modell via vLLM oder llama.cpp erfordert lediglich eine Anpassung der YAML-Konfiguration in der `model_list`. Die Logik der AI-Agenten bleibt davon unberührt, da sie gegen eine vereinheitlichte Schnittstelle programmiert ist. Zudem erlaubt die Konfiguration komplexes Routing, um Lasten auf verschiedene Modelle zu verteilen oder Fallbacks zu definieren, falls ein Anbieter nicht erreichbar ist.

17.4 Erweiterbarkeit durch SDK und Plugin-System

17.4.1 Geschäftlicher Nutzen

Kein Standardprodukt kann die spezifischen Anforderungen jedes Unternehmens zu 100 Prozent abdecken. Oft scheitern Plattformen daran, dass Anpassungen den Kerncode verändern, was zukünftige Updates unmöglich macht oder extrem verteuert. Die Anforderung lautet daher, maximale Anpassbarkeit bei gleichzeitiger Wahrung der Update-Fähigkeit des Kernsystems sicherzustellen. Unternehmen müssen in der Lage sein, eigene Geschäftslogik als Erweiterung zu bauen, die sich nahtlos in die Suite einfügt und automatisch von allen Plattformfunktionen profitiert.

17.4.2 Konzeptioneller Ansatz

Der Swiss AI Hub bietet ein Software Development Kit (SDK) und eine Plugin-Architektur, die Erweiterungen als gleichberechtigte Bestandteile behandelt. Das Architekturmuster trennt strikt zwischen der Kerninfrastruktur, die durch die Plattform bereitgestellt wird, und benutzerdefinierten Diensten, welche durch den Kunden entwickelt werden. Das SDK eliminiert Redundanz, da die Plattform bereits das Streaming, die Authentifizierung und das Tracing übernimmt. Erstellt ein Entwickler einen neuen Agenten-Bauplan, erbt dieser automatisch alle Enterprise-Fähigkeiten der Plattform.

17.4.3 Technische Umsetzung im Swiss AI Hub

Die Erweiterbarkeit wird durch das `Controller-Pattern` realisiert. Benutzerdefinierte Dienste erben von einer Basis-Controller-Klasse und definieren dort ihre Metadaten und API-Endpunkte. Die Plattform erkennt diese Dienste beim Start automatisch über eine `Service Discovery` und integriert sie dynamisch in die Benutzeroberfläche. Ein technologischer Meilenstein sind die dynamischen Endpunkte, bei denen der `AgentEndpointsDiscoveryService` automatisch REST-Schnittstellen für neue Agenten generiert. Da Erweiterungen denselben Technologie-Stack mit Nuxt 3 und Vue 3 nutzen, fügen sie sich nahtlos in das Erscheinungsbild der Suite ein, während sie gleichzeitig Zugriff auf die gemeinsame Infrastruktur wie NATS oder MongoDB erhalten.

17.5 Lifecycle-Management und Update-Strategie

17.5.1 Geschäftlicher Nutzen

Software altert, und ohne regelmässige Updates entstehen Sicherheitslücken. Die Angst vor inkompatiblen Änderungen führt jedoch oft dazu, dass Systeme veralten. Unternehmen benötigen eine Update-Strategie, die Stabilität garantiert. Es muss möglich sein, die zugrundeliegende Plattform zu aktualisieren, um von Sicherheits-Patches und neuen Features zu profitieren, ohne dass mühsam entwickelte, kundenspezifische Agenten-Profile und Workflows funktionsunfähig werden.

17.5.2 Konzeptioneller Ansatz

Der Swiss AI Hub löst dieses Problem durch eine strikte Trennung von Core-Plattform und Custom-Code in Kombination mit semantischer Versionierung. Die Plattform entwickelt sich unabhängig von der Kundenanwendung weiter. Die Kundenanwendung deklariert explizit, mit welcher Version des Cores sie kompatibel ist. Dies verhindert, dass ein automatisches Plattform-Update ungewollt Inkompatibilitäten einführt, da Updates bewusst und kontrolliert durchgeführt werden können.

17.5.3 Technische Umsetzung im Swiss AI Hub

Das technische Management erfolgt über Docker-Container und die Python-Paketverwaltung. In der Konfiguration des Kundenprojekts, beispielsweise in der `requirements.txt`, wird die Abhängigkeit zum Core fixiert. Ein Update des Cores erfordert eine aktive Änderung dieser Version, was Raum für Tests in einer Staging-Umgebung schafft. Da Core-Dienste und Kunden-Dienste in separaten Containern laufen, können sie unabhängig voneinander skaliert und aktualisiert werden. Die Unterstützung von Rolling Updates ermöglicht es zudem, neue Versionen bereitzustellen, ohne den laufenden Betrieb zu unterbrechen, während unveränderliche Docker-Images eine einfache Rollback-Fähigkeit bei Problemen sicherstellen.